

T319 - Introdução ao Aprendizado de Máquina: *Introdução*



Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

A disciplina

- Introdução ao aprendizado de máquina.
- Como o próprio nome diz, é um curso introdutório onde veremos os conceitos básicos de funcionamento de vários **algoritmos de aprendizado de máquina** ou do Inglês, **machine learning** (ML).
- O curso será o mais prático possível, com vários exercícios envolvendo o uso dos algoritmos discutidos.
- O curso será dividido em duas partes: T319 e T320.
- Não nós aprofundaremos nos conceitos matemáticos envolvidos.
- Porém, precisamos conhecer Python e alguns conceitos de álgebra linear e estatística.

Cronograma

Aula	Data	Dia	Horário	Atividade
1	22/2/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
2	8/3/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
3	22/3/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
4	5/4/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
5	19/4/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
6	3/5/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
7	17/5/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
8	31/5/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
9	14/6/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
10	28/6/2021	Segunda-feira	08:00	Avaliação


Objetivo do curso

- O objetivo principal do curso é apresentar à vocês
 - os conceitos fundamentais da teoria do aprendizado de máquina.
 - um conjunto de ferramentas (ou seja, algoritmos) de aprendizado de máquina.
- Ao final do curso vocês devem ser capazes de
 - Entender e discutir sobre os principais algoritmos de ML.
 - Compreender a terminologia utilizada na área.
 - Aplicar algoritmos de ML para a resolução de problemas.
 - Analisar e entender novos algoritmos de ML.
 - Criar seus próprios projetos.



Avaliação do curso

- Prova
 - Uma (1) prova valendo 85% da nota.
 - Data ainda será definida, mas será ao final do curso.
 - Teórica/prática.
- Tarefas
 - Exercícios (em grupo/individual) e quizzes.
 - 15% da nota.
 - Ao longo das aulas e para casa.
 - [Entregues no MS Teams](#).
- Presença
 - Dada através da entrega de tarefas.



Motivação

- **Emprego:** grandes companhias (e.g., Google, Facebook, Amazon, etc.) usam ML para resolver os mais diversos tipos de problemas e assim aumentarem sua eficiência/lucros.
- **Pesquisa:** já se prevê que ML terá um papel importante no desenvolvimento da próxima geração de redes móveis e sem-fio (e.g., 6G).




Referências:

- [1] Matti Latva-aho and Kari Leppänen (editors), KEY DRIVERS AND RESEARCH CHALLENGES FOR 6G UBIQUITOUS WIRELESS INTELLIGENCE, 6G Flagship, University of Oulu, Oulu, disponível online em: <http://jultika.oulu.fi/files/isbn9789526223544.pdf>
- [2] Mostafa Zaman Chowdhury, Md. Shahjalal, Shakil Ahmed, Yeong Min Jang, "6G Wireless Communication Systems: Applications, Requirements, Technologies, Challenges, and Research Directions", <https://arxiv.org/ftp/arxiv/papers/1909/1909.11315.pdf>

Um pouco de história

- A ideia de criar uma máquina pensante que imitasse as habilidades humanas é muito antiga, remontando à Grécia antiga.
- **Mitologia grega:** Talos, um autômato (máquina que realiza ações que lembram humanos ou animais) criado para proteger a princesa Europa de Creta de invasores.
- **300 A.C.:** Aristóteles almejava substituir a mão-de-obra escrava por objetos autônomos.
- **1822:** Charles Babbage cria os primeiros computadores mecânicos, as *máquinas diferencial* e *analítica*, se tornando o “pai dos computadores”.
- **1837:** Ada Lovelace escreve o primeiro programa de computador para a *máquina analítica* de Babbage, se tornando a primeira “programadora” conhecida.



- A ideia de construir uma máquina pensante ou uma criatura artificial que imitasse as habilidades humanas é muito antiga, remontando à Grécia antiga.
- Na mitologia grega, Talos, era um autômato (máquinas que realizam ações que lembram humanos ou animais) criado para proteger a princesa Europa de Creta.
- A ideia de IA como a conhecemos hoje só foi possível após o surgimento dos computadores modernos, ou seja, após a Segunda Guerra Mundial.
- A área de pesquisa em IA surgiu em 1956 em um workshop no Dartmouth College nos EUA onde o termo IA foi cunhado por John McCarthy.
- IA tem como objetivo criar máquinas que *imitem* nossa capacidade mental para uma determinada tarefa. Porém, esta *imitação* não será perfeita dado que somos construídos de matéria viva e até o momento não fomos capazes de criar nada semelhante ao nosso cérebro. Essa imitação é, portanto, apenas uma aproximação. É por isso que em IA fala-se da criação de máquinas que são modelos de nossa capacidade de aprender, raciocinar, enxergar, falar, etc.
- Embora o GPS fosse capaz de resolver problemas simples, como o problema das torres de Hanói que poderia ser *suficientemente formalizado*, ele não poderia resolver todos os problemas do mundo real, porque a busca facilmente se perderia em uma explosão combinatória de estados intermediários. **Problemas que podem ser formalizados.**

Artificial Intelligence (AI) - the broad discipline of creating intelligent machines.

Machine Learning (ML) - refers to systems that can learn from experience.

Difference: Artificial Intelligence is the broader concept of machines being able to carry out tasks in a way that we would consider “smart”. On the other hand, Machine Learning is a current application of AI based around the idea that machines should

learn for themselves by only having access to data. In **Machine learning**, algorithms acquire the knowledge or skill through experience. Machine learning relies on big data sets to find common patterns.

In summary, machine learning uses the experience to learn a pattern (induced learning). AI uses the experience to acquire knowledge/skill and also how to apply that knowledge for new environments.

First of all, **leave the terms artificial and machine aside**. We will try to understand the words intelligence and learning one-by-one. Think of how one can solve a given (mathematical and not real life) problem. There are two possibilities - *either*

Method 1: he/she/it has solved such a problem before and has **learned** how to solve such kind of problems (learned the pattern) *or*

Method 2: (it is first time he/she/it faced this type of problem and) he/she/it is **actually intelligent** to think of possibilities of how to solve the problem based on what he/she/it **knows**, right?

The former is called **learning** and the latter is called **knowledge** (along with intelligence). So, in short, to solve a problem, one needs either of these two. Hence, **learning is a part of intelligence**.

AI is a broader concept (umbrella term) to create intelligent machines that can simulate human thinking capability and behavior, whereas, machine learning is an application or subset of AI that allows machines to learn from data without being programmed explicitly.

Codebreaker: alguém que decodifica mensagens encriptadas sem a chave de criptografia.

Um pouco de história (continuação)

- **1847:** George Boole cria a lógica booleana, lançando as bases para a era da informação.
- **1943:** McCulloch e Pitts propõem um modelo matemático para o funcionamento de um neurônio. Lançando as bases para a criação das redes neurais artificiais.
- **1950:** Alan Turing cria o “*teste de Turing*”, que testa a capacidade de uma máquina em exibir comportamento inteligente indistinguível ao de um ser humano.
- **1952:** Arthur Samuel cria o primeiro programa de auto-aprendizagem (que mais tarde seria chamado de *aprendizado de máquina*) do mundo, o *Checkers-Player*, sendo a primeira demonstração do conceito de inteligência artificial.



Colossus foi um conjunto de computadores desenvolvidos por codebreakers britânicos nos anos de 1943 a 1945 para ajudar na análise de mensagens criptografadas.


Assia ao filme: The Imitation Game

Embora o ENIAC tenha sido projetado e usado principalmente para calcular tabelas de tiro de artilharia para o Laboratório de Pesquisa Balística do Exército dos Estados Unidos (que mais tarde se tornou parte do Laboratório de Pesquisa do Exército), seu primeiro programa foi um estudo da viabilidade de armas term nucleares.

“Pela primeira vez no mundo, computador engana pessoas e passa no teste de Turing”,
<https://canaltech.com.br/ciencia/Pela-primeira-vez-na-mundo-computador-engana-pessoas-e-passa-no-teste-de-Turing/>

Um pouco de história (continuação)

- **1956:** Surgimento da área de pesquisa em IA em um workshop no Dartmouth College nos EUA onde o termo IA foi cunhado por John McCarthy.
- **1958:** Frank Rosenblatt cria a primeira rede neural artificial, chamada de *Perceptron*.
- **1959:** Arthur Samuel cunha o termo *Aprendizado de Máquina* enquanto trabalhava na IBM.
- **1970-1980:** Devido a limitação dos computadores da época, IA atravessou alguns *invernos*, i.e., interesse e financiamentos na área diminuíram drasticamente.
- **1986:** Ascensão do aprendizado de máquina: redes neurais retornam a popularidade e grandes avanços em algoritmos e aplicações de ML.



1986 – Computadores se tornam mais poderosos devido a lei de Moore e pesquisadores re-descobrem as redes neurais.

Um pouco de história (continuação)

- **1997:** O supercomputador da IBM, chamado de *DeepBlue*, vence o campeão mundial de xadrez, Garry Kasparov.
- **2009:** O Google constrói o primeiro carro autônomo que dirige em áreas urbanas.
- **2011:** Outro supercomputador da IBM, chamado *Watson*, vence o show de perguntas e respostas *Jeopardy!*.
- **2011-2014:** Surgem assistentes pessoais, tais como *Siri*, *Google Now*, *Alexa* e *Cortana*, que utilizam reconhecimento de fala para responder questões e realizar tarefas simples.
- **2016:** O programa conhecido como *AlphaGo*, da empresa *DeepMind*, derrota o então 18 vezes campeão mundial de Go, Lee Sedol.
- **2018:** Universidades de todo o mundo começam a oferecer cursos de AI e ML.



Inatel

Inteligência + Artificial (IA)



- Vocês já pensaram sobre a definição destas duas palavras?
- **Inteligência:** são as **habilidades mentais** de **conhecer, compreender, aprender, resolver problemas e adaptar-se**.
 - Latim -> prefixo **inter**: "entre" + sufixo **legere**: "escolha" => "entre escolhas".
 - Ou seja, inteligência é a **capacidade de escolha** de um indivíduo entre as várias possibilidades ou opções que lhe são apresentadas.
- **Artificial:** produzido pela mão do homem, não pela natureza, geralmente como uma cópia de algo natural.

Habilidades mentais desenvolvidas de forma não natural pela mão do homem.

Cópias de habilidades mentais humanas criadas de forma não natural pelo homem.

- **Inteligência:** é um conjunto que forma todas as **características intelectuais** de um indivíduo, ou seja, a faculdade de conhecer, compreender e aprender. Capacidade de compreender e resolver novos problemas e conflitos e de adaptar-se a novas situações. É a capacidade de alguém para lógica, abstração, memorização, compreensão, autoconhecimento, comunicação, aprendizado, controle emocional, planejamento e resolução de problemas.
- **Conhecer:** perceber e incorporar à memória (algo); ficar sabendo.
- Etimologicamente, a palavra **inteligência** se originou a partir do latim *intelligentia*, oriundo de *intelligere*, em que o prefixo *inter* significa "entre", e *legere* quer dizer "escolha". Assim sendo, o significado original deste termo faz referência a **capacidade de escolha** de um indivíduo entre as várias possibilidades ou opções que lhe são apresentadas.

Definições e objetivo da IA

- **Definição:** "Capacidade de um sistema de interpretar corretamente dados externos (vindos do ambiente), aprender com esses dados e usá-los para atingir tarefas e objetivos específicos por meio de adaptação flexível." (*Andreas Kaplan*).
- **Definição:** "Ciência e engenharia de produzir máquinas inteligentes." (*John McCarthy*).
- **Objetivo:** Criar máquinas que *imitem* nossa capacidade mental para uma determinada tarefa.
- Essa *imitação* é apenas uma aproximação pois ainda não conseguimos criar matéria viva.
- É por isso que em IA fala-se da criação de máquinas que são **modelos aproximados** de nossa capacidade de aprender, raciocinar, enxergar, falar, ouvir, etc.

- **Inteligência:** é a capacidade de alguém para lógica, abstração, memorização, compreensão, autoconhecimento, comunicação, aprendizado, controle emocional, planejamento e resolução de problemas, etc. Etimologicamente, a palavra "inteligência" se originou a partir do latim *intelligentia*, oriundo de *intelligere*, em que o prefixo *inter* significa "entre", e *legere* quer dizer "escolha". Assim sendo, o significado original deste termo faz referência a capacidade de escolha de um indivíduo entre as várias possibilidades ou opções que lhe são apresentadas.
- **Artificial:** feito com arte, produzido pela mão do homem, não pela natureza.
- **Objetivo:** Criar máquinas que *imitem* nossa capacidade mental para uma determinada tarefa.
- Porém, esta *imitação* não será perfeita dado que somos construídos de matéria viva e até o momento não fomos capazes de criar nada semelhante ao nosso cérebro.
- Essa *imitação* é, portanto, apenas uma aproximação. É por isso que em IA fala-se da criação de máquinas que são *modelos* de nossa capacidade de aprender, raciocinar, enxergar, falar, ouvir, etc.

First of all, **leave the terms artificial and machine aside**. We will try to understand the words intelligence and learning one-by-one. Think of how one can solve a given (mathematical and not real life) problem. There are two possibilities - *either*

Method 1: he/she/it has solved such a problem before and has **learned** how to solve such problems *or*


Method 2: (it is first time he/she/it faced this type of problem and) he/she/it is **actually intelligent** to think of possibilities of how to solve the problem based on what he/she/it **knows**, right?

The former is called **learning** and the latter is called **knowledge** (along with intelligence). So, in short, to solve a problem, one needs either of these two. Hence, **learning is a part of intelligence**.

AI is a broader concept to create intelligent machines that can simulate human thinking capability and behavior, whereas, machine learning is an application or subset of AI that allows machines to learn from data without being programmed explicitly.

Inteligência Artificial

- IA é uma área muito ampla que **engloba** várias aplicações (ou sub-áreas ou objetivos) tais como (i) *processamento de linguagem natural*, (ii) *representação do conhecimento*, (iii) planejamento, (iv) *raciocínio automatizado*, (v) *visão computacional*, (vi) *robótica* (vii) *inteligência artificial geral* e (viii) *aprendizado de máquina* que por sua vez engloba redes neurais artificiais, deep learning, etc.
- IA utiliza a **experiência** para adquirir **conhecimento** e também como aplicar esse conhecimento a problemas desconhecidos.
- Exemplo:** Um problema matemático pode ser solucionado (i) caso ele tenha sido resolvido antes e sua solução **aprendida** ou (ii) caso ele nunca tenha sido visto antes mas um indivíduo com inteligência imagina (pensa) possíveis maneiras de como resolvê-lo baseado no que ele **sabe (conhecimento)**.



Processamento de linguagem natural: criação automática de resumos, tradução de textos em uma língua para outra, reconhecimento de fala, etc.

Representação do conhecimento: lida com problemas de como criar e armazenar conhecimento do mundo. É um campo da inteligência artificial que se concentra no design de representações computacionais que capturam informações sobre o mundo.

Raciocínio automatizado: utiliza o conhecimento armazenado por computadores para resolver problemas complexos, como por exemplo, provar teoremas matemáticos.

Visão computacional: desenvolvimento de máquinas inteligentes que obtêm informação de imagens. Exemplos: reconhecimento de faces, controle de qualidade em indústrias, carros autônomos, etc.

Robótica: lida com o design (projeto), construção e operação de robôs que repliquem ações humanas. Exemplos: robôs militares, industriais, médicos, etc.

Aprendizado de máquina: lida com o design e construção de máquinas que executam uma tarefa específica sem terem sido explicitamente programadas para isso. Exemplos: algoritmo de recomendações do netflix, carro autômato, etc. Esses algoritmos aprendem através da experiência.

- Inteligência:** é a capacidade de alguém para lógica, abstração, memorização, compreensão, autoconhecimento, comunicação, aprendizado, controle emocional, planejamento e resolução de problemas. Etimologicamente, a palavra "inteligência" se originou a partir do latim *intelligentia*, oriundo de *intelligere*, em que o prefixo *inter* significa "entre", e *legere* quer dizer "escolha". Assim sendo, o significado original deste termo faz referência a capacidade de escolha de um indivíduo entre as várias possibilidades ou opções que lhe são apresentadas.
- Artificial:** feito com arte, produzido pela mão do homem, não pela natureza.

- **Objetivo:** Criar máquinas que *imitem* nossa capacidade mental para uma determinada tarefa.
- Porém, esta *imitação* não será perfeita dado que somos construídos de matéria viva e até o momento não fomos capazes de criar nada semelhante ao nosso cérebro.
- Essa *imitação* é, portanto, apenas uma aproximação. É por isso que em IA fala-se da criação de máquinas que são *modelos* de nossa capacidade de aprender, raciocinar, enxergar, falar, ouvir, etc.

KR&R: Knowledge representation and reasoning

Algumas aplicações de IA

Algumas áreas onde IA é aplicada são:

- **Transporte:** veículos terrestres e aéreos autônomos, previsão do tráfego, etc.
- **Negócios:** recomendação de anúncios, produtos e conteúdos (e.g., netflix), chatbots para atendimento ao cliente, etc.
- **Educação:** pontuação automatizada de fala em testes de Inglês, correção de provas, chatbots para realização de matrículas, dúvidas, etc.
- **Clima:** previsão do tempo (temperatura, chuva, furacões, etc.).
- **Medicina:** detecção e/ou previsão de doenças (câncer, Alzheimer, Pneumonia, COVID-19, etc.), chatbots que auxiliam no agendamento de consultas e respondendo perguntas referentes a uma doença, descoberta de novas drogas, etc.
- **Finanças:** detecção de fraudes com cartão de crédito, previsão do comportamento do mercado de ações, etc.
- **Tecnologia:** filtros AntiSpam, “motores” de busca como o do Google, reconhecimento de fala, conversão de texto/fala e fala/texto, assistentes pessoais on-line (e.g., Siri, Alexa, etc.), tradução de textos.



Recomendação de anúncios/produtos: IA extrai conhecimento através do comportamento dos clientes e com isso consegue recomendar produtos específicos/customizados para os clientes.

“Faculdade particular usa robô para corrigir provas e dar nota aos alunos”,
<https://cartacampinas.com.br/2020/04/faculdade-particular-usa-robo-para-corriger-provas-e-dar-nota-aos-alunos/>


“Artificial Intelligence May Be Key to Better Weather Forecasts”,
<https://eos.org/opinions/artificial-intelligence-may-be-key-to-better-we>

“AI improves fraud detection, prediction and prevention”,
<https://www.ibm.com/analytics/fraud-prediction-weather-forecasts>

“Inteligência artificial ajuda em diagnóstico da covid-19 no Brasil”,
<https://www.correiobraziliense.com.br/app/noticia/ciencia-e-saude/2020/08/04/interna-ciencia-saude,878353/inteligencia-artificial-ajuda-em-diagnostico-da-covid-19-no-brasil.shtml>

Exemplos interessantes do uso de IA

- **Predição de surtos de doenças infecciosas:** IA previu em Dezembro de 2019 o novo surto de corona vírus e onde ele apareceria em seguida.
- **Ajuda no diagnóstico de doenças:** IA tem sido usada para ajudar médicos a diagnosticarem o novo coronavírus através de imagens de raio-X e tomografias.
- **Criação de vídeos/fotos falsas:** IA foi usada para criar vídeo viral utilizando trecho de “A Usurpadora” para falsificar uma conversa entre Lula e Bolsonaro.
- **Criação de novos medicamentos:** IA foi utilizada para criar uma nova droga capaz de combater o transtorno obsessivo-compulsivo (TOC). Encurtou o tempo para encontrar novos medicamentos de 4 para menos de 1 ano.



- **Predição de surtos de doenças infecciosas:** IA ajudou uma startup a prever em Dezembro de 2019 o novo surto de corona vírus e onde ele apareceria em seguida.
 - Eles utilizaram processamento de linguagem natural e aprendizado de máquina para processar informações e notícias publicadas em redes sociais, sites e jornais em mais de 30 idiomas, além de informações sobre passagens aéreas.
- **Criação de vídeos/fotos falsas:** Redes Generativas Adversariais e Autoencoders foram usados no vídeo viral que utilizou trecho de “A Usurpadora” para falsificar uma conversa entre Lula e Bolsonaro.
- **Criação de novos medicamentos:** IA foi utilizada para criar uma droga capaz de combater o transtorno obsessivo-compulsivo (TOC).
 - Uma Rede Neural (professor) é inicialmente treinada para distinguir entre compostos químicos que funcionam no sistema imunológico humano e compostos inúteis.
 - Na sequência, outro modelo (aluno) aprende a gerar diferentes combinações de compostos.
 - Em seguida, o aluno gera trilhões de diferentes combinações de compostos e os apresenta ao professor, que separa as combinações que podem resultar em novos medicamentos.
 - Neste caso, IA ajudou a encurtar o tempo necessário para se encontrar novos medicamentos de 4 para menos de 1 ano.

Foco do curso

- Como vimos, IA é um termo muito amplo, abrangendo várias sub-áreas, usado para designar máquinas capazes executar **tarefas** de forma inteligente.
- **Foco do curso:** estudo dos principais algoritmos de **Aprendizado de Máquina**.
- **Por quê?**
 - **Caixa de ferramentas:** ML oferece ferramentas importantes para a solução e análise eficiente de vários problemas em várias áreas.
 - **Redução de complexidade e custo:** vários algoritmos em várias áreas que apresentam desempenho ótimo não são utilizados na prática pois possuem complexidade computacional e/ou custo proibitivos.
 - **Oportunidades:** existem muitos empregos na área de análise de dados e pesquisas sobre a aplicação de ML.

The diagram illustrates the focus of the course through four interconnected icons: a person at a computer for Natural Language Processing, a brain with a gear for Knowledge Representation, a gear with a checkmark for Automated Reasoning, and a circuit board for Machine Learning.

AI is a broad concept of machines being able to carry out tasks smartly while machine learning (ML) is a current (probably the most popular) application/sub-area of AI that enables machines to learn from large amounts of data and act accordingly without being explicitly programmed.

AI is the ability to acquire and apply knowledge, and perform naturally like a human. For example, planning, problem solving, reasoning, learning, etc.

- **Planejamento:** (determinar ações necessárias para se atingir um objetivo) tem como objetivo refletir e decidir quais ações devem ser tomadas por uma máquina, antecipando resultados esperados. Exemplo: planejamento de uma operação de resgate após um desastre natural.
- **Representação do conhecimento e raciocínio:** (armazenar informação de forma eficaz e de rápido acesso. Baseado em informações conhecidas ser capaz de determinar novas informações) tem como objetivo representar informações sobre o mundo de uma forma que uma máquina possa utiliza-las para resolver tarefas complexas tais como diagnosticar uma condição médica ou conversar com alguém através de linguagem natural.
- **Aprendizado de máquina:** tem como objetivo fazer com que uma maquina aprenda sem ser explicitamente programada através de uma grande quantidade de dados. Algoritmos de ML tem como objetivo aprender com seus erros e fazer previsões sobre dados. Exemplo, filtragem de spam, motores de busca como o do Google, diagnostico de doenças, etc.
- **Processamento de linguagem natural:** tem como objetivo a geração e compreensão automática de línguas naturais. Exemplos: reconhecimento de voz, transcrição de voz em texto e vice versa,

- **Visão computacional:** tem como objetivo a construção de máquinas que obtém entendimento de alto-nível a partir de imagens ou vídeos. Exemplo: processamento de imagens para diagnósticos médicos. Inspeção e controle de qualidade.
- **Robótica:** (interação com o mundo) tem como objetivo o design/projeto, construção, operação e uso de robôs, bem como sistemas de computador para controle, feedback sensorial e processamento de informações. Exemplos: robôs domésticos, drones autônomos, robôs industriais, robôs militares (drones, tanques, resgate).
- **Inteligência artificial geral:** também conhecida como IA forte ou IA completa. Tem como objetivo desenvolver máquinas que percebam o ambiente ao seu redor e que executem ações que maximizem sua chance de atingir com sucesso seus objetivos. Ou seja, tem como objetivo criar máquinas que executem toda a gama de habilidades cognitivas humanas.
- Foco do curso: estudo dos principais algoritmos de **Aprendizado de Máquina**. Por quê?
 - ML oferece ferramentas importantes para a solução eficiente de vários problemas de Telecomunicações.
 - Pós-graduação em Telecomunicações.
 - Sistemas de comunicações são estudados e desenvolvidos baseando-se em modelos matemáticos (muitas vezes simplificados) que não capturam com precisão os efeitos dos sistemas e canais do mundo real (HW: intermodulação, desbalanceamento de quadratura, perdas por quantização, etc. e o canal: desvanecimento, multi-percursos, interferência, etc.).
 - Modelos de canal, imperfeições do hardware, interferência, etc. são muito complicados na prática devido à natureza dinâmica dos canais de comunicação sem fio.
 - **Controle e otimização de parâmetros:** Além disto, o número de parâmetros (modulação, vetores de beamforming, taxas de código, larguras de banda, canais, potência de transmissão, seleção da melhor rota) que um sistema de próxima geração precisa controlar e otimizar continua a crescer.
 - Algoritmos de aprendizado de máquina podem modelar correlações e estimar parâmetros (sub)ótimos do sistema.
 - **Redução de complexidade/custo:** Complexidade e/ou custo de algoritmos de comunicações ótimos as vezes é proibitivo. Por exemplo, algoritmos de otimização como o de controle de potência em sistemas (massive) MIMO podem exibir alta complexidade, impedindo sua utilização/implementação em sistema de tempo real. Dirty Paper Coding (DPC) que é a técnica ótima de pré-codificação em sistemas MIMO, possui alta complexidade computacional e de implementação e portanto, não é implementado em sistemas reais. Linearização dos canais de fibra-ótica. Pré-distorção de amplificadores de RF.
 - **Oportunidades:** Pesquisas sobre a aplicação de aprendizado de máquina em problemas de comunicações móveis e sem fio ainda estão em fase de exploração.
- Channel and interference models are extremely complicated in reality due to the dynamic nature of wireless communication channels.

Telecommunications is a discipline traditionally driven by well-established mathematical models. First, while communications' systems have developed largely as a **model-driven** field, the complexities of many emerging communication scenarios raise the need to introduce **data-driven** methods into the design and analysis of mobile networks.

Designers rely on simplified closed-form models that don't accurately or holistically capture the effects of real-world systems and channels.

Additionally, the degrees of freedom required to operate next-generation communications systems continues to increase. The number of radio and modulation parameters, such as antennas, channels, bands, beams, codes, and bandwidths, represent degrees of freedom that must be controlled by the radio system. Individual communications standards now use many more of these – in part, as an effort to mitigate the growing number of impairments.


Research in the field of machine learning for wireless communications are still largely in an exploration phase.

Até hoje, sistemas de comunicações são estudados e desenvolvidos baseando-se modelos matemáticos (muitas vezes simplificados) que não capturam com precisão os efeitos dos sistemas e canais do mundo real.

Weak AI is the form of AI where programs are developed to perform specific tasks, for instance, Machine learning, Planning, Computer vision, etc.

ML is a learning technique where machines *learn* from huge data sets.

Mas então, o que é ML?



- É uma sub-área ou objetivo da inteligência artificial.
- O termo foi cunhado em 1959, por Arthur Samuel, que o definiu como o *“campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados”*.
- Uma outra definição interessante feita por Jojo John Moolayil é *“Aprendizado de máquina é o processo de **induzir** inteligência em uma máquina sem que ela seja explicitamente programada”*.
 - **Indução**: aprender um modelo ou padrão geral a partir de exemplos.
- Algoritmos de ML são **orientados a dados**, ou seja, eles aprendem automaticamente um modelo/padrão geral (i.e., generalizar) a partir de grandes volumes de dados (i.e., exemplos).
- **Exemplo**: filtro de spam do Gmail.

ML: técnicas e algoritmos orientadas a dados: aprendem automaticamente a partir de grandes volumes de dados.

O aprendizado de máquina pode ser definido como o processo de **induzir** inteligência em uma máquina **sem que ela seja explicitamente programada**.

Por exemplo, o filtro de spam do gmail utiliza aprendizado de máquina para aprender se um email é spam (por exemplo, sinalizados por usuários) e exemplos de emails regulares (não spam, também chamados de “ham”).

Os exemplos que o modelo usa para aprender são chamados de **conjunto de treinamento**. Cada **exemplo de treinamento** é chamado de **instância de treinamento** (ou amostra).

Por que ML se tornou tão importante?

Alguns dos principais motivos são:

- Vivemos na era da informação. Nessa era, um volume sem precedentes de dados (de tera a petabytes) está disponível, impossibilitando sua análise por nós seres humanos.
- Porém, para modelos de ML isso não é um problema e sim uma solução, quanto mais dados melhor será o aprendizado.
- Hoje em dia, dados são preciosíssimos e a extração de novas informações (úteis) vale ouro.
- O surgimento de recursos computacionais poderosos tais como GPUs, FPGAs e CPUs com múltiplos cores.
- Surgimento de novas e eficientes estratégias/técnicas de treinamento (i.e., aprendizagem).
- Existência de frameworks e bibliotecas poderosas que facilitam o desenvolvimento de soluções com ML.



Estamos vivendo na era da informação. Nessa era, um volume sem precedentes de dados (de tera a petabytes) está disponível, impossibilitando sua análise por nós seres humanos. Porém, para modelos de ML, quanto mais dados melhor será o aprendizado. Surgimento de recursos computacionais poderosos tais como GPUs, FPGAs, CPUs com múltiplos cores.

Surgimento de novas estratégias de treinamento (i.e., aprendizagem).

Existência de frameworks e bibliotecas que facilitam o desenvolvimento de soluções com ML.

TensorFlow é uma biblioteca de software livre e de código aberto para fluxo de dados e programação diferenciável. É uma biblioteca matemática simbólica e também é usada para aplicativos de aprendizado de máquina, como redes neurais.

Theano é uma biblioteca de computação científica. Foi desenvolvido pela Université de Montréal e está disponível desde 2007.

PyTorch é uma biblioteca de aprendizado de máquina de código aberto baseada na biblioteca Torch usada em aplicações de visão computacional e processamento de linguagem natural.

Scikit-learn é uma biblioteca de aprendizado de máquina de software livre para a linguagem de programação Python.

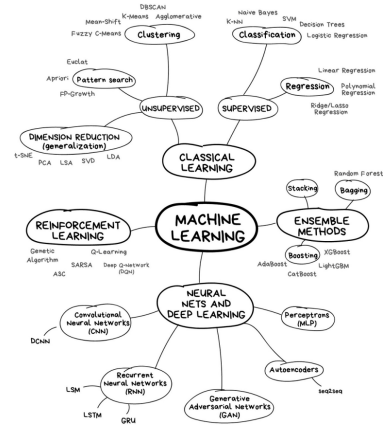
Keras é uma biblioteca de rede neural de código aberto escrita em Python. É capaz de rodar sobre TensorFlow, Microsoft Cognitive Toolkit, R, Theano ou PlaidML. Keras foi projetado para permitir experimentação rápida com redes neurais profundas, ele se concentra em ser fácil de usar, modular e extensível.

Pandas é uma biblioteca de código aberto criada para a linguagem de programação Python para manipulação e análise de dados. Em particular, oferece estruturas e operações de dados para manipulação de tabelas e séries temporais.

Tipos de Aprendizado de Máquina


Os algoritmos de aprendizado de máquina podem ser agrupados nas seguintes categorias:

- Supervisionado
- Não-Supervisionado
- Semi-Supervisionado
- Por Reforço
- Metaheurístico



Aprendizado Supervisionado



- Neste tipo de aprendizado, os dados ou exemplos de treinamento incluem os **atributos**, x , que são a entrada do algoritmo de ML e as **soluções desejadas**, y , (i.e., as respostas corretas), chamadas de **rótulos** (ou *labels*, do Inglês).
- Tarefa**: os modelos supervisionados de ML devem **aprender** uma função que mapeie as entradas x nas saídas y , ou seja, $y = f(x)$.
- Esse tipo de aprendizado pode ser dividido em problemas de: **Regressão** e **Classificação**.
 - Classificação**: o rótulo, y , pertence a um **conjunto finito** de valores, i.e., conjunto finito de classes.
 - Regressão**: o rótulo, y , pertence a um **conjunto infinito** de valores, i.e., números reais.



- Aprendizado supervisionado é o processo de aprendizado quando a máquina sabe o que aprender, ou seja, os **rótulos** são o que a máquina deve aprender.
- No **aprendizado supervisionado**, os dados de treinamento que você alimenta para o algoritmo incluem as soluções desejadas, chamadas de rótulos
- Por exemplo, a algoritmo de ML do filtro de spam, tem como entrada o email (**atributos** são: remetente, assunto, corpo do email, horário recebido) e um **rótulo** dizendo se aquele é ou não um spam.
- Analogia com trabalho, onde você tem alguém supervisionando seu trabalho e dizendo se o que foi feito está ou não correto.
- Exemplos de **regressão**: predição de quando o número de leitos de UTI vão se esgotar devido a uma pandemia, predição do preço de ações, predição do preço de imóveis, no caso de engenharia aproximação da PDF de uma variável aleatória com PDF desconhecida, predição do path-loss.

Principais Algoritmos para Aprendizado Supervisionado

- Regressão linear.
- Regressão logística.
- k vizinhos mais próximos (*k-nearest neighbors* - k-NN).
- Árvores de Decisão (*Decision Trees*).
- Florestas Aleatórias (*Random Forests*).
- Máquinas de Vetores de Suporte (*Support Vector Machines* - SVMs).
- Redes Neurais Artificiais.




SVM: pode ser usado, por exemplo, para criar um modelo de previsão de perda de caminho (path-loss) para ambientes urbanos usando máquinas de vetores de suporte (SVM) para garantir um nível aceitável de qualidade de serviço (QoS) para usuários de redes móveis e sem fio.

Deep Neural Network (ou Deep Learning): pode ser utilizada para predição da futura ocupação do espectro de frequências por redes vizinhas desconhecidas. Esta predição pode, por exemplo, ser utilizada por schedulers (alocadores de recursos) durante a alocação de recursos com o objetivo de mitigar colisões, encontrar o canal e a potência ótima.

Aprendizado Não-Supervisionado

- Neste tipo de aprendizado, as máquinas não são informadas sobre o que aprender. Elas só recebem os exemplos de treinamento, x .
- Neste caso, os algoritmos ***aprendem/descobrem padrões*** (ocultos) presentes nos dados de entrada sem a presença de rótulos.
- **Tarefa:** os modelos devem ***descobrir/aprender*** padrões desconhecidos se baseando apenas nos exemplos de entrada.
- Trata problemas de clusterização, redução/aumento de dimensionalidade, detecção de anomalias (*outliers*) e aprendizado de regras de associação.




- **Clusterização:** tarefa de agrupar automaticamente os dados de entrada (i.e., features) em categorias/classes. A categoria é o rótulo que é determinado para os dados de entrada fornecidos. Ou seja, podemos dizer que a clusterização tem como objetivo fazer com que a máquina aprenda/encontre classes/grupos e rotule as features.
 - **Exemplo de aplicação:** Agrupar/encontrar grupos de clientes que são similares em termos de comportamento ou características para envio de propaganda personalizada.
- **Redução de dimensionalidade:** como o próprio nome já diz, tem por objetivo encontrar formas eficientes de representação das entradas/features, ou seja, aprender vetores de saída com menor dimensão mas que ainda representem bem o vetor de entrada.
 - **Exemplo de aplicação:** Em reconhecimento de faces, as features possuem grandes dimensões (ou seja, grandes vetores) o que dificulta o treinamento de algoritmos de ML, portanto, diminuindo-se a dimensão das features pode-se diminuir o tempo de treinamento sem afetar grandemente a performance do algoritmo utilizado.
- **Aumento de dimensionalidade:** aprender vetores de saída que possuam uma dimensão maior, aumentando a quantidade de informação sobre aquele vetor.
 - **Exemplo de aplicação:** Em sistemas de comunicação digital o aumento de dimensionalidade é utilizado para encontrar *palavras código* (code words) ótimas para um canal sem fio, ou seja, esse tipo de aprendizado encontra um vetor que possui informações adicionais (redundância) que consequentemente aumenta a chances de decodificação bem sucedida da mensagem transmitida.
- **Detecção de Anomalias:** detecta se uma nova observação (i.e., feature) pertence à mesma distribuição que as observações existentes/anteriores. Identificação de

features que levantam suspeitas por serem significativamente diferentes da maioria dos dados.

- **Exemplo de aplicação:** detecção de fraude bancária, defeito estrutural, problemas médicos, erros em um texto, controle de qualidade em fábricas, etc.
- **Regras de associação:** tarefa de associar as entradas (i.e., features), encontrando regras que descrevam grandes porções dos dados.
 - **Exemplo de aplicação:** Localização de itens em supermercados. Por exemplo, o algoritmo pode encontrar uma regra de associação que diz que mais de 70% dos clientes que compram leite também compram pão e portanto, o supermercado pode colocar ambos produtos próximos uns dos outros, aumentando a chance da venda desses produtos.

Principais Algoritmos para Aprendizado Não-Supervisionado

- **k-médias (*k-means*)**.
 - Particiona as features em **k** clusters distintos com base na distância ao centroide de um cluster.
- **Redes Neurais Artificiais**, e.g., auto-encoders.
 - Os autoencoders são usados para redução ou aumento de dimensionalidade.
- **Análise de Componentes Principais (*Principal Component Analysis* - PCA)**.
 - Redução de dimensionalidade.



No aprendizado não-supervisão não se sabe o que a máquina precisa aprender.

Alguns algoritmos não-supervisionados são:


- **k-médias**: particiona os dados em k clusters distintos com base na distância ao centroide de um cluster.
- **Autoencoders**: usado para redução ou para aumento de dimensionalidade.

Exemplos:

- **k-médias**: encontrar grupos de clientes com um mesmo perfil de compra ou encontrar separações ótimas para a decodificação de uma modulação desconhecida.
 - Imagine que você tenha dados de uma modulação mas que você não tenha os labels, com o k-médias você pode encontrar grupos/clusters que representariam cada um dos símbolos da modulação desconhecida.
 - Num supermercado, baseado em várias características do que foi comprado o algoritmo poderia encontrar um cluster/grupo de homens que compram fraldas e que também compram cerveja, e o supermercado poderia colocar essas mercadorias juntas.
- **Auto-encoders**: podem ser usados em comunicações digitais para por exemplo aprender um sistema de codificação e decodificação de canal ótimo para um dado canal sem-fio.
- **PCA**: utilizado na redução da dimensionalidade. Utilizado em problemas onde um número de dimensões é muito grande para ser tratado por um modelo em tempo razoável e com recursos computacionais existentes.

Principais Algoritmos para Aprendizado Não-Supervisionado (continuação)

- Análise de Componentes Independentes (*Independent Component Analysis* - ICA)
 - Realiza uma espécie de clusterização baseada em propriedades estatísticas dos sinais envolvidos.
- Mapas Auto-Organizáveis (*Self-Organized Map* - SOM)
 - Tipo de rede neural usada para aprender a topologia e distribuição dos dados.
- Modelos Ocultos de Markov (*Hidden Markov Models* - HMM)
 - usa dados observados para recuperar uma sequência de estados.



Alguns algoritmos não-supervisionados são:


- **Self-organizing maps:** usa redes neurais para aprender a topologia e distribuição dos dados.
- **Hidden Markov Models:** usa dados observados para recuperar uma sequência de estados.

Exemplos:

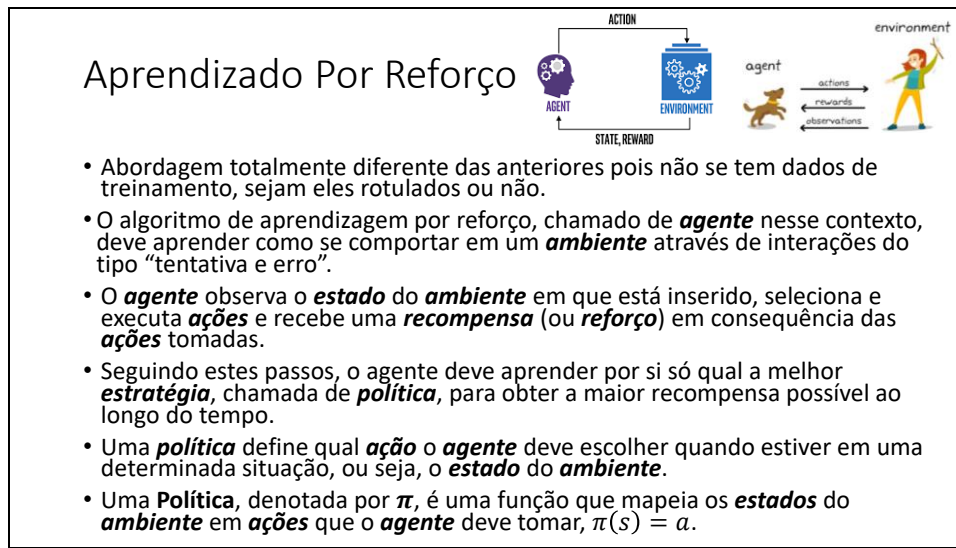
- ICA: utilizado no “problema do coquetel” onde o algoritmo separa as conversas de várias pessoas falando ao mesmo tempo em um mesmo ambiente.
- SOM: utilizado para criar visualizações de baixa dimensão à partir de dados de alta dimensão.
- HMM: utilizados em reconhecimento de fala para reconhecer a sequência de fonemas e por fim identificar uma palavra.

Aprendizado Semi-Supervisionado

- Neste tipo de aprendizado, as máquinas tem acesso a exemplos com e sem rótulos.
- Geralmente envolve uma pequena quantidade de dados rotulados e uma grande quantidade de dados não-rotulados.
- É de grande ajuda em casos onde se ter uma grande quantidade de dados rotulados é muito caro ou complexo.
- Algoritmos de aprendizagem semi-supervisionada são o resultado da combinação de algoritmos supervisionados e não-supervisionados.
- **Exemplo:** Facebook e Instagram recebem várias fotos suas e de conhecidos seus. Em várias fotos enviadas a eles, um algoritmo de **clusterização** agrupa pessoas A, B e C, em outras várias fotos enviadas, pessoas B, D e E. Em um determinado momento, você carrega uma foto onde você fornece o nome (label) de algumas dessas pessoas.



Exemplo: O Facebook/Instagram recebe centenas/milhares de fotos suas e de conhecidos/familiares seus. Em uma grande quantidade de fotos um algoritmo de clusterização encontra/agrupa pessoas A, B e C, em outra grande quantidade de fotos pessoas B, D e E. Em determinado momento, você carrega uma foto onde você fornece o nome (label) de algumas desses grupos/pessoas.





- Aprendizado por reforço pode ser entendido como o problema em que um **agente** deve aprender como se comportar em um **ambiente** através de interações do tipo “tentativa e erro”.
- O **agente** tem como objetivo aprender/construir um modelo do ambiente em que está inserido.
- O algoritmo aprende a escolher **ações** apenas interagindo com o **ambiente**.
- **Problema da aprendizagem por reforço**: Como escolher uma **política** de **ações** que maximize o total de **recompensas** recebidas pelo **agente**.
- A **política** pode ser entendida como sendo a função que mapeia os **estados** do **ambiente** em **ações** que o **agente** deve tomar: $\pi(s) = a$.
- **Exemplos**:
 - Algoritmo muito utilizado em jogos.
 - O programa AlphaGo da Google (DeepMind) utilizou aprendizado por reforço (Deep reinforcement learning) para aprender a jogar Go e derrotar o campeão mundial de Go.
 - Agente jogador de damas
 - **Estados**: as diferentes configurações do tabuleiro.
 - **Ações**: mover uma determinada peça.
 - **Recompensas**: número de capturas de peças vs. número de perdas.
 - Modulação e codificação adaptativas
 - **Estado**: qualidade do canal (CQI) enviado pelo dispositivo móvel (podem haver vários outros estados, por exemplo QoS).
 - **Ação**: modulação e taxa de código.
 - **Recompensa**: uma medida baseado na taxa de erro de bloco (BLER) ou na eficiência espectral (i.e., no número de bits/s/Hz possível).

- Robô aspirador de pó que precisa aprender a limpar uma casa de forma ótima.
- Os algoritmos de aprendizado por reforço tentam encontrar a **política** que mapeia os **estados** do **ambiente** às **ações** que o **agente** deve tomar nesses **estados**.
- Como um algoritmo de aprendizagem aprende a escolher ações apenas interagindo com o ambiente?
 - Muitas vezes, é impraticável o uso de aprendizagem supervisionada.
 - Como obter exemplos do comportamento correto e representativo para qualquer situação?
 - E se o agente for atuar em um ambiente desconhecido?

Principais Algoritmos de Aprendizado Por Reforço

- Q-Learning
 - Usado para encontrar uma **política** ótima de seleção de **ações** usando a **função-Q**.
 - 'Q', ou **valor-Q**, representa a **qualidade** de uma dada **ação** em um determinado **estado**.
- Deep Q-Learning
 - Junção de Deep Learning + Q-Learning. Redes neurais profundas possibilitam que Q-Learning seja aplicado a problemas com número gigantesco de **estados** e **ações**.
 - O Q-Learning tabela a **função-Q**, já o Deep Q-Learning encontra uma função que aproxime a **função-Q**.



Deep Q-Learning: É a junção de Deep Learning com Q-Learning. As redes neurais profundas possibilitam que Q-Learning seja aplicado a problemas maiores.

Q-Table é apenas um nome sofisticado para uma tabela de pesquisa (lookup Table) simples, onde calculamos as recompensas futuras máximas esperadas para a ação em cada estado.

Cada posição na tabela Q será a recompensa futura máxima esperada que o agente receberá se executar essa ação nesse estado. Este é um processo iterativo, pois precisamos melhorar o Q-Table a cada iteração.

Uma função de valor Q mostra o quão boa uma determinada ação é, dado um estado, para um agente que segue uma determinada política.

Aprendizado Metaheurístico

- São algoritmos usados para resolver de forma genérica problemas de otimização.
- Uma **metaheurística** é um método **heurístico** para resolver de forma genérica problemas de otimização.
- **Heurística** é um método ou processo criado com o objetivo de encontrar soluções, de forma rápida e muitas vezes sub-ótimas, para um problema.
- **Metaheurísticas** são geralmente aplicadas a problemas para os quais não se conhece algoritmo eficiente (veja problemas NP-completos).
- Metaheurísticas
 - não garantem que uma solução globalmente ótima seja encontrada.
 - são estratégias que orientam o processo de busca.
 - não são específicas do problema.

Heurística é um método ou processo criado com o **objetivo de encontrar soluções, muitas vezes sub-ótimas, para um problema.**

Em otimização matemática e ciência da computação, heurística é uma técnica projetada para resolver um problema mais rapidamente quando os métodos clássicos são muito lentos, ou para encontrar uma solução aproximada quando os métodos clássicos não conseguem encontrar qualquer solução. Isso é obtido trocando-se a otimização, integridade, precisão ou precisão por velocidade. De certa forma, pode ser considerado um atalho.

Uma **metaheurística** é um procedimento de alto nível projetado para encontrar, gerar ou selecionar uma heurística (i.e., algoritmo de busca local) que pode fornecer uma solução suficientemente boa para um problema de otimização, especialmente com informações incompletas ou imperfeitas ou quando se tem capacidade de computação limitada.

Principais Algoritmos de Aprendizado Metaheurístico

- Algoritmo Genético (*Genetic Algorithm - GA*).
 - Inspirados pelo processo de seleção natural.
- Otimização por enxame de partículas (*Particle Swarm Optimization - PSO*).
 - Inspirado no comportamento de cardumes de peixes e de bandos de pássaros
- Otimização da colônia de formigas (*Ant Colony Optimization - ACO*).
 - Inspirado no comportamento das formigas ao saírem de sua colônia para encontrar comida.





Figure 3. A, ants in a pheromone trail between nest and food. B, an obstacle interrupts the trail. C, ants find two paths to go around the obstacle. D, a new pheromone trail is formed along the shorter path.

- **Algoritmos Genético:** inspirados pelo processo de seleção natural. São projetados para encontrar, gerar ou selecionar uma heurística (algoritmo de busca parcial) que forneça uma solução suficientemente boa para um problema de otimização, especialmente com informações incompletas ou imperfeitas ou capacidade de computação limitada. Aprendizado baseado na evolução biológica dos seres vivos. Novos **indivíduos** com diferentes **características**, pertencentes a uma **população**, são criados através de **cruzamentos** e **mutações** onde apenas os mais aptos são **selecionados (seleção natural)** e passam suas **características** para uma nova geração. Com isso a **população** se torna mais apta a cada geração.
- **Otimização por enxame de partículas:** Inspirado no comportamento de cardumes de peixes e de bandos de pássaros. Resolve um problema de otimização ao ter uma **população** de soluções candidatas, denominadas **partículas**, e movê-las no **espaço de busca** sendo que existe cooperação entre as partículas.
 - Analogia: Imagine que você e vários amigos, todos com rádios, estão tentando localizar o ponto mais baixo de um terreno. Vocês começam a percorrer o terreno e a reportar via rádio a posição atual e a elevação do terreno, até que através de cooperação vocês encontram o ponto mais baixo.
- **Otimização da colônia de formigas:** É inspirado no comportamento das formigas ao saírem de sua colônia para encontrar comida. É uma técnica probabilística para resolver problemas computacionais que pode ser reduzida para encontrar bons caminhos através de grafos.
 - As formigas ao procurarem por alimento deixam feromônios para que outras formigas possam segui-las.

Tipos de Treinamento

Uma outra forma de se classificar algoritmos de ML é se eles podem ser treinados incrementalmente ou não. Assim, os algoritmos podem ser divididos em algoritmos com treinamento:

- **incremental (online).**
- **em batelada (batch).**


Treinamento incremental

- Algoritmo aprende incrementalmente: exemplos de treinamento são apresentados sequencialmente um-a-um ou em pequenos grupos chamados de mini-batches (ou mini-lotes).
- Cada iteração de treinamento é rápida possibilitando que o sistema aprenda sobre novos dados à medida que eles chegam.
- Ótima opção para casos onde os dados chegam como um fluxo contínuo ou se tem recursos computacionais limitados.
- Como não há pré-processamento/análise, dados corrompidos ou com problemas afetam a performance do sistema.

Treinamento em batelada

- Algoritmo é treinado com todos os exemplos disponíveis.
- O treinamento é demorado e utiliza muitos recursos computacionais (e.g., CPU, memória) quando comparado ao treinamento incremental.
- Para treinar com novos exemplos é necessário iniciar o treinamento do zero.
- Se a quantidade de dados do conjunto de treinamento for muito grande pode ser impossível treinar em batelada.
- Dados podem ser pré-processados/analizados, evitando assim, dados corrompidos ou com problemas.
- É um tipo de treinamento simples, de fácil implementação e obtém ótimos resultados.

Python, Jupyter & Colab



O que é Python?

- Linguagem de programação de alto nível, interpretada e multiparadigma.
- Foi lançada por Guido van Rossum em 1991.
- Possui um modelo de desenvolvimento comunitário, aberto e gerenciado pela *Python Software Foundation* (PSF).
- **Curiosidade:** o nome Python é uma homenagem ao grupo de humor britânico, Monty Python.




- Alto nível: longe do código de máquina e mais próximo à linguagem humana.
- Interpretada: programa é interpretado/executado por um interpretador e em seguida é executado pelo sistema-operacional/processador. Linguagens interpretadas têm seus códigos fontes transformados em uma linguagem intermediária (específica de cada linguagem), que será interpretada pela máquina virtual da linguagem quando o programa for executado.
- Script: que pode ser utilizada para automatizar pequenas tarefas, porém, python é muito poderosa e vai além da linguagem de script
- Python é tida como uma linguagem multiparadigma, um mesmo programa pode ser feito utilizando paradigmas diferentes ou um único programa pode ser criado utilizando mais de um paradigma de programação
 - Imperativa: comandos que dizem como o processador deve acessar e modificar dados armazenados em memória. O programador diz **como** e **o que** um programa deve realizar.
 - Orientada a objetos: sw baseado na composição e interação entre diversos 'objetos'.
 - Funcional: programação através de funções e métodos que são avaliados como se fossem funções matemáticas.
 - Procedural: baseado no conceito de chamadas a procedimentos. Os procedimentos, são também conhecidos como rotinas, subrotinas, métodos, ou funções
 - Reflexão é a capacidade de um programa observar ou até mesmo modificar sua estrutura ou comportamento.

Por que Python?

Algumas razões são:

1. É uma das linguagens mais fáceis de se aprender.
2. Python é muito popular e será mais ainda nos próximos anos.
3. Grandes empresas usam python.
4. Python é a linguagem mais usada em aplicações de ML.
5. Possui vasto suporte on-line: tutoriais, vídeos, StackOverflow, etc.
6. Python é usado como linguagem educativa para ensino de computação e eletrônica (e.g., Raspberry Pi, LEGO Mindstormstem suas aplicações desenvolvidas em Python).
7. Possui um rico ecossistema de bibliotecas: SciPy, NumPy, Pandas, Matplotlib, SciKit-Learn, TensorFlow, OpenCV, etc.
8. Teve uma rápida adoção pela comunidade científica.
9. Python é gratuito e open-source.



- 1 – Com uma taxa de crescimento constante, projeções mostram que Python será a linguagem mais utilizada em 2020, superando até o JavaScript.
- 2 – Google, Uber, Netflix, Facebook, Instagram dentre várias outras utilizam python.
- 3 – Por exemplo, TensorFlow, que é um framework para machine learning, utiliza principalmente python
- 4 – Milhares de tutoriais, vídeos, e temos o StackOverflow dando suporte para questões desde nível básico até níveis avançadíssimos, existe até uma versão de Minecraft que ensina como programar em python.
- 5 – Muitas plataformas que promovem o ensino de computação e eletrônica como Raspberry Pi e LEGO Mindstorms tem suas aplicações desenvolvidas em python.
- 6 – Você pode criar e distribuir sua própria biblioteca, modificar/melhorar bibliotecas já existentes e uma grande suporte da comunidade
- 7 – TensorFlow: Machine Learning, OpenCV: visão computacional (reconhecimento facial, de movimentos, etc.), Scrappy: Data Mining, Ipython: execução de códigos python no web browser.

Executando códigos Python na nuvem

- Para evitarmos a instalação de softwares, utilizaremos ambientes computacionais interativos baseados em **aplicações web** para criação de documentos virtuais, chamados de **notebooks**.
- Os **notebooks** são documentos usados para criar e compartilhar código interativo juntamente com equações, gráficos e texto.
- Dessa forma, um **notebook** permite uma maneira interativa de programar e documentar o código.
- Existem vários ambientes computacionais interativos gratuitos disponíveis, mas usaremos o **Jupyter** ou o **Google Colaboratory**.

Jupyter

- **Jupyter**: aplicação web gratuita que permite a criação e edição de **notebooks** em navegadores web.
- Suporta a execução de várias linguagens de programação: Python, C++, C#, PHP, Julia, R, etc.
- Site oficial: <https://jupyter.org/>
- Algumas desvantagens do **Jupyter** são:
 - Poucos servidores disponíveis.
 - Depois de algum tempo inativo, a máquina virtual executando seu **notebook** se desconecta e você pode perdê-lo.



Google Colaboratory (Colab)



- **Colab**: outra aplicação web gratuita, baseada no Jupyter, que permite a criação e edição de **notebooks** em navegadores web.
- É um produto da Google.
- Por hora, suporta apenas a execução de código em Python.
- Vantagens sobre o Jupyter:
 - Maior número de servidores.
 - Inicialização e processamento do código mais rápido.
 - Fornece GPUs e TPUs gratuitamente.
 - Compartilhamento de notebooks entre usuários é mais fácil.
- Site oficial: <https://colab.research.google.com/>

Instalando o Python, Jupyter e outras ferramentas

- Para resolver os exercícios do curso, vocês podem usar o **Jupyter** de forma online ou instalá-lo localmente.
- Eu recomendo que vocês o instalem localmente caso vocês precisem executá-lo sem uma conexão com a internet.
- O Python, o Jupyter e outras ferramentas e bibliotecas podem ser instaladas através da distribuição Anaconda seguindo-se o tutorial a seguir:
 - [Link para instalação do Anaconda.](#)
- **OBS.:** infelizmente, o Google Colab não pode ser instalado localmente.

Alguns Exemplos

Histograma

```
import numpy as np
import matplotlib.pyplot as plt


%matplotlib inline

data = np.random.randn(1000000)

# histograma (pdf)
plt.subplot(1, 2, 1)
plt.title('PDF')
plt.hist(data, bins=100, density=True, color='b')

# CDF empirica
plt.subplot(1, 2, 2)
plt.title('CDF')
plt.hist(data, bins=100, density=True, color='g', cumulative=True)

plt.savefig('histogram.png') # salva figura em arquivo
```



Exemplo:

https://mybinder.org/v2/gh/zz4fap/t319_aprendizado_de_maquina/main?filepath=notebooks%2Fjupyter%2FHistograma.ipynb


Figura 3D

```
import matplotlib.pyplot as plt
# facilita visualizacao de figuras 3D
from mpl_toolkits.mplot3d import axes3d # graficos 3D sao habilitados importando axes3d

# para figuras interativas usar "notebook" ao inves de "inline"
%matplotlib notebook

ax = plt.subplot(111, projection='3d')
X, Y, Z = axes3d.get_test_data(0.1)
ax.plot_wireframe(X, Y, Z)

# salva figura em arquivo
plt.savefig('figura3d.png')
```



[Exemplo: Figura_3D.ipynb](#)

Exemplo:

https://mybinder.org/v2/gh/zz4fap/t319_aprendizado_de_maquina/main?filepath=notebooks%2Fjupyter%2FFigura_3D.ipynb

Ajuste de curva com Redes Neurais

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.neural_network import MLPRegressor # importa classe MLPRegressor do modulo neural network

%matplotlib inline

x = np.arange(-10, 10, 0.1)

# dados originais
y = 12 + 3 * np.exp(-0.05*x) + 1.4 * np.sin(1.2*x) + 2.1 * np.sin(-2.2*x + 3)

# faz com que o gerador de numeros aleatorios sempre forneça os mesmos valores
np.random.seed(42)


# adicionando ruído aos dados originais
y_noise = y + np.random.normal(0, 0.5, size = len(y))

# trata o ajuste de curva como um problema de regressao e treina um modelo para se ajuste aos dados.
mlp = MLPRegressor(hidden_layer_sizes=(50,25,10), max_iter=10000, solver='lbfgs', alpha=0.9, activation='tanh')
yfit = mlp.fit(x[:, None], y_noise).predict(x[:, None])

plt.figure()
plt.plot(x, y_noise, 'o', label = 'dados original + ruído')
plt.plot(x, y, 'x', label = 'dados original')
plt.plot(x, yfit, '-r', label = 'curva ajustada com MLP', zorder = 10)
plt.legend()
plt.xlabel('X')
plt.ylabel('Y')

# salva figura em arquivo
plt.savefig('mlp_regression.png')
```

[Exemplo: Ajuste de curva com Redes Neurais.ipynb](#)



Exemplo:

https://mybinder.org/v2/gh/zz4fap/t319_aprendizado_de_maquina/main?filepath=notebooks%2FJupyter%2FAjuste_de_curva_com_Red_Neural.ipynb

Referências

- [1] Stuart Russell and Peter Norvig, "*Artificial Intelligence: A Modern Approach*," Prentice Hall Series in Artificial Intelligence, 3rd ed., 2015.
- [2] Aurélien Géron, "*Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*", 1st ed., O'Reilly Media, 2017.
- [3] Joseph Misiti, "*Awesome Machine-Learning*," on-line data base with several free and/or open-source books (<https://github.com/josephmisiti/awesome-machine-learning>).
- [4] Andriy Burkov, "*The Hundred-Page Machine-Learning Book*," Andriy Burkov 2019.
- [5] C. M. Bishop, "*Pattern Recognition and Machine Learning*," Springer, 1st ed., 2006.
- [6] S. Haykin, "*Neural Networks and Learning Machines*," Prentice Hall, 3ª ed., 2008.
- [7] Coleção pessoal de livros,
<https://drive.google.com/drive/folders/1lylMu1w6POBhrVnw11yqXXy6BjC439j?usp=sharing>

Avisos

- Entregas de exercícios devem ser feitas no MS Teams.
 - Se atentem às datas de entrega no MS Teams.
- Todo material do curso será disponibilizado no MS Teams e no GitHub:
 - https://github.com/zz4fap/t319_aprendizado_de_maquina
- Horário de Atendimento
 - Professor: Segundas-feiras das 18:30 às 19:30 e Quartas-feiras das 15:30 às 16:30 via MS Teams.
 - Monitora (Bruna): Todas as Sextas-feiras das 17:30 às 18:30.

Tarefas

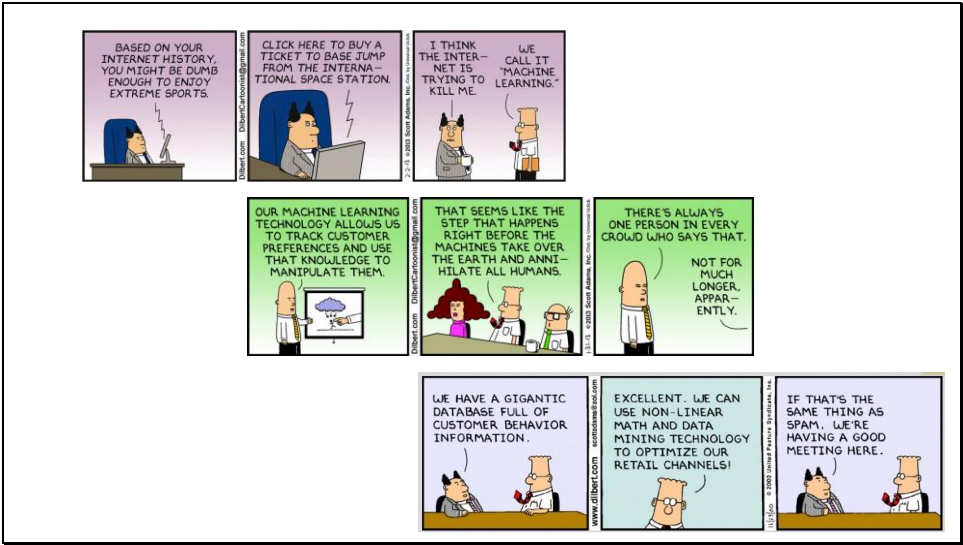
- **Quiz:** “T319 - Quiz - Introdução (1S2021)” que se encontra no MS Teams.
- **Exercício Prático:** [Laboratório #1](#).
 - Pode ser baixado do MS Teams ou do GitHub.
 - Pode ser respondido através do link acima (na nuvem) ou localmente.
 - [Instruções para resolução e entrega dos laboratórios](#).

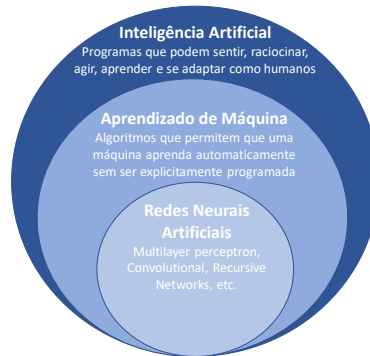
Laboratório #1:

https://mybinder.org/v2/gh/zz4fap/t319_aprendizado_de_maquina/main?filepath=labs%2FLaboratorio1.ipynb

Perguntas?

Obrigado!





Slide 51

