


Introdução



Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

A disciplina

- **Introdução** ao aprendizado de máquina.
- Curso onde veremos os **conceitos fundamentais** do funcionamento de alguns **algoritmos de aprendizado de máquina** ou em inglês, **machine learning** (ML).
- O curso é dividido em duas partes: T319 e T320.
- O curso terá sempre uma parte **expositiva** e outra **prática** para fixação dos conceitos introduzidos.
 - Quizzes e exercícios envolvendo o uso dos conceitos discutidos em sala de aula.
- Nós não nos aprofundaremos nos conceitos matemáticos envolvidos.
- Porém, vocês precisam conhecer o básico de **Python** e alguns conceitos simples de **cálculo, álgebra linear e estatística**.

Cronograma



- Aulas **quinzenais**, começando sempre às 19:30.

Aula	Data	Dia	Horário	Atividade
1	31/7/2026	Sexta-feira	19:30 às 21:10	Introdução ao Aprendizado de Máquina
2	14/8/2026			Introdução ao Aprendizado de Máquina
3	28/8/2026			Introdução ao Aprendizado de Máquina
4	11/9/2026			Introdução ao Aprendizado de Máquina
5	25/9/2026			Introdução ao Aprendizado de Máquina
6	9/10/2026			Introdução ao Aprendizado de Máquina
7	23/10/2026			Introdução ao Aprendizado de Máquina
8	6/11/2026			Avaliação Presencial (Sala ??)
9	20/11/2026*			Introdução ao Aprendizado de Máquina
10	4/12/2026			NP3

*Feriado (reposição assíncrona)

Objetivo do curso


- O objetivo principal do curso é apresentar
 - os ***conceitos fundamentais*** da teoria do aprendizado de máquina.
 - um ***conjunto de ferramentas*** (i.e., algoritmos, técnicas, métricas) de aprendizado de máquina para solução de diversos tipos de problemas.
- Ao final do curso vocês devem ser capazes de
 - Entender e discutir os principais algoritmos de ML.
 - Compreender a terminologia utilizada na área.
 - Compreender o funcionamento de novos algoritmos de ML.
 - Aplicar algoritmos de ML para a resolução de problemas.



Critérios de avaliação



- **Um (1) trabalho** em grupo com peso de 85%.
 - Envolvendo questões práticas e/ou teóricas.
 - Uma parte do trabalho será feita **presencialmente**.
- Atividades (**quizzes e laboratórios**) com peso de 15%.
 - Podem sempre ser entregues até o fim de semana da próxima aula.
 - As atividades podem ser resolvidas em grupo com no máximo 3 alunos.
 - As atividades serão atribuídas e entregues corrigidas através do MS Teams.
- Extra: 10% da nota da FETIN (**mas precisa envolver IA**).
- **Frequência**
 - Gerada automaticamente pelo MS Teams.
 - Por favor, acompanhem suas frequências através do portal.




Motivação



- **Emprego:** grandes empresas têm usado IA para
 - Automatizar tarefas repetitivas e demoradas.
 - Processar grandes volumes de dados para extração de *insights*.
 - Criar experiências personalizadas para seus clientes.
- Tudo isso para aumentar a eficiência dos processos, reduzir custos e, conseqüentemente, aumentar os lucros.
- Além das empresas de **tecnologia**, IA é empregada em empresas de **telecom**, **saúde**, **finanças**, **automação** e muitas outras.

Motivação



- **Salário**: como as empresas têm se apoiado mais e mais em IA para aumentar seus lucros, elas têm tido uma **demanda crescente por profissionais** com esse conhecimento.
- Os *salários são muito bons*, pois a *demanda é alta, mas não existem tantos profissionais* com essa experiência no mercado.

Motivação



NOKIA

Qualcomm

ZTE



- **Pesquisa:** IA já tem sido empregada no 5G e terá um papel fundamental no desenvolvimento da próxima geração de redes móveis e sem fio, o 6G.
- Os algoritmos de IA serão usados nas *mais diversas camadas* da rede para auxiliar em tarefas que vão desde a *estimação de canal, detecção de símbolos de uma modulação, alocação de recursos (e.g., feixes, potência, subportadoras) até segurança cibernética e chatbots para atendimento.*



*Mas o que é inteligência
artificial?*

O que é inteligência artificial?



- Campo da computação que almeja *criar máquinas que imitem as capacidades humanas*.
- Que capacidades são essas?
 - Aprendizado;
 - Adaptação;
 - Comunicação;
 - Raciocínio e tomada de decisão;
 - Resolução de problemas;
 - Criatividade;
 - Movimento;
 - etc.

O que é inteligência artificial?



- **Definição formal:**

Capacidade de uma máquina de *receber estímulos* vindos do ambiente, *interpretá-los*, *aprender* com eles e usar o *conhecimento adquirido* para *tomar decisões e resolver problemas*, *interagindo* com o ambiente.

- Porém, criar máquinas que **emulem todas** as nossas capacidades de uma única vez, **não é uma tarefa simples**.


O problema da inteligência artificial

IA é uma área muito ampla que engloba várias aplicações (subáreas) diferentes.



- Portanto, criar máquinas que imitem a inteligência humana é um **problema muito complexo e difícil de ser resolvido de uma só vez**.
- Sendo assim, **divide-se o problema em problemas menores**, chamadas de **subáreas da IA**.

Subáreas da inteligência artificial



- **Processamento de linguagem natural**
 - Compreensão e interpretação de linguagens humanas.
- **Representação do conhecimento**
 - Extração e armazenamento eficiente de conhecimento do mundo real.
- **Raciocínio automatizado**
 - Resolução de problemas complexos a partir de conhecimento prévio.
- **Planejamento**
 - Criação de planos que permitam que uma máquina execute uma tarefa.

Subáreas da inteligência artificial



- **Visão computacional**

- Compreensão e interpretação de imagens e vídeos.

- **Robótica**


- Criação de robôs capazes de realizar tarefas físicas e interagir com o ambiente.

- **Aprendizado de máquina**


- Criação de máquinas que aprendem através de experiências prévias.

- **Inteligência artificial geral (IAG)**

- Criação de máquinas que se comportem como seres humanos. É a meta final da IA.




Subáreas da inteligência artificial



- Como vimos, IA é um área muito ampla e não teríamos tempo para ver todas as subáreas.
- Além disso, ML é a base da IA moderna.
 - **Exemplos:** Redes convolucionais (imagens), *transformers* (ChatGPT), modelos de difusão (geração de dados sintéticos).
- Assim, focaremos no estudo dos fundamentos do ***aprendizado de máquina***.

Por quê ML?



- **Caixa de ferramentas:** ML oferece **ferramentas para a análise e solução de problemas** em várias áreas de forma eficiente.
- **Redução de complexidade e custo:** ML pode **reduzir o custo e a complexidade computacional** de métodos muitas vezes com desempenho ótimo na teoria, mas inviáveis na prática devido a sua alta complexidade e/ou custo.
- **Oportunidades:** existem muitos **empregos** na área de análise, ciência e engenharia de dados, além de **pesquisas inovadoras**, que usam ML para a solução de problemas em diversas áreas.

*OK, mas o que é o aprendizado
de máquina?*

O que é o aprendizado de máquina?

- É uma das subáreas da inteligência artificial.
 - O termo foi cunhado em 1959, pelo cientista da computação Arthur Samuel, que o definiu como o
- “Campo de estudo que dá aos computadores a habilidade de **aprender sem serem explicitamente programados.**”*



O que é o aprendizado de máquina?




- Mas como eles aprendem?
 - Através de ***experiências prévias***, ***induz-se*** conhecimento nas máquinas.
- Algoritmos de ML são ***orientados a dados***, i.e., eles ***aprendem*** (***através de treinamento***) uma ***solução geral*** a partir de ***conjuntos de dados*** fornecidos a eles.

Conjuntos de dados = experiências prévias


Paradigma da programação tradicional

- Para entendermos o que é o aprendizado de máquina, vamos fazer um ***paralelo com a programação tradicional***.
- Na programação tradicional, o **programador cria as regras** (i.e., programa) **que mapeiam as entradas, x , nas saídas, $y = f(x)$** .
- Imaginem um problema onde a **solução geral** é a equação de uma reta, **$f(x)$** .




O paradigma do aprendizado de máquina

- “... *aprender sem serem explicitamente programados*.”
- Esse trecho pode ser entendido se reorganizarmos a figura anterior.
- No ML, nós fornecemos as *entradas* e as *respostas esperadas* ao computador e deixamos que ele *aprenda*, através de *treinamento*, um *modelo* (i.e., as regras) que *mapeie* as entradas nas respostas esperadas.




Generalização

- Porém, não basta que o algoritmo de ML aprenda um modelo que faça um bom mapeamento **apenas para os dados do conjunto de treinamento**.
- O **algoritmo** de ML deve **treinar** um **modelo** que **aprenda** uma **solução geral**, ou seja, que **generalize para entradas não vistas durante o treinamento**.




Qual é a estimativa de paletas vendidas quando a temperatura é de ≈ 6 graus (valor não visto durante o treinamento)?



A partir do mapeamento aprendido (i.e., **reta**), o modelo gera como saída o valor 23, que é coerente com o restante dos dados.

Exemplos de aplicações de ML em várias áreas

- **Transporte:** veículos autônomos.
- **Negócios:** recomendação de produtos e conteúdos (e.g., amazon e netflix).
- **Educação:** pontuação automatizada de fala em testes de Inglês.
- **Saúde:** detecção e diagnóstico de doenças (câncer, Alzheimer, pneumonia, COVID-19, etc.).
- **Finanças:** detecção de fraudes com cartão de crédito.
- **Tecnologia:** assistentes pessoais (e.g., chatGPT, *Siri, Alexa, Cortana*, etc.).



Principais motivos da difusão do ML


- **Grandes volumes de dados** disponíveis: geramos centenas de *terabytes* por dia.
- Possibilidade de **extrair informações úteis do enorme volume de dados** disponível atualmente, algo que seria impossível para nós humanos.
 - Isso **vale ouro**, pois tem grande potencial para **aumentar o lucro das empresas**.
- Surgimento de **recursos computacionais poderosos** tais como GPUs, FPGAs e CPUs com múltiplos cores.
- Surgimento de **novas estratégias de aprendizagem**, e.g., *deep-learning*, *deep reinforcement-learning*, modelos generativos, *transformers* etc.
- Disponibilidade de **bibliotecas que facilitam o desenvolvimento** de soluções com ML.
 - Tensorflow, PyTorch, Scikit-learn, etc.



Paradigmas de aprendizado de máquina

Os algoritmos de aprendizado de máquina podem ser *agrupados* de acordo com o *tipo de aprendizado que realizam*:

- Supervisionado
- Não-Supervisionado
- Por Reforço
- Metaheurístico




Aprendizado supervisionado



$x = [x_1, x_2, x_3, \dots]$: data, remetente, assunto, etc.
 y : spam ou ham

- No aprendizado supervisionado, o **algoritmo de ML tem acesso às saídas esperadas**, y , chamadas de **rótulos** (ou *labels*, em inglês), **para o conjunto de valores de entrada**, chamados de **atributos**, x .
- Em outras palavras, cada **exemplo de treinamento** é composto pelos valores de entrada, x (**atributos**), e sua saída correspondente, y (**rótulo**).

Aprendizado supervisionado




$x = [x_1, x_2, x_3, \dots]$: data, remetente, assunto, etc.
 y : spam ou ham

- **Objetivo:** os algoritmos *supervisionados* de ML devem **aprender** uma **função** (i.e., o modelo) que **mapeie** as entradas x nas saídas esperadas, y , ou seja, $y = f(x)$.
- Esse tipo de aprendizado é dividido em **problemas** de **regressão** e **classificação**.
 - **Regressão:** o rótulo, y , pertence a um **conjunto infinito** de valores, i.e., números reais.
 - **Exemplo:** anos de experiência versus salário.
 - **Classificação:** o rótulo, y , pertence a um **conjunto finito e discreto** de valores, i.e., número de possíveis classes.
 - **Exemplos:** filtro de spam, classificação de imagens.


Aprendizado não-supervisionado

Dados não rotulados



Algoritmo de aprendizado não-supervisionado


Dados agrupados por proximidade




- Neste tipo de aprendizado, os algoritmos de ML **não têm acesso às saídas esperadas**, y .
- Os algoritmos só têm acesso aos **atributos**, x .
- **Objetivo:** os algoritmos devem **aprender/descobrir** padrões, muitas vezes ocultos, presentes nos dados se baseando apenas, por exemplo, na **similaridade** entre os **atributos**, x , ou seja, **sem a presença de rótulos**.

Aprendizado não-supervisionado

Clusterização




Detecção de Anomalias




- Esses algoritmos de ML tratam problemas de **clusterização**, **detecção de anomalias** (outliers), **redução de dimensionalidade**, e **aprendizado de regras de associação**.

Redução de dimensionalidade

Reduce data from 3D to 2D




Regras de associação



Of transactions that included milk:


- 71% included bread
- 43% included eggs
- 29% included toilet paper

Aprendizado por reforço



- Abordagem de aprendizado totalmente diferente das anteriores, pois ***não temos exemplos de treinamento***, sejam eles rotulados ou não.
- O algoritmo de aprendizado por reforço, chamado de ***agente*** nesse contexto, aprende como se comportar em um ***ambiente*** através de interações do tipo ***tentativa e erro***.
- O ***agente*** observa o ***estado*** do ***ambiente***, seleciona, executa uma ***ação*** e recebe um ***reforço positivo ou negativo*** em consequência da ***ação*** tomada.

Aprendizado por reforço




- Seguindo estes passos, o agente aprende por si só qual a melhor **estratégia**, chamada de **política**, para obter a **maior recompensa possível ao longo do tempo**.
- Uma **política** define qual **ação** o **agente** deve escolher quando o **ambiente** estiver em um determinado **estado**.
- Portanto, a **política** é uma **função que mapeia os estados do ambiente em ações** que o **agente** deve tomar para **maximizar as recompensas**.

Aprendizado metaheurístico


- **Metaheurísticas** são **estratégias gerais de otimização** usadas para encontrar boas soluções (muitas vezes próximas da ótima, i.e., **subótimas**) para **problemas complexos**, especialmente quando:
 - O espaço de busca é muito grande
 - O problema é NP-difícil
 - Problemas para os quais não existe algoritmo rápido que os resolva exatamente para todos os casos.
 - Não existe solução exata viável computacionalmente
 - O modelo matemático é não linear ou não diferenciável
- Elas não garantem a solução ótima, mas geralmente produzem **boas soluções em tempo razoável**.

Principais tipos de metaheurísticas


Algoritmo genético



Otimização por exame de partículas



Otimização por colônia de formigas



- Inspirados na natureza

- Otimização por colônia de formigas

- Baseada no comportamento de formigas encontrando caminhos mínimos.

- Otimização por exame de partículas

- Inspirada no movimento coletivo de pássaros ou peixes.

- Algoritmo genéticos

- Baseado em evolução natural dos seres vivos.

- Baseadas em busca local

- Tabu Search

- Mantém memória para evitar revisitar soluções.

Características das metaheurísticas

- São **genéricas** (podem ser aplicadas a vários problemas).
 - Não foram projetadas para um único problema específico.
- Trabalham com **busca estocástica**.
 - Exploram o espaço de soluções probabilisticamente.
- Não exigem o cálculo de derivadas como regressores, redes neurais, etc.
- Funcionam bem mesmo em dispositivos com ***capacidade computacional limitada*** (e.g., dispositivos IoT).
- Equilibram exploração vs. exploração.
 - Explora soluções em novas regiões do espaço de soluções ao mesmo tempo em que se refina as melhores soluções já encontradas.

Executando códigos




- Durante o curso, usaremos ***Python***.
 - Pois é a linguagem mais utilizada em ML além de ser gratuita e *open-source*.
- Utilizaremos ***notebooks Jupyter*** para execução de exemplos e resolução dos laboratórios.
 - Eles são ***documentos virtuais*** usados para desenvolver e documentar código.
 - Pode-se adicionar equações, gráficos e texto.
- Para executá-los, usaremos o ***Google Colab***.

Google Colaboratory (Colab)



- **Colab** é uma aplicação web gratuita que permite a *criação, edição e execução* de *notebooks Jupyter* em navegadores web.
- É um produto da Google.
- Vantagens:
 - Grande número de servidores.
 - Fornece acesso a GPUs e TPUs gratuitamente.
 - Notebooks podem ser salvos no Google Drive, evitando a perda de códigos.
- URL: <https://colab.research.google.com/>
- **Vocês não precisam instalar nada**, apenas terem conexão com a internet.


Objetivo do curso



↓ x e y


Machine
Learning

↓ $\hat{y} = a_0 + a_1x$



- O **objetivo** desta primeira parte do curso é ensinar a vocês **como encontrar uma função** (i.e., **um modelo**), **usando ML**, que **aproxime** (i.e., **aprenda**) o comportamento geral por trás de um **conjunto de amostras** (x e y) da **melhor forma possível**.
 - Queremos um bom mapeamento tanto para amostras conhecidas quanto para inéditas.


Objetivo do curso



↓ x e y

Machine Learning

↓ $\hat{y} = a_0 + a_1x$



- Mas o que você quer dizer com “*melhor forma possível*”?
 - No sentido da otimização de uma dada métrica.
- Na maioria dos casos, o *mapeamento verdadeiro* entre x e y *não é conhecido ou nem mesmo existe* e nós nos baseamos apenas em uma *métrica* para definir se a função de mapeamento aprendida (i.e., o *modelo*) é boa ou não.
 - **Exemplo:** dada a previsão da temperatura média para um dia qualquer, quantos picolés serão vendidos?
 - Não existe uma função na natureza que mapeie temperatura em picolés.

Referências

- [1] Stuart Russell e Peter Norvig, “*Artificial Intelligence: A Modern Approach*,” Prentice Hall Series in Artificial Intelligence, 3rd ed., 2015.
- [2] Aurélien Géron, “*Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*”, 1st ed., O'Reilly Media, 2017.
- [3] Levy Boccato, “Notas de aula do curso Tópicos em Sistemas Inteligentes II - Aprendizado de Máquina” (IA006), disponíveis em https://www.dca.fee.unicamp.br/~lboccato/ia006_2s2019.html (2019).
- [4] Joseph Misiti, “*Awesome Machine-Learning*,” on-line data base with several free and/or open-source books (<https://github.com/josephmisiti/awesome-machine-learning>).
- [5] C. M. Bishop, “*Pattern Recognition and Machine Learning*,” Springer, 1st ed., 2006.
- [6] Coleção de livros, <https://tinyurl.com/mp64ksye>

Avisos

- Toda a nossa comunicação será feita via Teams.
- Todas as aulas serão gravadas e os vídeos ficarão disponíveis na pasta "Recordings" dentro de "Arquivos".
- Todo material do curso está disponível no GitHub:
 - https://github.com/zz4fap/t319_aprendizado_de_maquina
- As entregas das atividades (laboratórios e quizzes) devem ser feitas através do Teams.
 - Se atentem às datas e horários de entrega das atividades no Teams.


Avisos

- Vídeos do minicurso curso de Python e de como usar o Colab estão na pasta “*Recordings*” dentro de “Arquivos”.
- Horários de atendimento
 - Professor: terças-feiras das 10:00 às 11:00 e das 17:30 às 18:30.
 - Monitor (João Gabriel: joao.g@get.inatel.br): todas as segundas-feiras das 17:30 às 19:30.
 - **Atendimento remoto via Teams.**


Tarefas

- **Quiz:** “*T319 - Quiz - Introdução*” que se encontra no MS Teams.
- **Exercício Prático:** Laboratório #1.
 - Pode ser acessado através do link acima (Google Colab) ou no GitHub.
 - **Vídeo explicando o laboratório #1: Arquivos -> Recordings -> Laboratório #1.**
 - Se atentem aos prazos de entrega.
 - [Instruções para resolução e entrega dos laboratórios.](#)



Obrigado!



Dilbert.com DilbertCartoonist@gmail.com




2-2-13 ©2013 Scott Adams, Inc./Dist. by Universal Uclick



Dilbert.com DilbertCartoonist@gmail.com



1-31-13 ©2013 Scott Adams, Inc./Dist. by Universal Uclick





www.dilbert.com scottadams@aol.com



©2003 United Feature Syndicate, Inc.









State


Action

Q-Table

State/Action	Value
-/-	0
-/-	0
-/-	0
-/-	0
-/-	0
-/-	0

Q-Value


Agente



Ações


Recompensas

Estados




Ambiente

Agente



Ambiente



Ações



Recompensas



Estados

