

T319 - Introdução ao Aprendizado de Máquina: *Introdução*



Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

A disciplina



- **Introdução** ao aprendizado de máquina.
- Curso introdutório onde veremos os **conceitos básicos** de funcionamento de alguns **algoritmos de aprendizado de máquina** ou do Inglês, **machine learning** (ML).
- O curso será dividido em duas partes: T319 e T320.
- O curso terá sempre uma parte **expositiva** e outra **prática** para fixação dos conceitos introduzidos.
 - Quizzes e exercícios envolvendo o uso dos algoritmos discutidos.
- Não nós aprofundaremos nos conceitos matemáticos envolvidos.
- Porém, precisamos conhecer Python e alguns conceitos de cálculo, álgebra linear e estatística.

Cronograma

Aula	Data	Dia	Horário	Atividade
1	18/02/2022	Sexta-feira	21:30 às 23:10	Introdução ao Aprendizado de Máquina
2	4/3/2022			Introdução ao Aprendizado de Máquina
3	18/3/2022			Introdução ao Aprendizado de Máquina
4	1/4/2022			Introdução ao Aprendizado de Máquina
5	15/4/2022			Introdução ao Aprendizado de Máquina
6	29/4/2022			Introdução ao Aprendizado de Máquina
7	13/5/2022			Introdução ao Aprendizado de Máquina
8	27/5/2022			Introdução ao Aprendizado de Máquina
9	10/6/2022			Introdução ao Aprendizado de Máquina
10	24/6/2022			Projeto Final


Objetivo do curso

- O objetivo principal do curso é apresentar
 - os conceitos fundamentais da teoria do aprendizado de máquina.
 - um conjunto de ferramentas (ou seja, algoritmos) de aprendizado de máquina para solução de problemas.
- Ao final do curso vocês devem ser capazes de
 - Entender e discutir sobre os principais algoritmos de ML.
 - Compreender a terminologia utilizada na área.
 - Aplicar algoritmos de ML para a resolução de problemas.
 - Analisar e entender novos algoritmos de ML.
 - Criar seus próprios projetos.



Critérios de avaliação

- 1 trabalho com peso de 85%.
 - Envolvendo questões teóricas e/ou práticas.
- Atividades (quizzes e laboratórios) com peso de 15%.
 - Podem sempre ser entregues até a próxima aula.
 - Podem ser resolvidos em grupo, mas entregas devem ser individuais.
 - Exercícios serão atribuídos através de tarefas do MS Teams.
- **Frequência**
 - Gerada automaticamente pelo MS Teams.
 - Por favor, acompanhem suas presenças no portal.



Motivação

- **Emprego:** grandes companhias usam ML em seus produtos e/ou soluções internas para resolver os mais diversos tipos de problemas e assim aumentarem sua eficiência e consequentemente os lucros.



- **Pesquisa:** já se prevê que ML terá um papel importante no desenvolvimento da próxima geração de redes móveis e sem-fio (e.g., 6G).



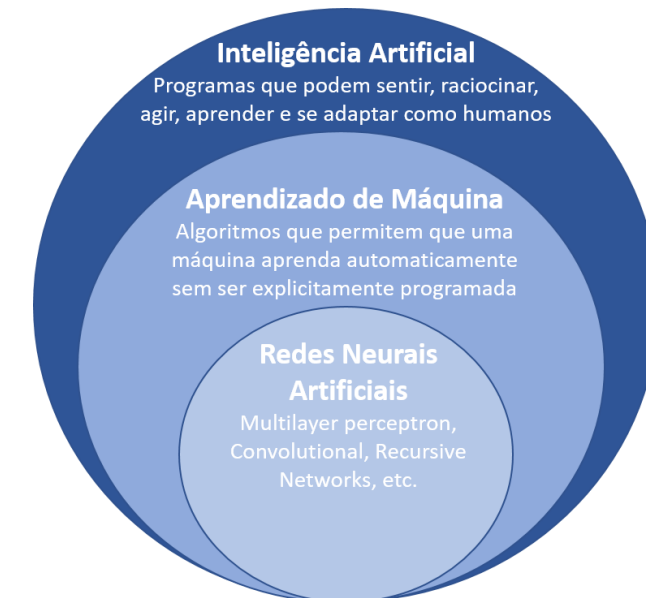

Definição e objetivo da Inteligência Artificial

- **Definição:** *“Capacidade de um sistema de interpretar corretamente dados externos (estímulos vindos do ambiente), aprender com esses dados e usá-los para atingir tarefas e objetivos específicos por meio de adaptação flexível.” (Andreas Kaplan).*
- **Objetivo:** Criar máquinas que **imitem** nossas **habilidades mentais**, ou seja, criar máquinas que são **modelos aproximados** de nossas habilidades de enxergar, falar, ouvir, sentir, aprender, raciocinar, resolver problemas, etc.
- IA utiliza a **experiência** para adquirir **conhecimento** e também como aplicar esse **conhecimento** a problemas desconhecidos.


Inteligência Artificial

- IA é uma área muito ampla que **engloba** várias aplicações (ou sub-áreas) tais como

- Processamento de linguagem natural.
 - ✓ Geração e compreensão automática de línguas humanas naturais.
- Representação do conhecimento.
 - ✓ Criação e armazenamento de conhecimento do mundo real.
- Raciocínio automatizado.
 - ✓ Resolução de problemas complexos a partir de conhecimento adquirido.
- Planejamento.
 - ✓ Criação de planos que permitam que uma máquina execute uma tarefa.
- Visão computacional.
 - ✓ Extração de informações de imagens e vídeos.
- Robótica.
 - ✓ Projeto, construção e operação de robôs que repliquem ações humanas.
- Aprendizado de máquina.
 - ✓ Criação de máquinas que aprendem através de exemplos.
- Inteligência artificial geral.
 - ✓ Criação de máquinas que solucionem qualquer tipo de problema. É a meta final da IA.



Foco do curso



Natural Language
Processing



Knowledge
Representation



Automated
Reasoning



Machine
Learning

- Como vimos, IA é um termo muito amplo, abrangendo várias sub-áreas, usado para designar máquinas capazes executar ***tarefas*** de forma inteligente.
- **Foco do curso:** estudo dos principais algoritmos de ***Aprendizado de Máquina***.
- **Por quê?**
 - ***Caixa de ferramentas:*** ML oferece ferramentas importantes para a análise e solução eficiente de vários problemas em várias áreas.
 - ***Redução de complexidade e custo:*** vários procedimentos e processos em várias áreas que apresentam desempenho ótimo na teoria não são utilizados na prática, pois possuem complexidade computacional e/ou custo proibitivos.
 - ***Oportunidades:*** existem muitos empregos na área de análise, ciência e engenharia de dados, além de pesquisas inovadoras para a solução de problemas com ML.

Mas então, o que é ML?




- É uma sub-área da inteligência artificial.
- O termo foi cunhado em 1959, pelo cientista da computação Arthur Samuel, que o definiu como o “*campo de estudo que dá aos computadores a habilidade de **aprender sem serem explicitamente programados***”.
- Uma outra definição interessante feita por Jojo John Moolayil é “*Aprendizado de máquina é o processo de **induzir** inteligência em uma máquina sem que ela seja explicitamente programada*”.
 - **Indução**: aprender um modelo ou padrão geral *a partir de exemplos corretos e incorretos*.
- Portanto, podemos dizer que algoritmos de ML são **orientados a dados**, ou seja, eles aprendem automaticamente um **padrão geral** a partir de **grandes volumes de dados**.


O que é o Aprendizado de Máquina?

- “... *aprender sem serem explicitamente programados.*”

Programação Tradicional



Aprendizado de Máquina



Exemplos de aplicações de ML

- **Transporte:** veículos autônomos, predição do tráfego, etc.
- **Negócios:** recomendação de produtos e conteúdos (e.g., amazon e netflix), chatbots para atendimento ao cliente, etc.
- **Educação:** pontuação automatizada de fala em testes de Inglês, correção de provas, etc.
- **Clima:** previsão do tempo (temperatura, chuva, furacões, etc.).
- **Medicina:** detecção e/ou predição de doenças (câncer, Alzheimer, pneumonia, COVID-19, etc.), descoberta de novas drogas, etc.
- **Finanças:** detecção de fraudes com cartão de crédito, etc.
- **Tecnologia:** filtros anti-spam, assistentes pessoais (e.g., *Siri*, *Alexa*, etc.), tradutores em tempo-real.



Por que ML se tornou tão difundido?

Alguns dos principais motivos são:

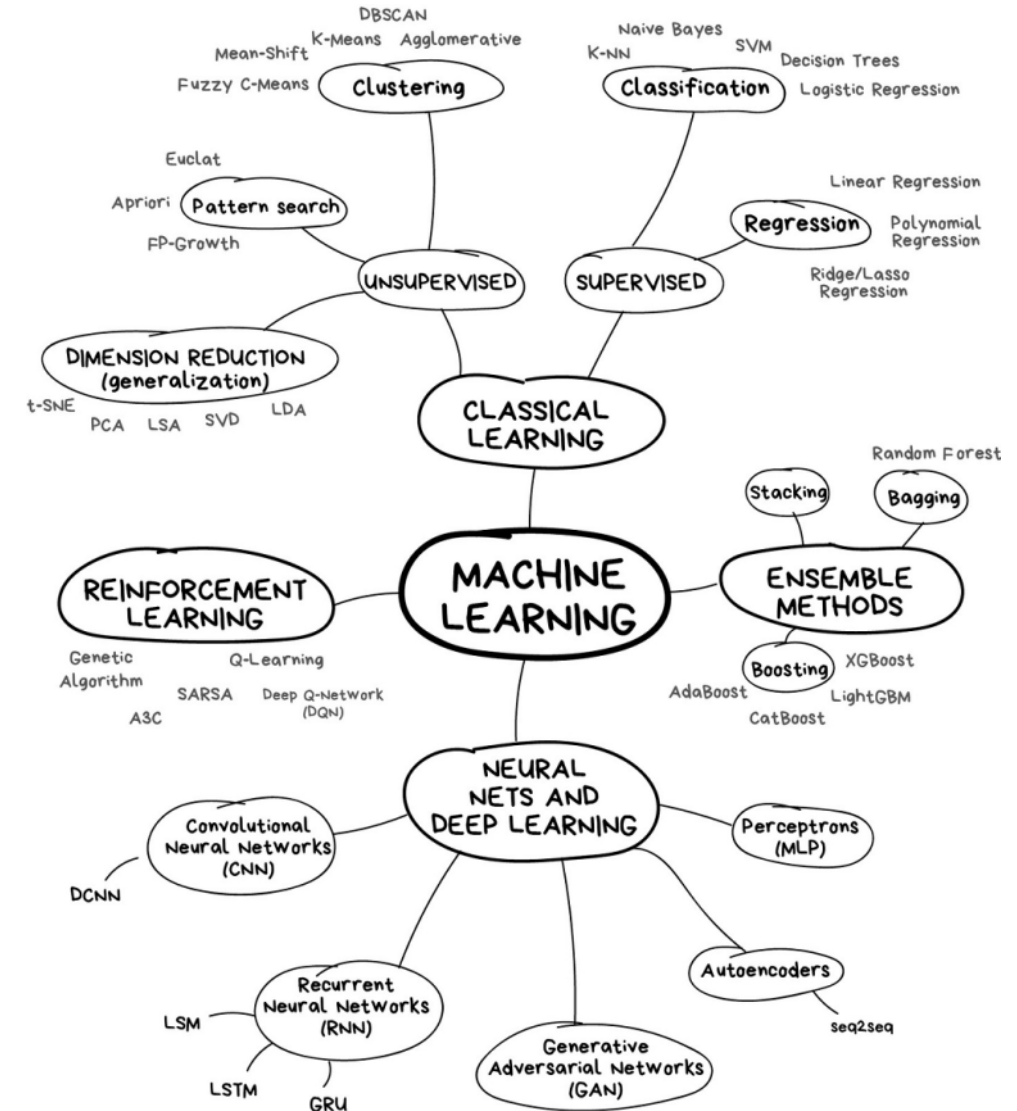
- Vivemos na era da informação e, portanto, um volume sem precedentes de dados (de tera a petabytes) está disponível, impossibilitando sua análise por nós seres humanos.
- Porém, para modelos de ML isso não é um problema e sim uma solução, pois quanto mais dados melhor será o aprendizado.
- Além disso, a extração de informações úteis a partir dos dados gerados por empresas vale ouro, pois têm grande potencial para aumentar seus lucros.
- O surgimento de recursos computacionais poderosos tais como GPUs, FPGAs e CPUs com múltiplos cores.
- Surgimento de novas e eficientes estratégias de aprendizagem, e.g., *deep-learning*, *deep reinforcement-learning*, etc.
- Existência de frameworks e bibliotecas poderosas que facilitam o desenvolvimento de soluções com ML.



Tipos de Aprendizado de Máquina


Dependendo do tipo de aprendizado realizado pelos algoritmos, eles podem ser agrupados da seguinte forma:

- Supervisionado
- Não-Supervisionado
- Semi-Supervisionado
- Por Reforço
- Metaheurístico




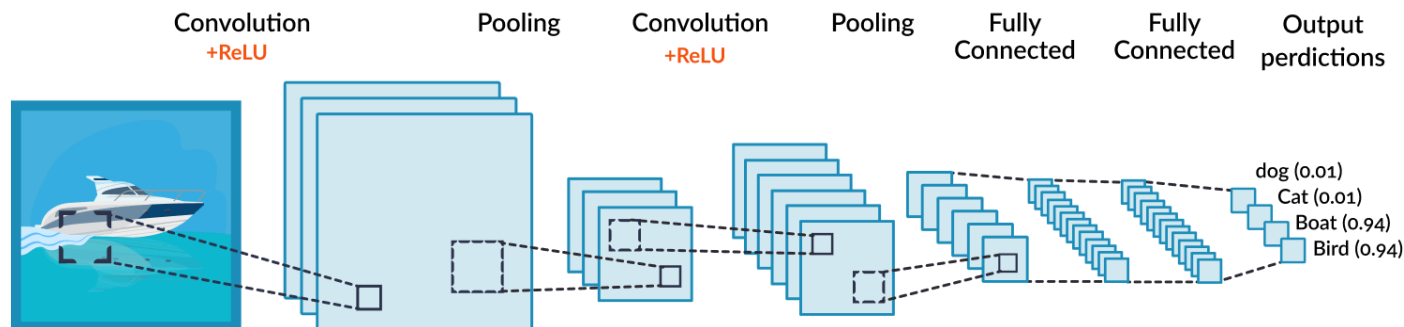
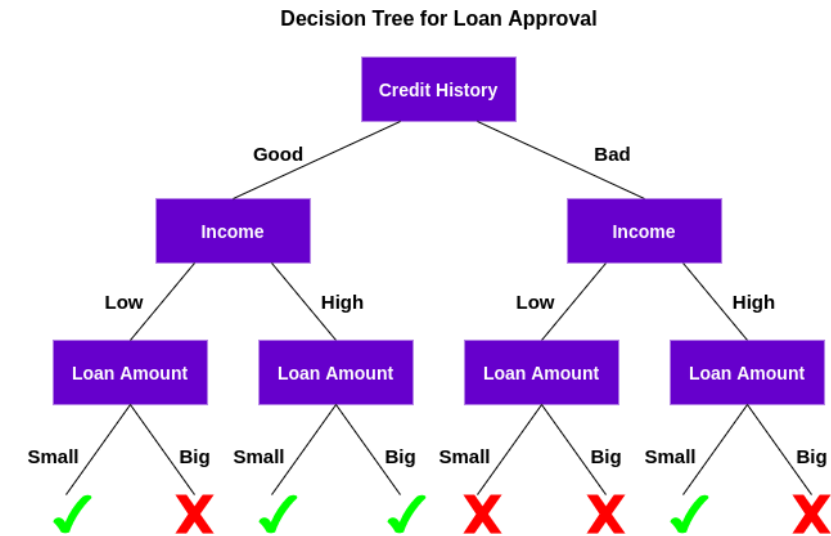
Aprendizado Supervisionado

- No aprendizado supervisionado a máquina sabe o que aprender, ou seja, ela tem acesso às respostas esperadas.
- Neste tipo de aprendizado, os dados ou exemplos de treinamento incluem os **atributos**, x , que são a entrada do algoritmo de ML e as **respostas esperadas**, y , para cada entrada, chamadas de **rótulos** (ou *labels*, do Inglês).
- **Objetivo:** os modelos supervisionados de ML devem **aprender** uma função que mapeie as entradas x nas saídas y , ou seja, $y = f(x)$.
- Esse tipo de aprendizado é dividido em problemas de **Regressão** e **Classificação**.
 - **Regressão:** o rótulo, y , pertence a um **conjunto infinito** de valores, i.e., números reais.
 - **Classificação:** o rótulo, y , pertence a um **conjunto finito** de valores, i.e., conjunto finito de classes.



Principais Algoritmos para Aprendizado Supervisionado


- Regressão linear.
- Regressão logística.
- Árvores de Decisão (*Decision Trees*).
- Florestas Aleatórias (*Random Forests*).
- k vizinhos mais próximos (*k-nearest neighbors* - k-NN).
- Máquinas de Vetores de Suporte (*Support Vector Machines* - SVMs).
- Redes Neurais Artificiais.



Aprendizado Não-Supervisionado


- Neste tipo de aprendizado, as máquinas não são informadas sobre o que aprender. Elas só recebem os exemplos de treinamento, x .
- Neste caso, os algoritmos ***aprendem/descobrem padrões*** (muitas vezes ocultos) presentes nos dados de entrada sem a presença de rótulos.
- **Objetivo:** os modelos devem ***aprender/descobrir*** padrões desconhecidos se baseando apenas nos exemplos de entrada.
- Trata problemas de clusterização, redução de dimensionalidade, detecção de anomalias (*outliers*) e aprendizado de regras de associação.

Clusterização




Redução de dimensionalidade


Reduce data from 3D to 2D



Detecção de Anomalias



Regras de associação






Of transactions that included milk:

- 71% included bread
- 43% included eggs
- 29% included toilet paper

Principais Algoritmos para Aprendizado Não-Supervisionado

- k-médias (*k-means*).
 - Particiona os exemplos em k clusters (ou grupos) distintos com base em sua distância até os centroides dos clusters.
- Redes Neurais Artificiais, e.g., auto-encoders.
 - Os autoencoders são usados para redução ou aumento de dimensionalidade.
- Análise de Componentes Principais (*Principal Component Analysis* - PCA).
 - Redução de dimensionalidade.



Aprendizado Semi-Supervisionado

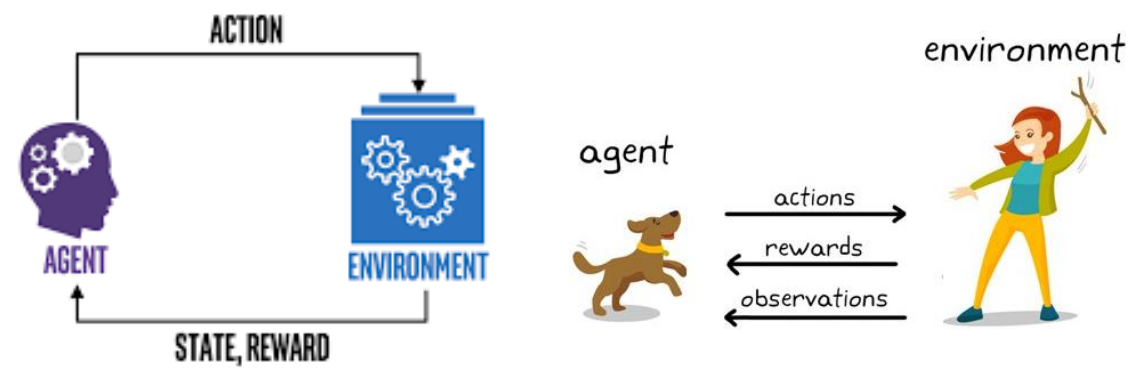
- Neste tipo de aprendizado, as máquinas têm acesso a exemplos com e sem rótulos.
- Geralmente envolve uma ***pequena quantidade de dados*** rotulados e uma ***grande quantidade de dados não-rotulados***.
- É de grande ajuda em casos onde se ter uma grande quantidade de dados rotulados é muito demorado, caro ou complexo.
- Algoritmos de aprendizagem semi-supervisionada são o resultado da combinação de algoritmos supervisionados e não-supervisionados.
- Uma maneira de realizar aprendizado semi-supervisionado é combinar, por exemplo, algoritmos de ***clustering*** e ***classificação***.

Aprendizado Semi-Supervisionado

- **Exemplo:** Como **classificaríamos** milhões de textos **não-rotulados** da internet em categorias como economia, esportes, política, entretenimento, etc.?
- Poderíamos usar **clustering** para agrupar a quantidade massiva de textos e usar apenas os exemplos mais representativos de cada **cluster** (quantidade bem menor de textos) para **rotular manualmente**.
- Esses **exemplos rotulados** são usados para treinar um **classificador**.
- Após o treinamento, o **classificador** classifica automaticamente todos os textos.



Aprendizado Por Reforço



- Abordagem totalmente diferente das anteriores pois ***não temos exemplos de treinamento***, sejam eles rotulados ou não.
- O algoritmo de aprendizado por reforço, chamado de ***agente*** nesse contexto, aprende como se comportar em um ***ambiente*** através de interações do tipo ***tentativa e erro***.
- O ***agente*** observa o ***estado*** do ***ambiente*** em que está inserido, seleciona e executa ***ações*** e recebe uma ***recompensa*** (ou ***reforço***) em consequência das ***ações*** tomadas.
- Seguindo estes passos, o agente deve aprender por si só qual a melhor ***estratégia***, chamada de ***política***, para obter a maior recompensa possível ao longo do tempo.
- Uma ***política*** define qual ***ação*** o ***agente*** deve escolher quando estiver em uma determinada situação, ou seja, em um ***estado*** do ***ambiente***.
- Portanto, a ***política*** é uma ***função*** que mapeia os ***estados*** do ***ambiente*** em ***ações*** que o ***agente*** deve tomar.


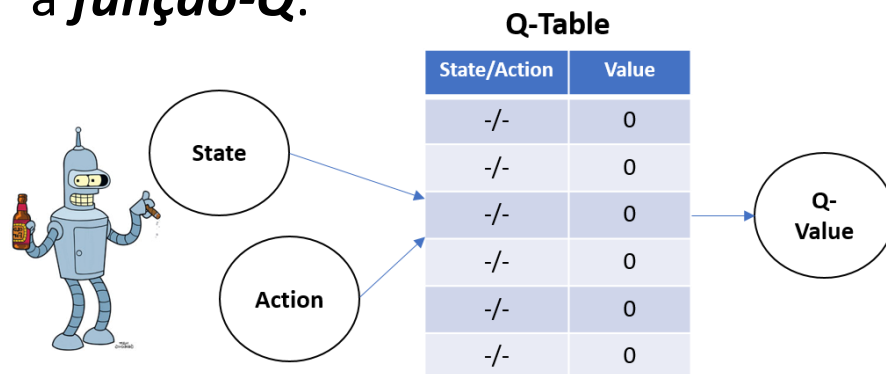
Principais Algoritmos de Aprendizado Por Reforço

- **Q-Learning**

- Usado para encontrar uma **política** ótima de seleção de **ações** usando a **função-Q**.
- **Q**, ou **valor-Q**, representa a **qualidade** de uma dada **ação** em um determinado **estado**.
- É impraticável se encontrar uma **política** quando número de **estados** e **ações** é grande.

- **Deep Q-Learning**

- Junção de Deep Learning + Q-Learning.
- Redes neurais profundas possibilitam que Q-Learning seja aplicado a problemas com número gigantesco de **estados** e **ações**.
- O Q-Learning tabela a **função-Q**, já o Deep Q-Learning encontra uma **função** que aproxime a **função-Q**.



Aprendizado Metaheurístico

- Uma **metaheurística** é um método **heurístico** usado para resolver de forma **genérica** problemas de otimização.
 - **Heurística** é um método ou processo criado com o objetivo de encontrar soluções, de **forma rápida**, mas muitas vezes **sub-ótimas**, para problemas complexos.
- **Metaheurísticas** são geralmente aplicadas a problemas para os quais não se conhece um algoritmo eficiente ou não se tem uma solução conhecida.
- Características das metaheurísticas:
 - não garantem que uma solução globalmente ótima seja encontrada, mas podem encontrar uma solução suficientemente boa (sub-ótima).
 - são estratégias que orientam o processo de busca através do espaço de soluções.
 - não são específicas do problema, ou seja, são genéricas.
 - funcionam bem mesmo com capacidade de computação limitada.

Principais Algoritmos de Aprendizado Metaheurístico

- Algoritmo Genético (*Genetic Algorithm* - GA).
 - Inspirados pelo processo de seleção natural.
- Otimização por enxame de partículas (*Particle Swarm Optimization* - PSO).
 - Inspirado no comportamento de cardumes de peixes e de bandos de pássaros
- Otimização da colônia de formigas (*Ant Colony Optimization* - ACO).
 - Inspirado no comportamento das formigas ao saírem de sua colônia para encontrar comida.






Figure 2. A. Ants in a pheromone trail between nest and food; B. an obstacle interrupts the trail; C. ants find two paths to go around the obstacle; D. a new pheromone trail is formed along the shorter path.

Tipos de Treinamento

Uma outra forma de se classificar algoritmos de ML é com relação se eles podem ser treinados incrementalmente ou não. Assim, os algoritmos podem ser divididos em algoritmos com treinamento:

- **incremental (online).**
- **em batelada (batch).**

Treinamento incremental


- Neste tipo de treinamento, o algoritmo ***aprende incrementalmente***:
 - Os exemplos de treinamento são apresentados ***sequencialmente um-a-um*** ou em ***pequenos grupos*** chamados de ***mini-batches***.
- Cada ***iteração de treinamento é rápida*** possibilitando que o sistema aprenda sobre novos dados à medida que eles chegam.
- Ótima opção para casos onde os dados chegam como um ***fluxo contínuo*** ou se tem ***recursos computacionais limitados***.
- Entretanto, como na maioria dos casos não é possível se realizar pré-processamento/análise dos dados, dados corrompidos ou com problemas afetam a performance do sistema.

Treinamento em batelada

- Neste tipo de treinamento, o algoritmo é ***treinado com todos os exemplos disponíveis***.
- É um tipo de treinamento simples, de fácil implementação e obtém ótimos resultados.
- Dados podem ser pré-processados/analísados, evitando assim, dados corrompidos ou com problemas.
- O treinamento é mais demorado e utiliza mais recursos computacionais (CPU e memória) quando comparado ao treinamento incremental.
- Para treinar com novos exemplos é necessário iniciar o treinamento do zero.
- Se a quantidade de dados do conjunto de treinamento for muito grande pode ser impossível treinar em batelada.

Executando os códigos

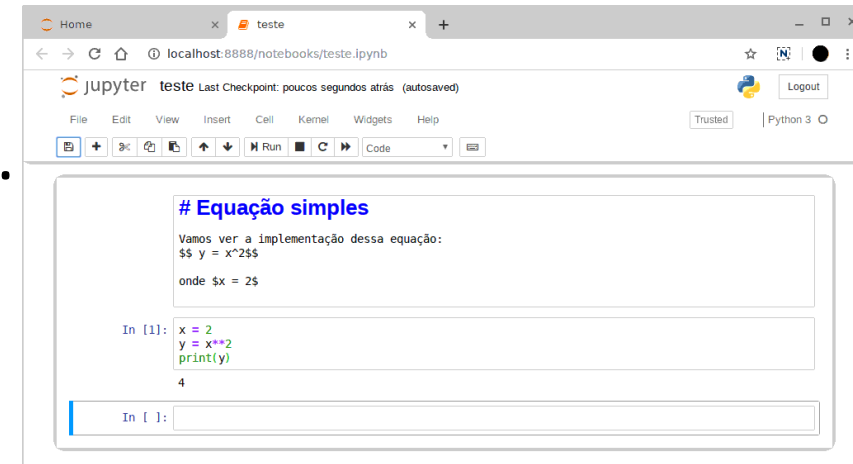
- Durante o curso, usaremos **Python** como linguagem de programação.
- Utilizaremos **notebooks Jupyter** para execução de exemplos e resolução dos exercícios práticos.
 - Eles são **documentos virtuais** usados para criar e documentar código.
 - Pode-se adicionar equações, gráficos e texto, além de código.
- Para executá-los, utilizaremos o **Google Colaboratory** ou o **Binder**, que são ambientes computacionais (i.e., servidores) interativos e gratuitos.
- Portanto, **vocês não precisam instalar nada**, apenas terem um navegador web e conexão com a internet.



Binder



- **Binder**: aplicação web gratuita que permite a criação e edição de *notebooks Jupyter* em navegadores web.
- Suporta a execução de várias linguagens de programação: Python, C++, C#, PHP, Julia, R, etc.
- Algumas desvantagens do **Jupyter** são:
 - Poucos servidores disponíveis.
 - Não é possível salvar os notebooks (e.g., Google Drive).
 - Depois de algum tempo inativo, a máquina virtual executando seu *notebook* se desconecta e você pode perder seu código.
- URL (através do Jupyter): <https://jupyter.org/>



Google Colaboratory (Colab)



- **Colab**: outra aplicação web gratuita que permite a criação e edição de *notebooks Jupyter* em navegadores web.
- É um produto da Google.
- Por hora, suporta apenas a execução de códigos escritos em Python.
- Vantagens sobre o Jupyter:
 - Maior número de servidores.
 - Inicialização e processamento do código mais rápidos do que com o Binder.
 - Fornece acesso a GPUs e TPUs gratuitamente.
 - Notebooks podem ser salvos no seu Google Drive, evitando que você perca seu código.
- URL: <https://colab.research.google.com/>

Exemplo de uso dos notebooks com Colab



colab

Figura 2D

```
# Importando as bibliotecas necessárias.
import numpy as np
import matplotlib.pyplot as plt

# Reseta o gerador de sequências pseudo-aleatórias.
np.random.seed(42)

# Define o número de exemplos.
N = 1000

# Vetor coluna com dimensão Nx1, com valores linearmente espaçados entre -1 e 1.
x = np.linspace(-1, 1, N).reshape(N,1)


# Vetor ruído com dimensão Nx1 e variância igual a 0.1.
w = np.sqrt(0.1)*np.random.randn(N,1)

# Função original.
y = -1 + 2*x**2

# Versão ruidosa de y.
y_noisy = y + w

plt.plot(x, y_noisy, '.b', label='Função ruidosa')
plt.plot(x, y, 'k', label='Função original', linewidth=4)
plt.xlabel('x', fontsize=14)
plt.ylabel('y', fontsize=14)
plt.legend()
plt.grid()
# salva figura em arquivo
plt.savefig('figura_2D.png')
# Mostra a figura.
plt.show()
```

[Exemplo \(colab\): Figura_2D.ipynb](#)



[Exemplo \(binder\): Figura_2D.ipynb](#)

Referências

- [1] Stuart Russell and Peter Norvig, *“Artificial Intelligence: A Modern Approach,”* Prentice Hall Series in Artificial Intelligence, 3rd ed., 2015.
- [2] Aurélien Géron, *“Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems”*, 1st ed., O'Reilly Media, 2017.
- [3] Joseph Misiti, *“Awesome Machine-Learning,”* on-line data base with several free and/or open-source books (<https://github.com/josephmisiti/awesome-machine-learning>).
- [4] Andriy Burkov, *“The Hundred-Page Machine-Learning Book,”* Andriy Burkov 2019.
- [5] C. M. Bishop, *“Pattern Recognition and Machine Learning,”* Springer, 1st ed., 2006.
- [6] S. Haykin, *“Neural Networks and Learning Machines,”* Prentice Hall, 3ª ed., 2008.
- [7] Coleção de livros,
<https://drive.google.com/drive/folders/1lylIMu1w6POBhrVnw11yqXXy6BjC439j?usp=sharing>


Avisos

- Entregas de exercícios (laboratórios e quizzes) devem ser feitas através do MS Teams.
 - Se atentem às datas/horários de entrega no MS Teams.
- Todo material do curso será disponibilizado no MS Teams e no GitHub:
 - <https://github.com/zz4fap/t319> *aprendizado de maquina*
- Horários de Atendimento
 - Professor: quintas-feiras das 18:30 às 19:30 e sextas-feiras das 15:30 às 16:30.
 - Monitor (Pedro Rezende: ***pedro_rafael@get.inatel.br***): Todas as sextas-feiras das 17:30 às 18:30.
 - Atendimento via MS Teams.


Tarefas

- **Quiz:** “*T319 - Quiz - Introdução*” que se encontra no MS Teams.
- **Exercício Prático:** [Laboratório #1](#).
 - Pode ser baixado do MS Teams ou do GitHub.
 - Pode ser respondido através do link acima (na nuvem) ou localmente.
 - [Instruções para resolução e entrega dos laboratórios](#).
 - **Laboratórios podem ser feitos em grupo, mas as entregas devem ser individuais.**



Obrigado!



Dilbert.com DilbertCartoonist@gmail.com



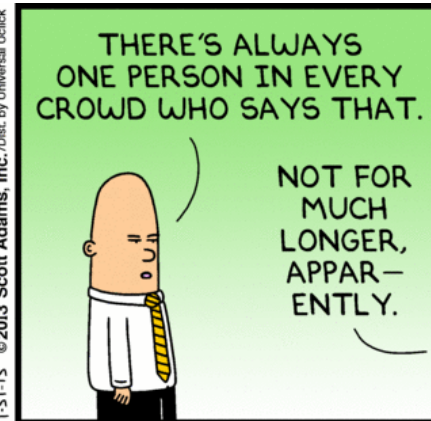
2-2-13 ©2013 Scott Adams, Inc./Dist. by Universal Uclick



Dilbert.com DilbertCartoonist@gmail.com



1-31-13 ©2013 Scott Adams, Inc./Dist. by Universal Uclick





www.dilbert.com scottadams@aol.com




©2003 United Feature Syndicate, Inc.









State

Action

Q-Table

State/Action	Value
-/-	0
-/-	0
-/-	0
-/-	0
-/-	0
-/-	0

Q-Value