T319 - Introdução ao Aprendizado de Máquina: *Introdução*

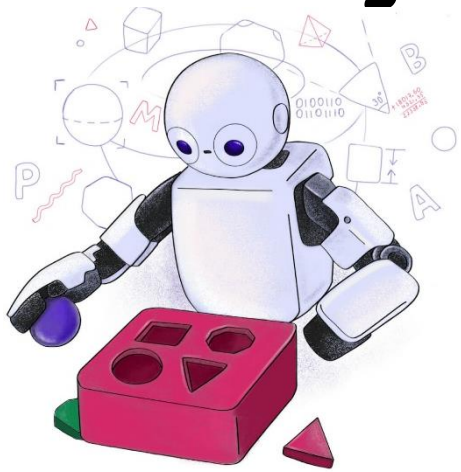

Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

A disciplina

- Introdução ao aprendizado de máquina.
- Como o próprio nome diz, é um curso introdutório onde veremos os conceitos básicos de funcionamento de vários ***algoritmos de aprendizado de máquina*** ou do Inglês, ***machine learning*** (ML).
- O curso será o mais prático possível, com vários exercícios envolvendo o uso dos algoritmos discutidos.
- O curso será dividido em duas partes: T319 e T320.
- Não nós aprofundaremos nos conceitos matemáticos envolvidos.
- Porém, precisamos conhecer Python e alguns conceitos de álgebra linear e estatística.

Cronograma

Aula	Data	Dia	Horário	Atividade
1	22/2/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
2	8/3/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
3	22/3/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
4	5/4/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
5	19/4/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
6	3/5/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
7	17/5/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
8	31/5/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
9	14/6/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
10	28/6/2021	Segunda-feira	08:00	Introdução ao Aprendizado de Máquina
11	12/07/2021	Segunda-feira	08:00	Avaliação

Objetivo do curso

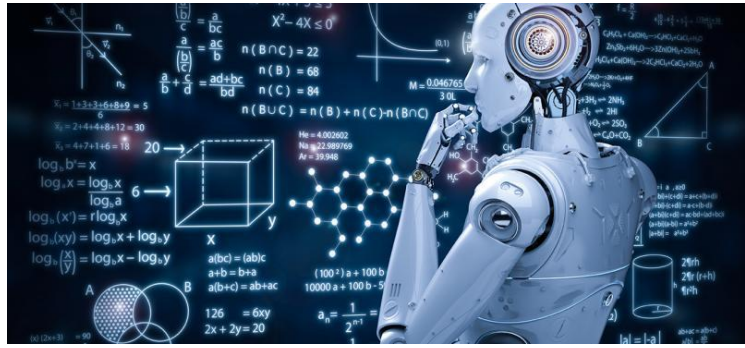

- O objetivo principal do curso é apresentar à vocês
  - os conceitos fundamentais da teoria do aprendizado de máquina.
  - um conjunto de ferramentas (ou seja, algoritmos) de aprendizado de máquina.
- Ao final do curso vocês devem ser capazes de
  - Entender e discutir sobre os principais algoritmos de ML.
  - Compreender a terminologia utilizada na área.
  - Aplicar algoritmos de ML para a resolução de problemas.
  - Analisar e entender novos algoritmos de ML.
  - Criar seus próprios projetos.

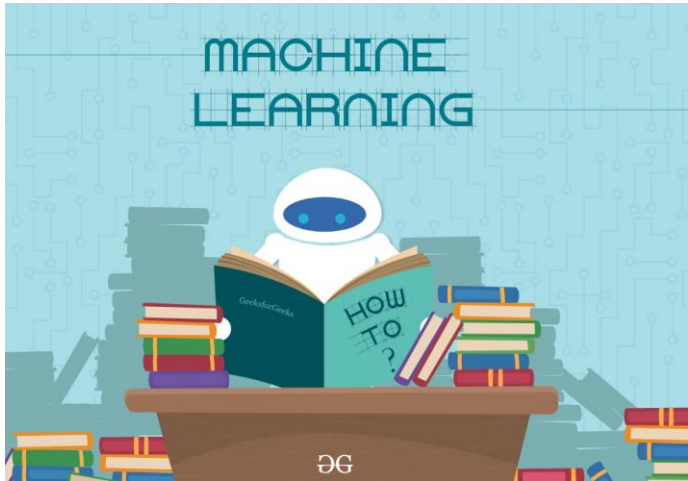

Avaliação do curso

- Prova
  - Uma (1) prova valendo 85% da nota.
  - Envolvendo questões teóricas e/ou práticas.
- Tarefas
  - Exercícios e quizzes em grupo valendo 15% da nota.
  - Ao longo das aulas e para casa.
  - Entregues no MS Teams.
- Presença
  - Dada através da entrega das tarefas.

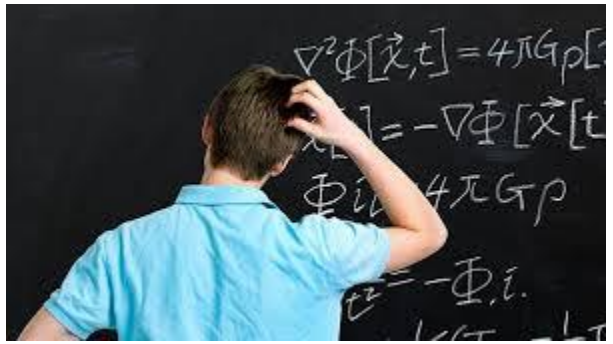

Motivação

- **Emprego**: grandes companhias (e.g., Google, Facebook, Amazon, etc.) usam ML para resolver os mais diversos tipos de problemas e assim aumentarem sua eficiência e consequentemente os lucros.
- **Pesquisa**: já se prevê que ML terá um papel importante no desenvolvimento da próxima geração de redes móveis e sem-fio (e.g., 6G).

Um pouco de história

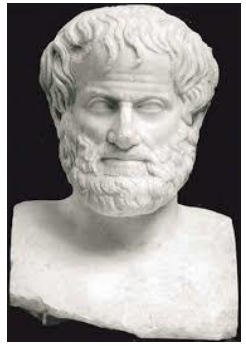

- A ideia de criar uma máquina pensante que imitasse as habilidades humanas é muito antiga, remontando à Grécia antiga.
- **Mitologia grega**: Talos, um autômato (máquina que realiza ações que lembram humanos ou animais) criado para proteger a princesa Europa de Creta de invasores.
- **300 A.C.**: Aristóteles almejava substituir a mão-de-obra escrava por objetos autônomos.
- **1822**: Charles Babbage cria os primeiros computadores mecânicos, as *máquinas diferencial* e *analítica*, se tornando o "*pai dos computadores*".
- **1837**: Ada Lovelace escreve o primeiro programa de computador para a *máquina analítica* de Babbage, se tornando a primeira "*programadora*" conhecida.

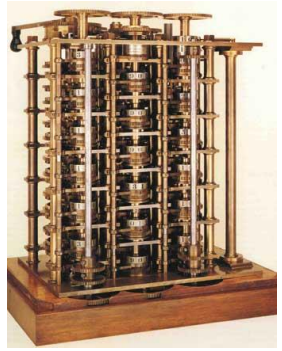

Um pouco de história (continuação)

- **1847**: George Boole cria a lógica booleana, lançando as bases para a era da informação.
- **1943**: McCulloch e Pitts propõem um modelo matemático para o funcionamento de um neurônio. Lançando as bases para a criação das redes neurais artificiais.
- **1950**: Alan Turing cria o "*teste de Turing*", que testa a capacidade de uma máquina em exibir comportamento inteligente indistinguível ao de um ser humano.
- **1952**: Arthur Samuel cria o primeiro programa de auto-aprendizagem (que mais tarde seria chamado de *aprendizado de máquina*) do mundo, o *Checkers-Player*, sendo a primeira demonstração do conceito de inteligência artificial.

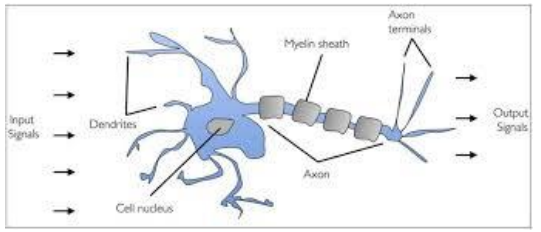

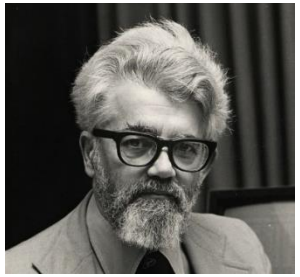

Um pouco de história (continuação)

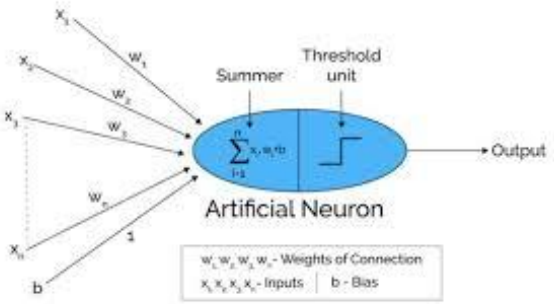

- **1956**: Surgimento da área de pesquisa em IA em um workshop no Dartmouth College nos EUA onde o termo IA foi cunhado por John McCarthy.
- **1958**: Frank Rosenblatt cria a primeira rede neural artificial, chamada de *Perceptron*.
- **1959**: Arthur Samuel cunha o termo *Aprendizado de Máquina* enquanto trabalhava na IBM.
- **1970-1980**: Devido a limitação dos computadores da época, IA atravessou alguns ***invernos***, i.e., interesse e financiamentos na área diminuíram drasticamente.
- **1986**: Ascensão do aprendizado de máquina: redes neurais retornam a popularidade e grandes avanços em algoritmos e aplicações de ML.

Um pouco de história (continuação)

- **1997**: O supercomputador da IBM, chamado de *DeepBlue*, vence o campeão mundial de xadrez, Garry Kasparov.

- **2009**: O Google constrói o primeiro carro autônomo que dirige em áreas urbanas.
- **2011**: Outro supercomputador da IBM, chamado *Watson*, vence o show de perguntas e respostas *Jeopardy!*.

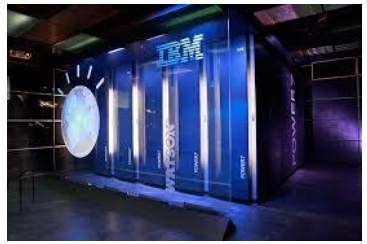

- **2011-2014**: Surgem assistentes pessoais, tais como *Siri*, *Google Now*, *Alexa* e *Cortana*, que utilizam reconhecimento de fala para responder questões e realizar tarefas simples.
- **2016**: O programa conhecido como *AlphaGo*, da empresa *DeepMind*, derrota o então 18 vezes campeão mundial de *Go*, Lee Sedol.

- **2018**: Universidades de todo o mundo começam a oferecer cursos de AI e ML.

Inatel

Inteligência + Artificial (IA)

- Vocês já pensaram sobre a definição destas duas palavras?
- **Inteligência**: é conjunto das ***habilidades mentais*** de ***conhecer***, ***compreender***, ***aprender***, ***resolver problemas*** e ***adaptar-se***.
  - Surgiu do Latim como união do prefixo ***inter***: "*entre*" + sufixo ***legere***: "*escolha*" => "*entre escolhas*".
  - Ou seja, inteligência é a ***capacidade de escolha*** de um indivíduo entre as várias possibilidades ou opções que lhe são apresentadas.
- **Artificial**: produzido pela mão do homem, não pela natureza, geralmente como uma cópia de algo natural.

Habilidades mentais desenvolvidas de forma não natural pela mão do homem.

Cópias de habilidades mentais humanas criadas de forma não natural pelo homem.

Definições e objetivo da IA

- **Definição**: "*Capacidade de um sistema de interpretar corretamente dados externos (vindos do ambiente), aprender com esses dados e usá-los para atingir tarefas e objetivos específicos por meio de adaptação flexível*." (*Andreas Kaplan*).
- **Definição**: "*Ciência e engenharia de produzir máquinas inteligentes*." (*John McCarthy*).
- **Objetivo**: Criar máquinas que ***imitem*** nossas *habilidades mentais*.
- Essa ***imitação*** é apenas uma aproximação pois ainda não conseguimos criar matéria viva.
- É por isso que em IA fala-se da criação de máquinas que são ***modelos aproximados*** de nossas habilidades de aprender, raciocinar, enxergar, falar, ouvir, etc.

Inteligência Artificial

- IA é uma área muito ampla que ***engloba*** várias aplicações (ou sub-áreas ou objetivos) tais como
  - *i. processamento de linguagem natural*,
  - *ii. representação do conhecimento*,
  - *iii. raciocínio automatizado,*
  - iv. planejamento,
  - *v. visão computacional*,
  - *vi. robótica*,
  - *vii. aprendizado de máquina,* que por sua vez engloba redes neurais artificiais, deep learning, etc. e
  - *viii. inteligência artificial geral.*

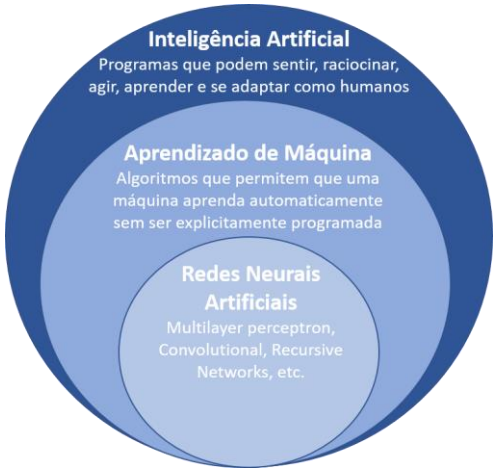

- IA utiliza a ***experiência*** para adquirir ***conhecimento*** e também como aplicar esse conhecimento a problemas desconhecidos.
  - **Exemplo**: Um problema matemático pode ser solucionado (i) caso ele tenha sido resolvido antes e sua solução ***aprendida*** ou (ii) caso ele nunca tenha sido visto antes mas um indivíduo com inteligência imagina (ou seja, pensa) possíveis maneiras de como resolve-lo baseado no que ele ***sabe (conhecimento)***.

Algumas aplicações de IA

Algumas áreas onde IA é aplicada são:

- **Transporte**: veículos terrestres e aéreos autônomos, predição do tráfego, etc.
- **Negócios**: recomendação de anúncios, produtos e conteúdos (e.g., netflix), chatbots para atendimento ao cliente, etc.
- **Educação**: pontuação automatizada de fala em testes de Inglês, correção de provas, chatbots para realização de matrículas, dúvidas, etc.
- **Clima**: previsão do tempo (temperatura, chuva, furacões, etc.).
- **Medicina**: detecção e/ou predição de doenças (câncer, Alzheimer, pneumonia, COVID-19, etc.), chatbots que auxiliam no agendamento de consultas e respondem perguntas referentes a uma doença, descoberta de novas drogas, etc.
- **Finanças**: detecção de fraudes com cartão de crédito, predição do comportamento do mercado de ações, etc.
- **Tecnologia**: filtros AntiSpam, “motores” de busca como o do Google, reconhecimento de fala, conversão de texto/fala e fala/texto, assistentes pessoais on-line (e.g., *Siri*, *Alexa*, etc.), tradução de textos.

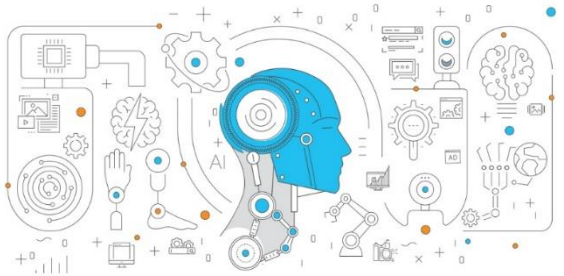

Exemplos interessantes do uso de IA

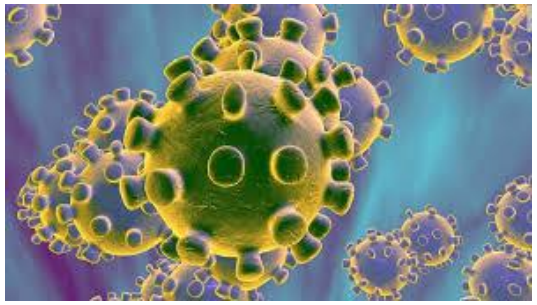

- **Predição de surtos de doenças infecciosas**: IA previu em Dezembro de 2019 o novo surto de corona vírus e onde ele apareceria em seguida.
- **Ajuda no diagnóstico de doenças**: IA tem sido usada para ajudar médicos a diagnosticarem o novo coronavírus através de imagens de raio-X e tomografias.
- **Criação de vídeos/fotos falsas**: IA foi usada para criar vídeo viral utilizando trecho de “A Usurpadora” para falsificar uma conversa entre Lula e Bolsonaro.
- **Criação de novos medicamentos**: IA foi utilizada para criar uma nova droga capaz de combater o transtorno obsessivo-compulsivo (TOC). Encurtou o tempo para encontrar um novo medicamento de 4 para menos de 1 ano.

Foco do curso

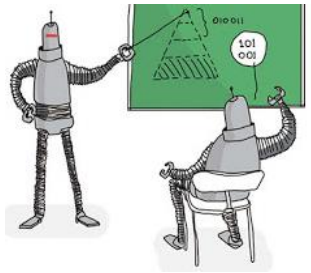

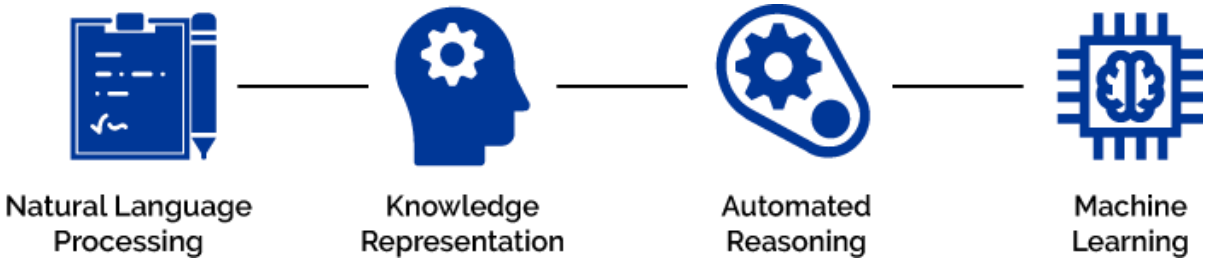

- Como vimos, IA é um termo muito amplo, abrangendo várias sub-áreas, usado para designar máquinas capazes executar ***tarefas*** de forma inteligente.
- **Foco do curso**: estudo dos principais algoritmos de ***Aprendizado de Máquina***.
- **Por quê?**
  - ***Caixa de ferramentas***: ML oferece ferramentas importantes para a solução e análise eficiente de vários problemas em várias áreas.
  - ***Redução de complexidade e custo***: vários algoritmos em várias áreas que apresentam desempenho ótimo não são utilizados na prática pois possuem complexidade computacional e/ou custo proibitivos.
  - ***Oportunidades***: existem muitos empregos na área de análise de dados e pesquisas sobre a aplicação de ML.

Mas então, o que é ML?

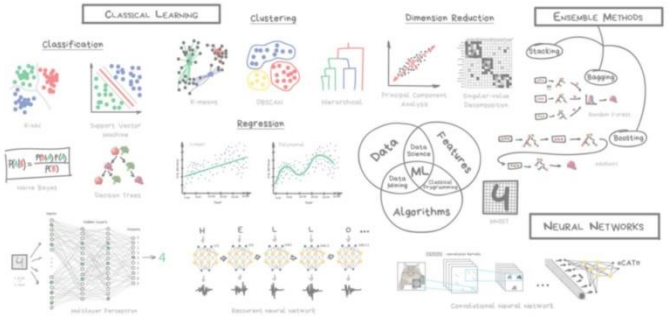

- É uma sub-área ou objetivo da inteligência artificial.
- O termo foi cunhado em 1959, por Arthur Samuel, que o definiu como o "*campo de estudo que dá aos computadores a habilidade de aprender sem serem explicitamente programados*".
- Uma outra definição interessante feita por Jojo John Moolayil é "*Aprendizado de máquina é o processo de **induzir** inteligência em uma máquina sem que ela seja explicitamente programada*".
  - **Indução**: aprender um modelo ou padrão geral a partir de exemplos.
- Algoritmos de ML são ***orientados a dados***, ou seja, eles aprendem automaticamente um modelo/padrão geral (i.e., generalizar) a partir de grandes volumes de dados (i.e., exemplos).
- **Exemplo**: filtro de spam do Gmail.

Por que ML se tornou tão difundido?

Alguns dos principais motivos são:

- Vivemos na era da informação. Nessa era, um volume sem precedentes de dados (de tera a petabytes) está disponível, impossibilitando sua análise por nós seres humanos.
- Porém, para modelos de ML isso não é um problema e sim uma solução, pois quanto mais dados melhor será o aprendizado.
- Hoje em dia, dados são preciosíssimos e a extração de novas informações (úteis) vale ouro.
- O surgimento de recursos computacionais poderosos tais como GPUs, FPGAs e CPUs com múltiplos cores.
- Surgimento de novas e eficientes estratégias/técnicas de treinamento (i.e., aprendizagem), e.g., deep-learning, reinforment-learning, etc.
- Existência de frameworks e bibliotecas poderosas que facilitam o desenvolvimento de soluções com ML.

Tipos de Aprendizado de Máquina

Os algoritmos de aprendizado de máquina podem ser agrupados nas seguintes categorias:

- Supervisionado
- Não-Supervisionado
- Semi-Supervisionado
- Por Reforço
- Metaheurístico

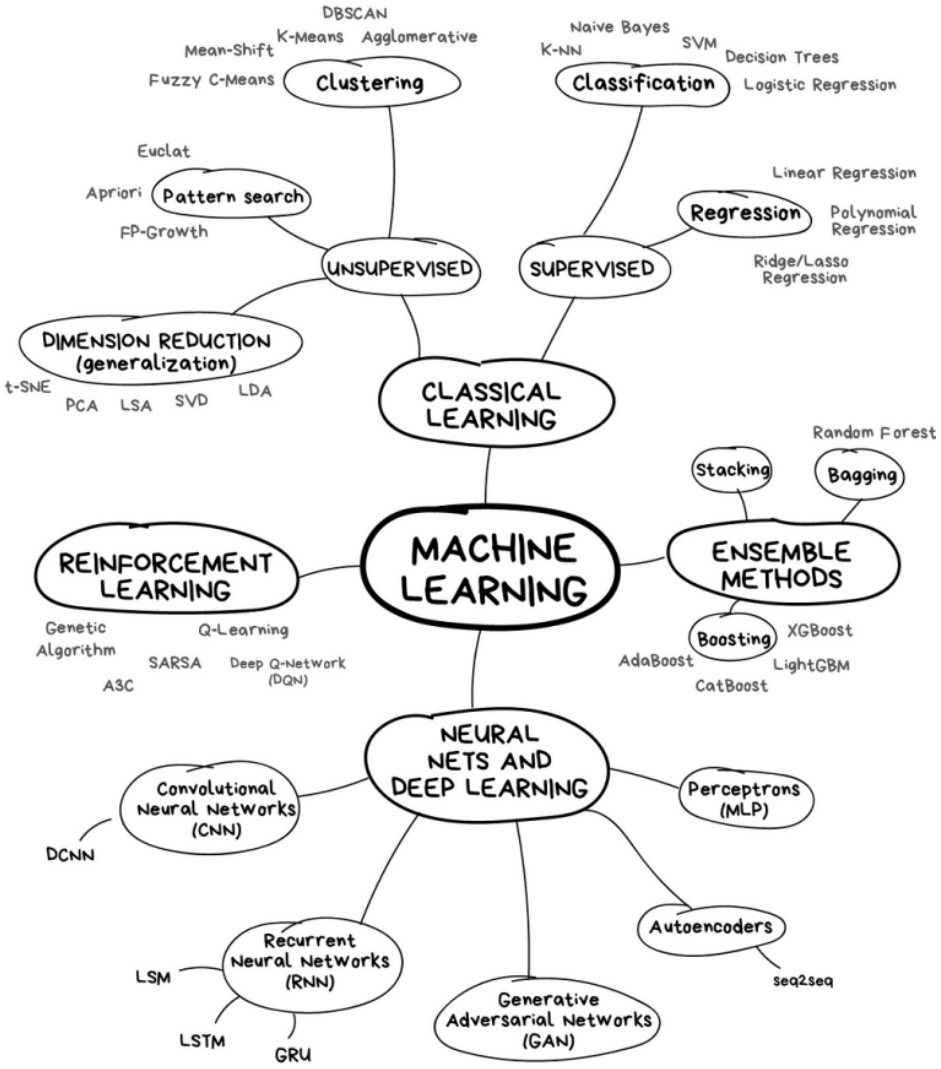

Aprendizado Supervisionado

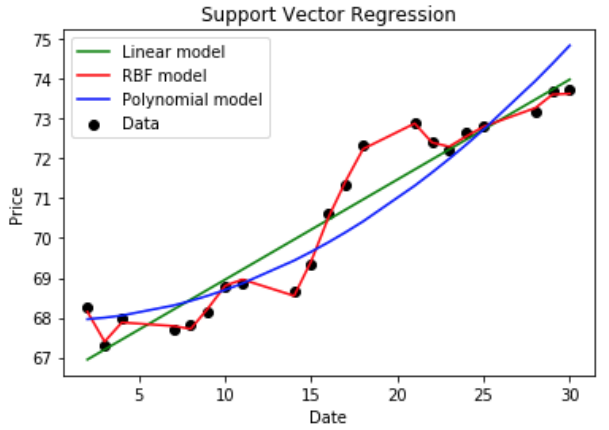

- No aprendizado supervisionado a máquina sabe o que aprender, ou seja, ela tem acesso às respostas esperadas.
- Neste tipo de aprendizado, os dados ou exemplos de treinamento incluem os ***atributos***, $\boldsymbol{x}$, que são a entrada do algoritmo de ML e as ***soluções desejadas***, y, (i.e., as respostas corretas), chamadas de ***rótulos*** (ou *labels*, do Inglês).

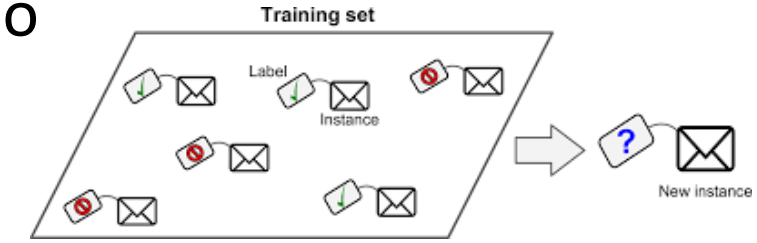

- **Tarefa**: os modelos supervisionados de ML devem ***aprender*** uma função que mapeie as entradas $\boldsymbol{x}$ nas saídas y, ou seja, $y = f(\boldsymbol{x})$.
- Esse tipo de aprendizado pode ser dividido em problemas de ***Regressão*** e ***Classificação***.
  - **Regressão**: o rótulo, y, pertence a um ***conjunto infinito*** de valores, i.e., números reais.
  - **Classificação**: o rótulo, y, pertence a um ***conjunto finito*** de valores, i.e., conjunto finito de classes.

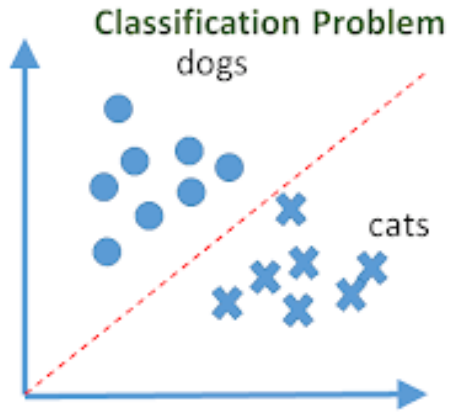

Principais Algoritmos para Aprendizado Supervisionado

- Regressão linear.
- Regressão logística.
- k vizinhos mais próximos (*k-nearest neighbors* - k-NN).
- Arvores de Decisão (*Decision Trees*).
- Florestas Aleatórias (*Random Forests*).
- Máquinas de Vetores de Suporte (*Support Vector Machines* - SVMs).
- Redes Neurais Artificiais.

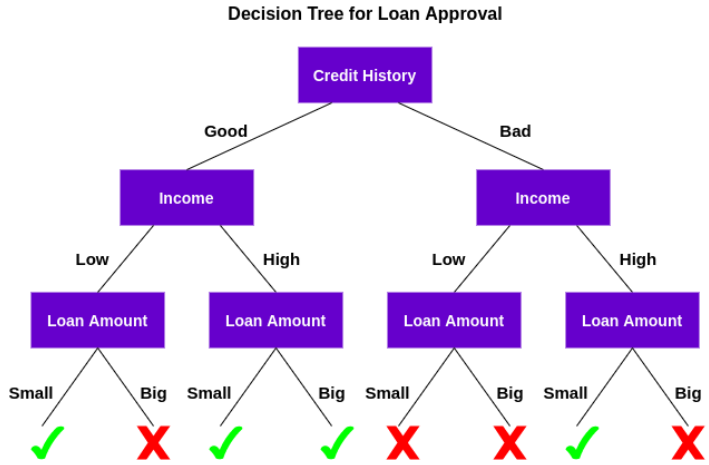

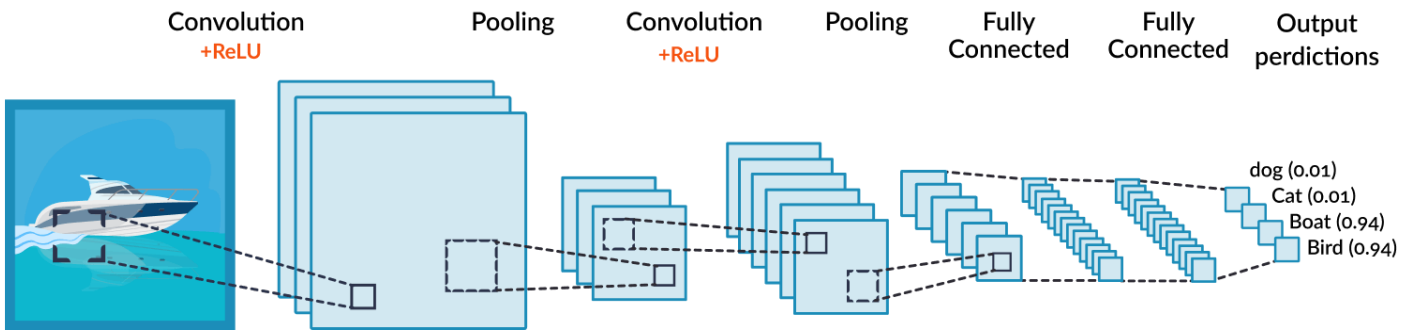

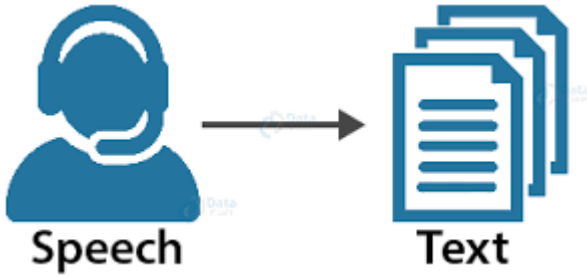

Aprendizado Não-Supervisionado

- Neste tipo de aprendizado, as máquinas não são informadas sobre o que aprender. Elas só recebem os exemplos de treinamento, $\boldsymbol{x}$.
- Neste caso, os algoritmos ***aprendem/descobrem padrões*** (muitas vezes ocultos) presentes nos dados de entrada sem a presença de rótulos.
- **Tarefa**: os modelos devem ***aprender/descobrir*** padrões desconhecidos se baseando apenas nos exemplos de entrada.
- Trata problemas de clusterização, redução de dimensionalidade, detecção de anomalias (*outliers*) e aprendizado de regras de associação.

Clusterização

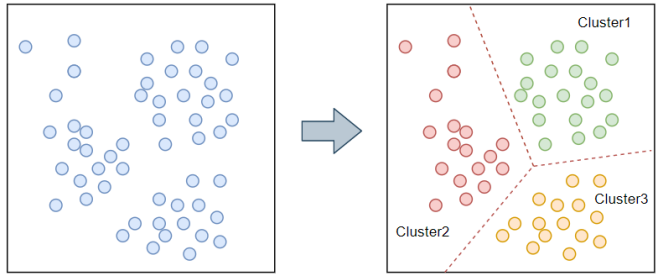

Redução de dimensionalidade

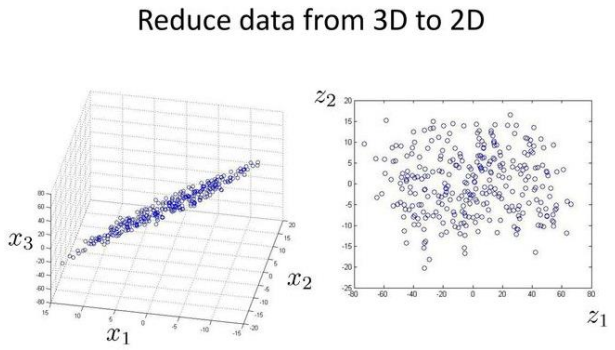

Detecção de Anomalias

Regras de associação

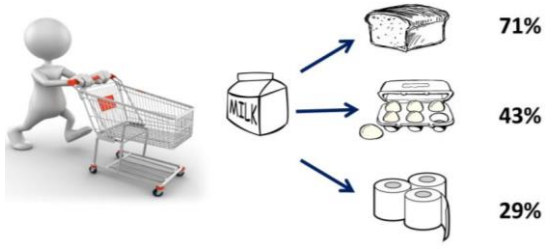

Of transactions that included milk:
- 71% included bread
- 43% included eggs
- 29% included toilet paper

Principais Algoritmos para Aprendizado Não-Supervisionado

- k-médias (*k-means*).
  - Particiona os atributos em ***k*** clusters (ou grupos) distintos com base na distância ao centroide de um cluster.
- Redes Neurais Artificiais, e.g., auto-encoders.
  - Os autoencoders são usados para redução ou aumento de dimensionalidade.
- Análise de Componentes Principais (*Principal Component Analysis* - PCA).
  - Redução de dimensionalidade.

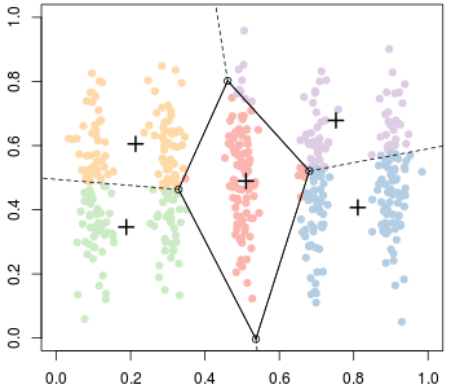

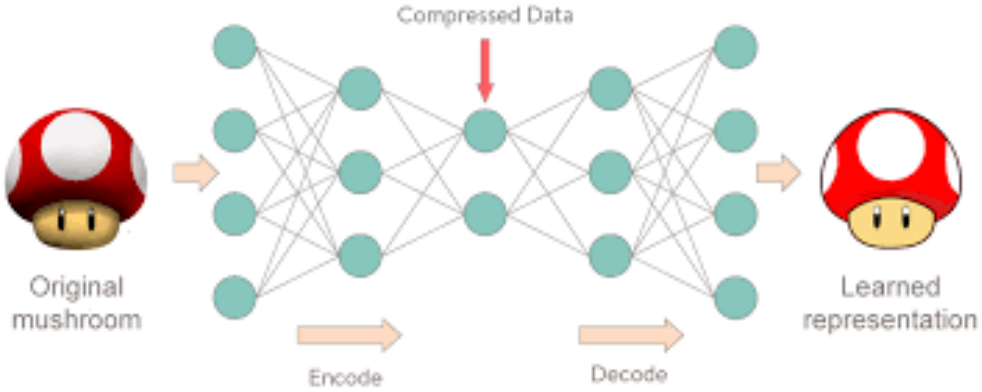

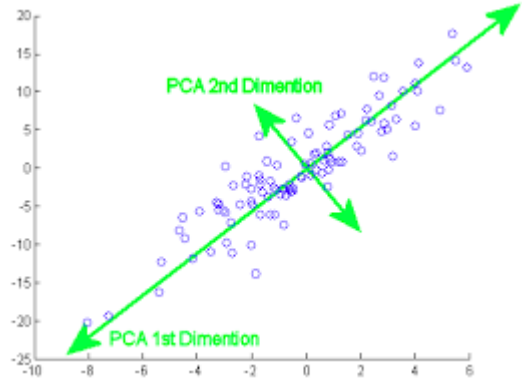

Principais Algoritmos para Aprendizado Não-Supervisionado (continuação)

- Análise de Componentes Independentes (*Independent Component Analysis* - ICA)
  - Realiza uma espécie de clusterização baseada em propriedades estatíticas dos sinais envolvidos, por exemplo, a independência dos sinais de voz em um coquetel.
- Mapas Auto-Organizáveis (*Self-Organized Maps* - SOMs)
  - Tipo de rede neural usada para aprender a topologia e distribuição dos dados.
- Modelos Ocultos de Markov (*Hidden Markov Models* - HMM)
  - Usa dados observados para recuperar uma sequência de estados.

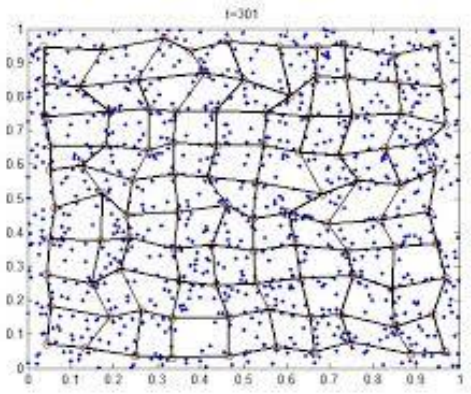

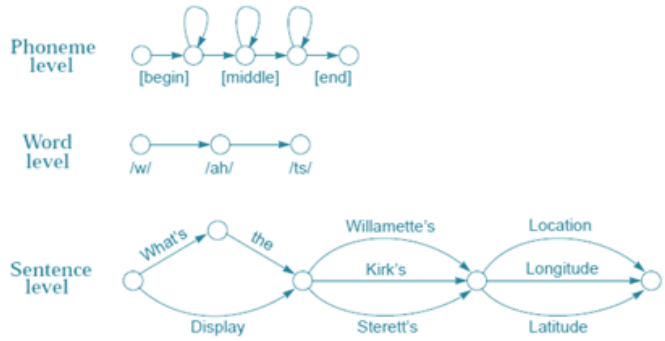

Aprendizado Semi-Supervisionado

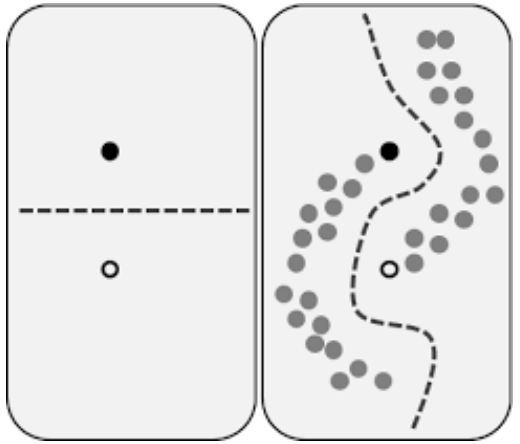

- Neste tipo de aprendizado, as máquinas tem acesso a exemplos com e sem rótulos.
- Geralmente envolve uma pequena quantidade de dados rotulados e uma grande quantidade de dados não-rotulados.
- É de grande ajuda em casos onde se ter uma grande quantidade de dados rotulados é muito caro ou complexo.
- Algoritmos de aprendizagem semi-supervisionada são o resultado da combinação de algoritmos supervisionados e não-supervisionados.
- **Exemplo**: Facebook e Instagram recebem várias fotos suas e de conhecidos e familiares seus. Em várias fotos postadas, um algoritmo de ***clusterização*** agrupa pessoas A, B e C, em outras várias fotos enviadas, pessoas B, D e E. Em um determinado momento, você carrega uma foto onde você fornece o nome (i.e., o label) de algumas dessas pessoas.

Aprendizado Por Reforço

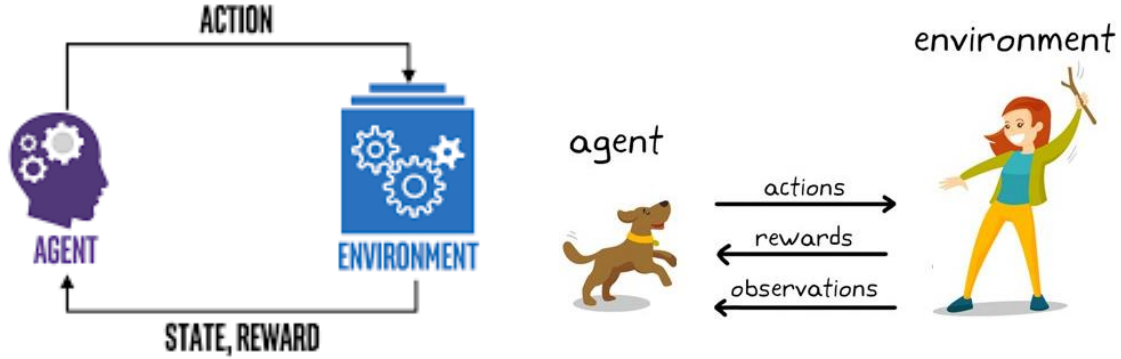

- Abordagem totalmente diferente das anteriores pois não se tem dados de treinamento, sejam eles rotulados ou não.
- O algoritmo de aprendizagem por reforço, chamado de ***agente*** nesse contexto, deve aprender como se comportar em um ***ambiente*** através de interações do tipo “tentativa e erro”.
- O ***agente*** observa o ***estado*** do ***ambiente*** em que está inserido, seleciona e executa ***ações*** e recebe uma ***recompensa*** (ou ***reforço***) em consequência das ***ações*** tomadas.
- Seguindo estes passos, o agente deve aprender por si só qual a melhor ***estratégia***, chamada de ***política***, para obter a maior recompensa possível ao longo do tempo.
- Uma ***política*** define qual ***ação*** o ***agente*** deve escolher quando estiver em uma determinada situação, ou seja, o ***estado*** do ***ambiente***.
- Uma **Política**, denotada por $\boldsymbol{\pi}$, é uma função que mapeia os ***estados*** do ***ambiente*** em ***ações*** que o ***agente*** deve tomar, $\pi(s) = a$.

Principais Algoritmos de Aprendizado Por Reforço

- Q-Learning
  - Usado para encontrar uma ***política*** ótima de seleção de ***ações*** usando a ***função-Q***.
  - *'Q',* ou ***valor-Q***, representa a ***qualidade*** de uma dada ***ação*** em um determinado ***estado***.
- Deep Q-Learning
  - Junção de Deep Learning + Q-Learning. Redes neurais profundas possibilitam que Q-Learning seja aplicado a problemas com número gigantesco de ***estados*** e ***ações***.
  - O Q-Learning tabela a ***função-Q***, já o Deep Q-Learning encontra uma ***função*** que aproxime a ***função-Q***.

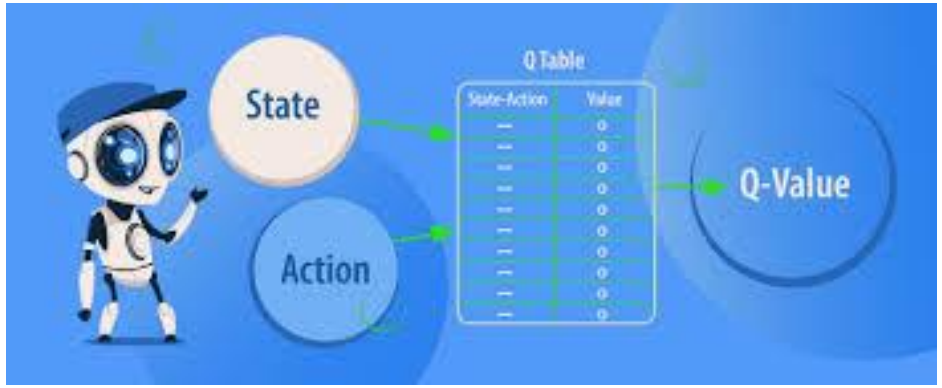

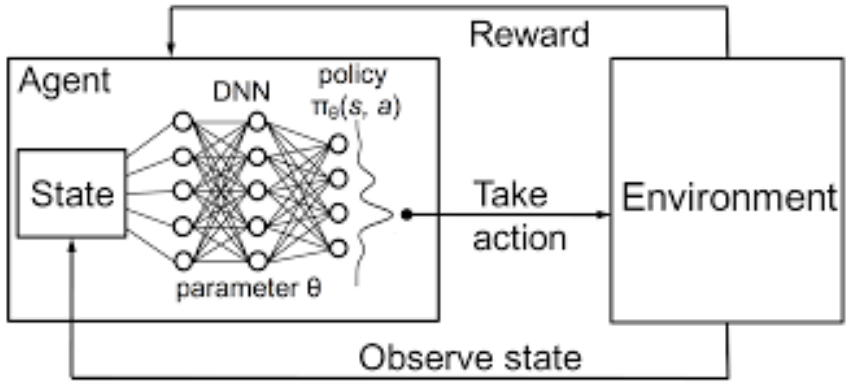

Aprendizado Metaheurístico

- Uma ***metaheurística*** é um método ***heurístico*** usado para resolver de forma genérica problemas de otimização.
- ***Heurística*** é um método ou processo criado com o objetivo de encontrar soluções, de forma rápida e muitas vezes sub-ótimas, para um problema.
- ***Metaheurísticas*** são geralmente aplicadas a problemas para os quais não se conhece um algoritmo eficiente (veja problemas NP-completos).
- As metaheurísticas:
  - não garantem que uma solução globalmente ótima seja encontrada, mas podem encontrar uma solução suficientemente boa.
  - são estratégias que orientam o processo de busca.
  - não são específicas do problema, ou seja, são genéricas.
  - funcionam bem mesmo com capacidade de computação limitada.

Principais Algoritmos de Aprendizado Metaheurístico

- Algoritmo Genético (*Genetic Algorithm* - GA).
  - Inspirados pelo processo de seleção natural.
- Optimização por enxame de partículas (*Particle Swarm Optimization* - PSO).
  - Inspirado no comportamento de cardumes de peixes e de bandos de pássaros
- Otimização da colônia de formigas (*Ant Colony Optimization* - ACO).
  - Inspirado no comportamento das formigas ao saírem de sua colônia para encontrar comida.

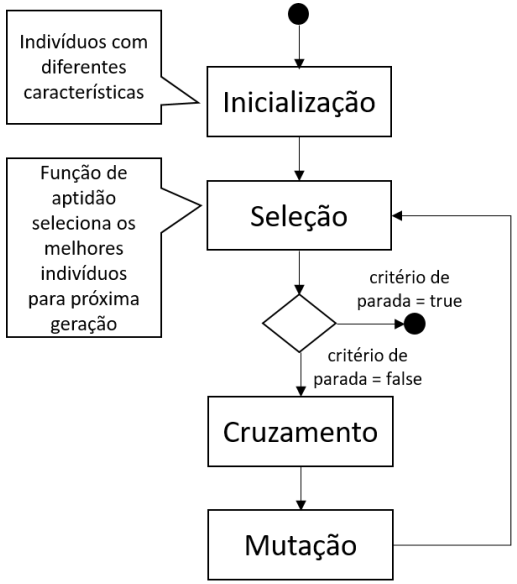

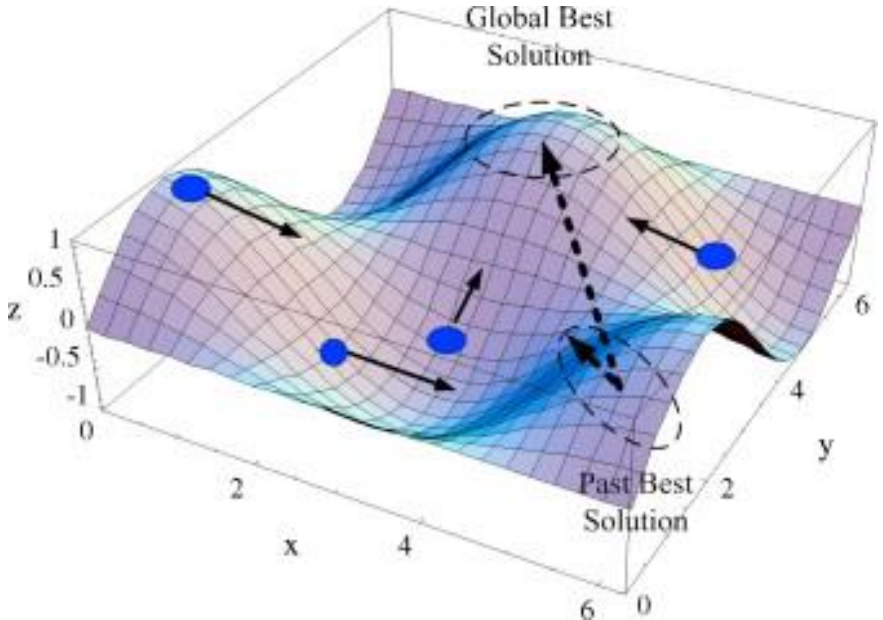

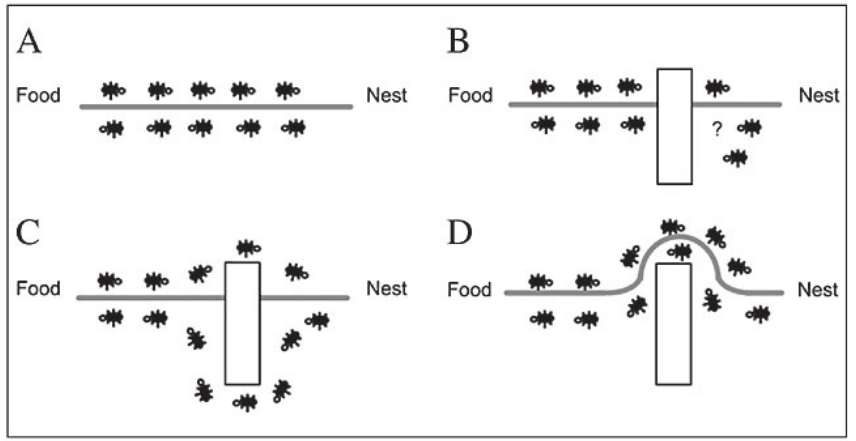

Figure 2. A. Ants in a pheromone trail between nest and food; **B.** an obstacle interrupts the trail; **C.** ants find two paths to go around the obstacle; **D.** a new pheromone trail is formed along the shorter path.

Tipos de Treinamento

Uma outra forma de se classificar algoritmos de ML é com relação se eles podem ser treinados incrementalmente ou não. Assim, os algoritmos podem ser divididos em algoritmos com teinamento:

- **incremental (online)**.
- **em batelada (batch)**.

Treinamento incremental

- Neste tipo de treinamento, o algoritmo aprende incrementalmente: exemplos de treinamento são apresentados sequencialmente um-a-um ou em pequenos grupos chamados de mini-batches (ou mini-lotes).
- Cada iteração de treinamento é rápida possibilitando que o sistema aprenda sobre novos dados à medida que eles chegam.
- Ótima opção para casos onde os dados chegam como um fluxo contínuo ou se tem recursos computacionais limitados.
- Entretanto, como não há pré-processamento/análise, dados corrompidos ou com problemas afetam a performance do sistema.

Treinamento em batelada

- Neste tipo de treinamento, o algoritmo é treinado com todos os exemplos disponíveis.
- É um tipo de treinamento simples, de fácil implementação e obtém ótimos resultados.
- Dados podem ser pré-processados/analisados, evitando assim, dados corrompidos ou com problemas.
- O treinamento é demorado e utiliza muitos recursos computacionais (e.g., CPU, memória) quando comparado ao treinamento incremental.
- Para treinar com novos exemplos é necessário iniciar o treinamento do zero.
- Se a quantidade de dados do conjunto de treinamento for muito grande pode ser impossível treinar em batelada.

Python, Jupyter & Colab

colab

O que é Python?

- Linguagem de programação de alto nível, interpretada, multiparadigma e gratuita.
- Foi lançada por Guido van Rossum em 1991.
- Possui um modelo de desenvolvimento comunitário, aberto e gerenciado pela *Python Software Foundation* (PSF).
- **Curiosidade**: o nome Python é uma homenagem ao grupo de humor britânico, Monty Python.

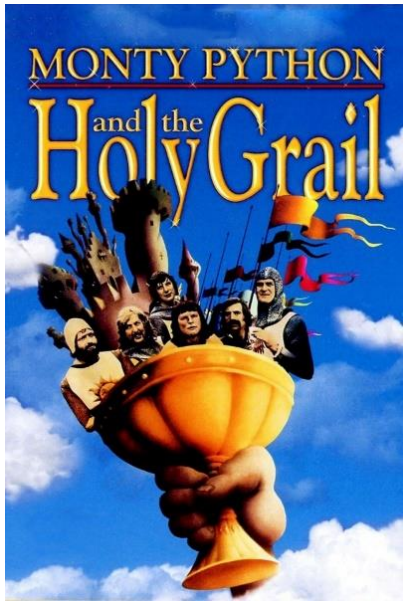

Por que Python?

Algumas razões são:

1. É uma das linguagens mais fáceis de se aprender.
2. É muito popular e será mais ainda nos próximos anos.
3. Grandes empresas a utilizam.
4. É a linguagem mais usada em aplicações de ML.
5. Possui vasto suporte on-line: tutoriais, vídeos, StackOverflow, etc.
6. É usada como linguagem educativa para ensino de computação e eletrônica (e.g., Raspberry Pi, LEGO Mindstormstem podem ter suas aplicações desenvolvidas em Python).
7. Possui um rico ecossistema de bibliotecas: SciPy, NumPy, Pandas, MatplotLib, SciKit-Learn, TensorFlow, OpenCV, etc.
8. Teve uma rápida adoção pela comunidade científica.
9. É gratuita e open-source.

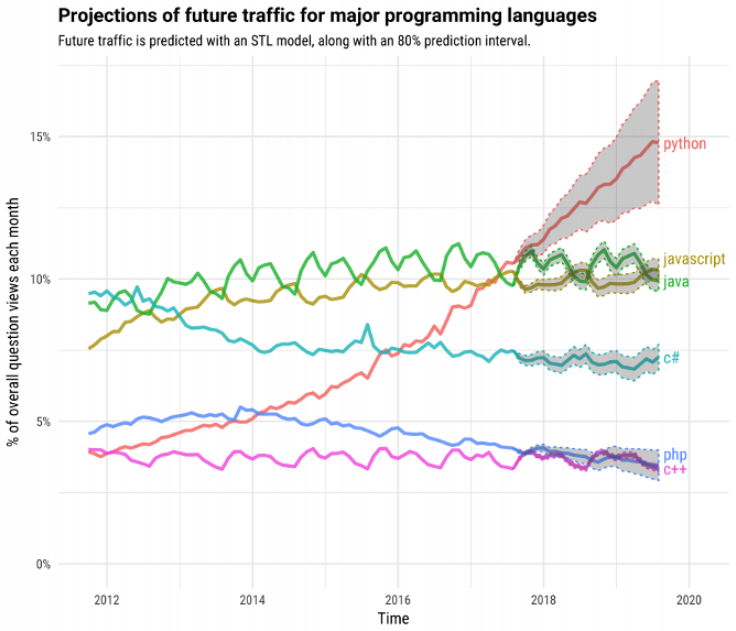

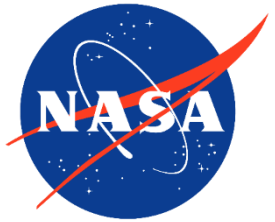

Executando códigos Python na nuvem

- Durante o curso, utilizaremos ambientes computacionais interativos baseados em ***aplicações web*** para criação de documentos virtuais, chamados de ***notebooks***.
- Os ***notebooks*** são documentos usados para criar e compartilhar código interativo juntamente com equações, gráficos e texto.
- Dessa forma, um ***notebook*** permite uma maneira interativa de programar e documentar o código.
- Existem vários ambientes computacionais interativos gratuitos disponíveis, mas usaremos o ***Jupyter*** ou o ***Google Colaboratory***, que são os mais conhecidos e estáveis.

Jupyter

- **Jupyter**: aplicação web gratuita que permite a criação e edição de ***notebooks*** em navegadores web.
- Suporta a execução de várias linguagens de programação: Python, C++, C#, PHP, Julia, R, etc.
- Site oficial: https://jupyter.org/
- Algumas desvantagens do **Jupyter** são:
  - Poucos servidores disponíveis.
  - Depois de algum tempo inativo, a máquina virtual executando seu ***notebook*** se desconecta e você pode perder seu código.

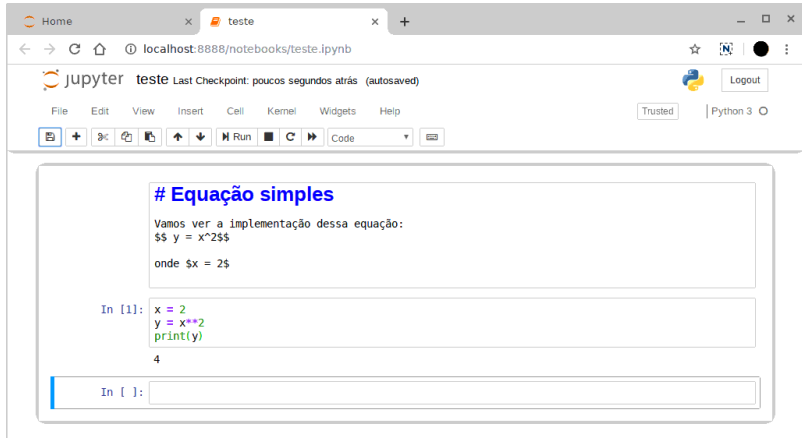

Goolge Colaboratory (Colab)

- **Colab**: outra aplicação web gratuita, baseada no Jupyter, que permite a criação e edição de ***notebooks*** em navegadores web.
- É um produto da Google.
- Por hora, suporta apenas a execução de códigos em Python.
- Vantagens sobre o Jupyter:
  - Maior número de servidores.
  - Inicialização e processamento do código mais rápidos.
  - Fornece GPUs e TPUs gratuitamente.
  - Compartilhamento de notebooks entre usários é mais fácil.
  - Salva os notebooks no seu Google Drive, evitando que você perca seu código.
- Site oficial: https://colab.research.google.com/

Instalando o Python, Jupyter e outras ferramentas e bibliotecas

- Para resolver os exercícios do curso, vocês podem usar o **Jupyter** de forma online ou instalá-lo localmente.
- Eu recomendo que vocês o instalem localmente caso vocês precisem executá-lo sem uma conexão com a internet.
- O Python, o Jupyter e outras ferramentas e bibliotecas podem ser instaladas através da distribuição Anaconda seguindo-se o tutorial a seguir:
  - Link para instalação do Anaconda.
- **OBS**.: infelizmente, o Google Colab não pode ser instalado localmente.

Alguns Exemplos

Histograma

```
import numpy as np
import matplotlib.pyplot as plt

%matplotlib inline

data = np.random.randn(1000000)

# histograma (pdf)
plt.subplot(1, 2, 1)
plt.title('PDF')
plt.hist(data, bins=100, density=True, color='b')

# CDF empirica
plt.subplot(1, 2, 2)
plt.title('CDF')
plt.hist(data, bins=100, density=True, color='g', cumulative=True)

plt.savefig('histogram.png') # salva figura em arquivo
```

Exemplo (binder): Histograma.ipynb

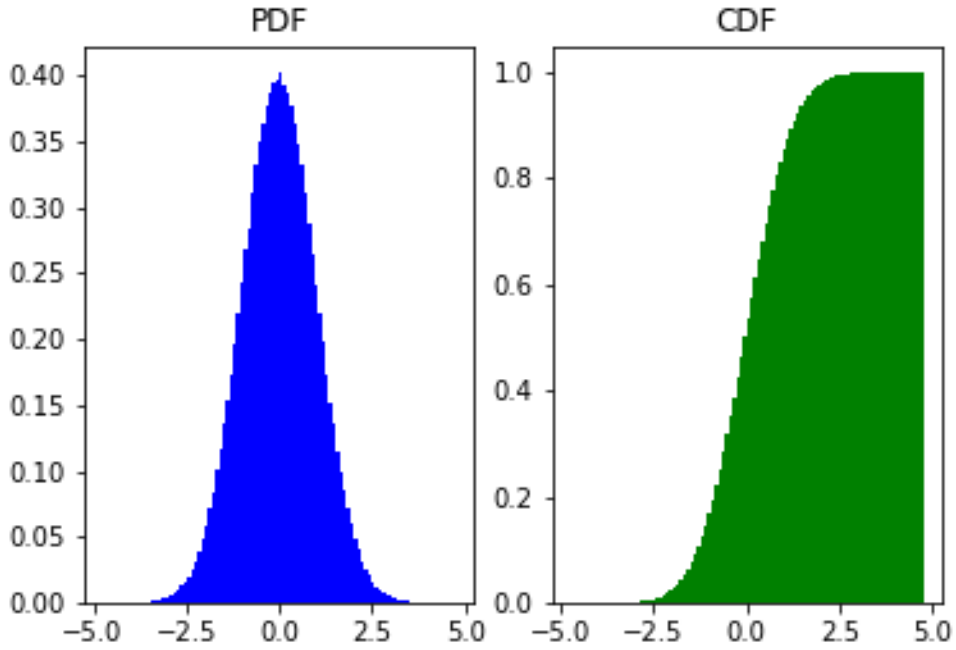

Exemplo (colab): Histograma.ipynb

Figura 3D

```
import matplotlib.pyplot as plt
# facilita visualizacao de figuras 3D
from mpl_toolkits.mplot3d import axes3d # graficos 3D sao habilitados importando axes3d

# para figuras interativas usar “notebook” ao inves de “inline”
%matplotlib notebook

ax = plt.subplot(111, projection='3d')
X, Y, Z = axes3d.get_test_data (0.1)
ax.plot_wireframe(X, Y, Z)

# salva figura em arquivo
plt.savefig('figura3d.png')
```

Exemplo (binder): Figura_3D.ipynb

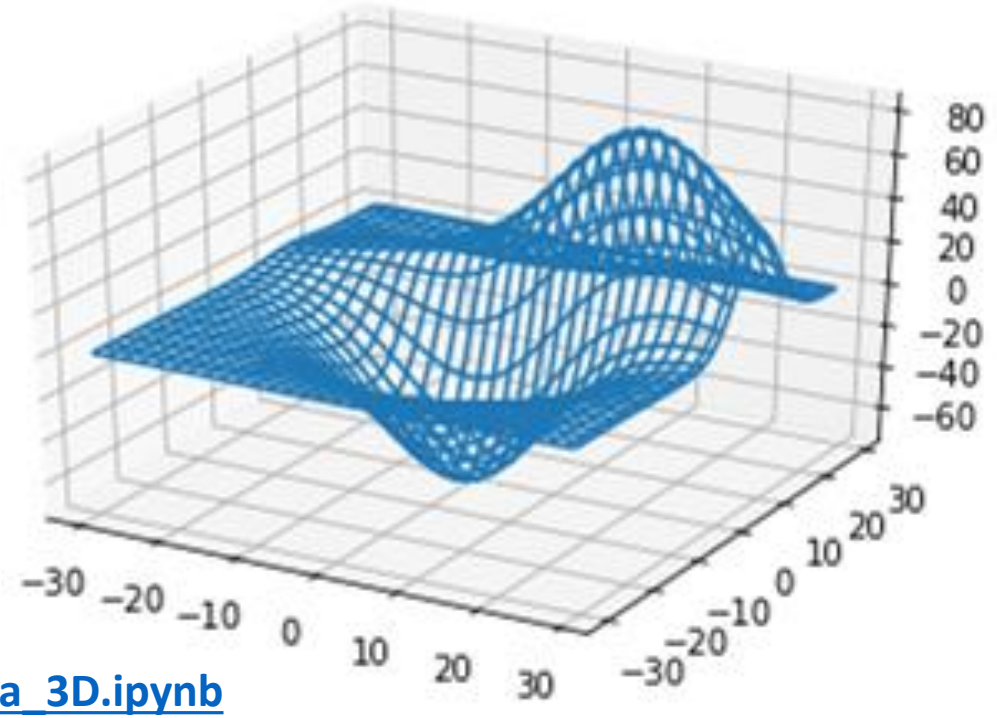

Exemplo (colab): Figura_3D.ipynb

Ajuste de curva com Redes Neurais

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.neural_network import MLPRegressor # importa classe MLPRegressor do modulo neural network

%matplotlib inline

x = np.arange(-10, 10, 0.1)

# dados originais
y = 12 + 3 * np.exp(-0.05*x) + 1.4 * np.sin(1.2*x) + 2.1 * np.sin(-2.2*x + 3)

# faz com que o gerador de numeros aleatorios sempre forneca os mesmos valores
np.random.seed(42)

# adicionando ruido aos dados originais
y_noise = y + np.random.normal(0, 0.5, size = len(y))

# trata o ajuste de curva como um problema de regressao e treina um modelo para que se ajuste aos dados.
mlp = MLPRegressor(hidden_layer_sizes=(50,25,10), max_iter=10000, solver='lbfgs', alpha=0.9, activation='tanh')
yfit = mlp.fit(x[:, None], y_noise).predict(x[:, None])

plt.figure()
plt.plot(x, y_noise, 'o', label = 'dado original + ruido')
plt.plot(x, y, 'k', label = 'dado original')
plt.plot(x, yfit, '-r', label = 'curva ajustada com MLP', zorder = 10)
plt.legend()
plt.xlabel('X')
plt.ylabel('y')

# salva figura em arquivo
plt.savefig('mlp_regression.png')
```

Exemplo (binder): Ajuste_de_curva_com_Redes_Neurais.ipynb

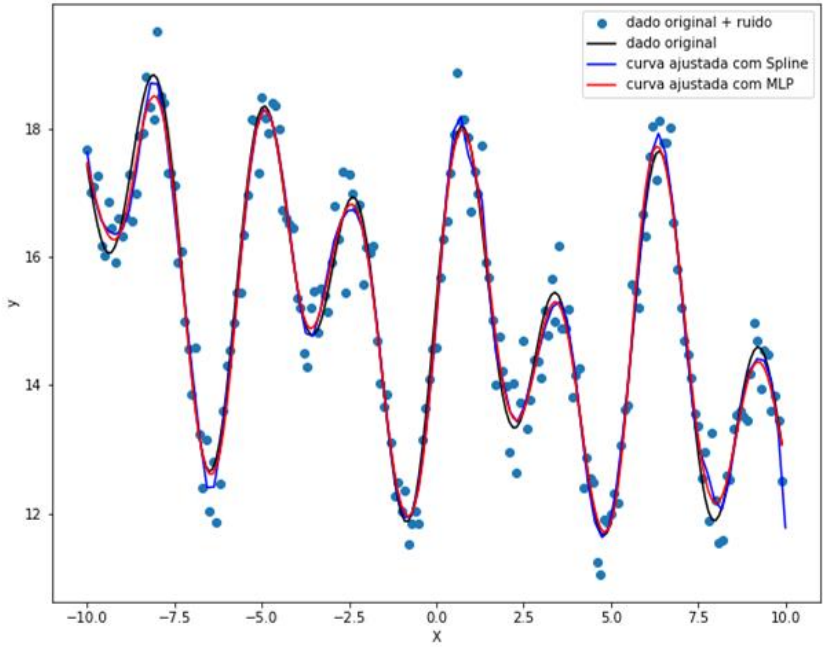

Exemplo (colab): Ajuste_de_curva_com_Redes_Neurais.ipynb

Referências

[1] Stuart Russell and Peter Norvig, "*Artificial Intelligence: A Modern Approach*," Prentice Hall Series in Artificial Intelligence, 3rd ed., 2015.

[2] Aurélien Géron, "*Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*", 1st ed., O'Reilly Media, 2017.

[3] Joseph Misiti, "*Awesome Machine-Learning*," on-line data base with several free and/or open-source books (https://github.com/josephmisiti/awesome-machine-learning).

[4] Andriy Burkov, "*The Hundred-Page Machine-Learning Book*," Andriy Burkov 2019.

[5] C. M. Bishop, "*Pattern Recognition and Machine Learning*," Springer, 1st ed., 2006.

[6] S. Haykin, "*Neural Networks and Learning Machines*," Prentice Hall, 3ª ed., 2008.

[7] Coleção pessoal de livros, https://drive.google.com/drive/folders/1IyIIMu1w6POBhrVnw11yqXXy6BjC439j?usp=sharing

Avisos

- Entregas de exercícios devem ser feitas no MS Teams.
  - Se atentem às datas de entrega no MS Teams.
- Todo material do curso será disponibilizado no MS Teams e no GitHub:
  - https://github.com/zz4fap/t319_aprendizado_de_maquina
- Horário de Atendimento
  - Professor: Segundas-feiras das 18:30 às 19:30 e Quartas-feiras das 15:30 às 16:30 via MS Teams.
  - Monitora (Bruna): Todas as Sextas-feiras das 17:30 às 18:30.

Tarefas

- Devem ser realizadas em grupo.
- **Quiz**: “*T319 - Quiz - Introdução (1S2021)*” que se encontra no MS Teams.
- **Exercício Prático**: **Laboratório #1**.
  - Pode ser baixado do MS Teams ou do GitHub.
  - Pode ser respondido através do link acima (na nuvem) ou localmente.
  - Instruções para resolução e entrega dos laboratórios.

Perguntas?

Obrigado!

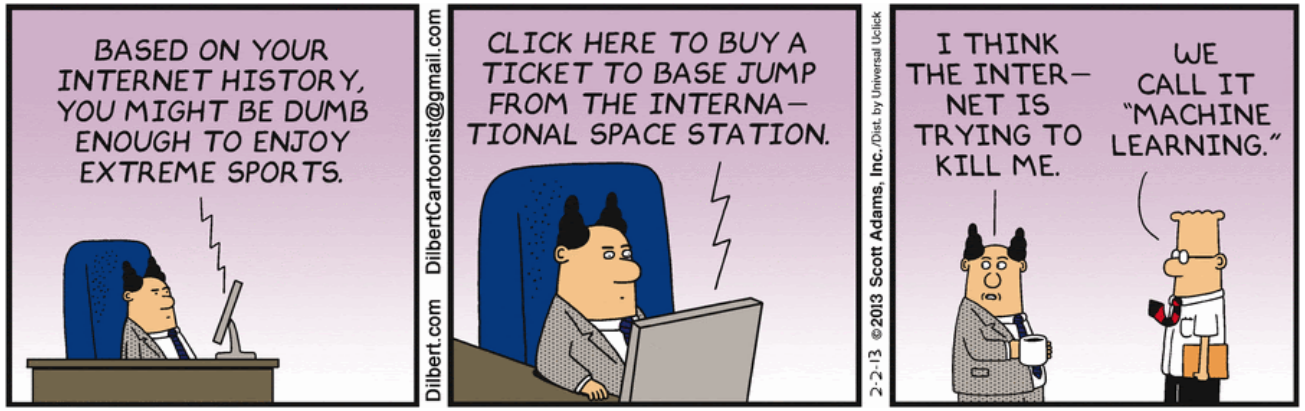
BASED ON YOUR INTERNET HISTORY, YOU MIGHT BE DUMB ENOUGH TO ENJOY EXTREME SPORTS.
Dilbert.com DilbertCartoonist@gmail.com
CLICK HERE TO BUY A TICKET TO BASE JUMP FROM THE INTERNA-TIONAL SPACE STATION.
2-2-13 ©2013 Scott Adams, Inc. /Dist. by Universal Uclick
I THINK THE INTER-NET IS TRYING TO KILL ME.
WE CALL IT "MACHINE LEARNING."


OUR MACHINE LEARNING TECHNOLOGY ALLOWS US TO TRACK CUSTOMER PREFERENCES AND USE THAT KNOWLEDGE TO MANIPULATE THEM.
Dilbert.com DilbertCartoonist@gmail.com
THAT SEEMS LIKE THE STEP THAT HAPPENS RIGHT BEFORE THE MACHINES TAKE OVER THE EARTH AND ANNI-HILATE ALL HUMANS.
1-31-13 ©2013 Scott Adams, Inc. /Dist. by Universal Uclick
THERE'S ALWAYS ONE PERSON IN EVERY CROWD WHO SAYS THAT.
NOT FOR MUCH LONGER, APPAR-ENTLY.


WE HAVE A GIGANTIC DATABASE FULL OF CUSTOMER BEHAVIOR INFORMATION.
www.dilbert.com scottadams@aol.com
EXCELLENT. WE CAN USE NON-LINEAR MATH AND DATA MINING TECHNOLOGY TO OPTIMIZE OUR RETAIL CHANNELS!
© 2000 United Feature Syndicate, Inc.
IF THAT'S THE SAME THING AS SPAM, WE'RE HAVING A GOOD MEETING HERE.

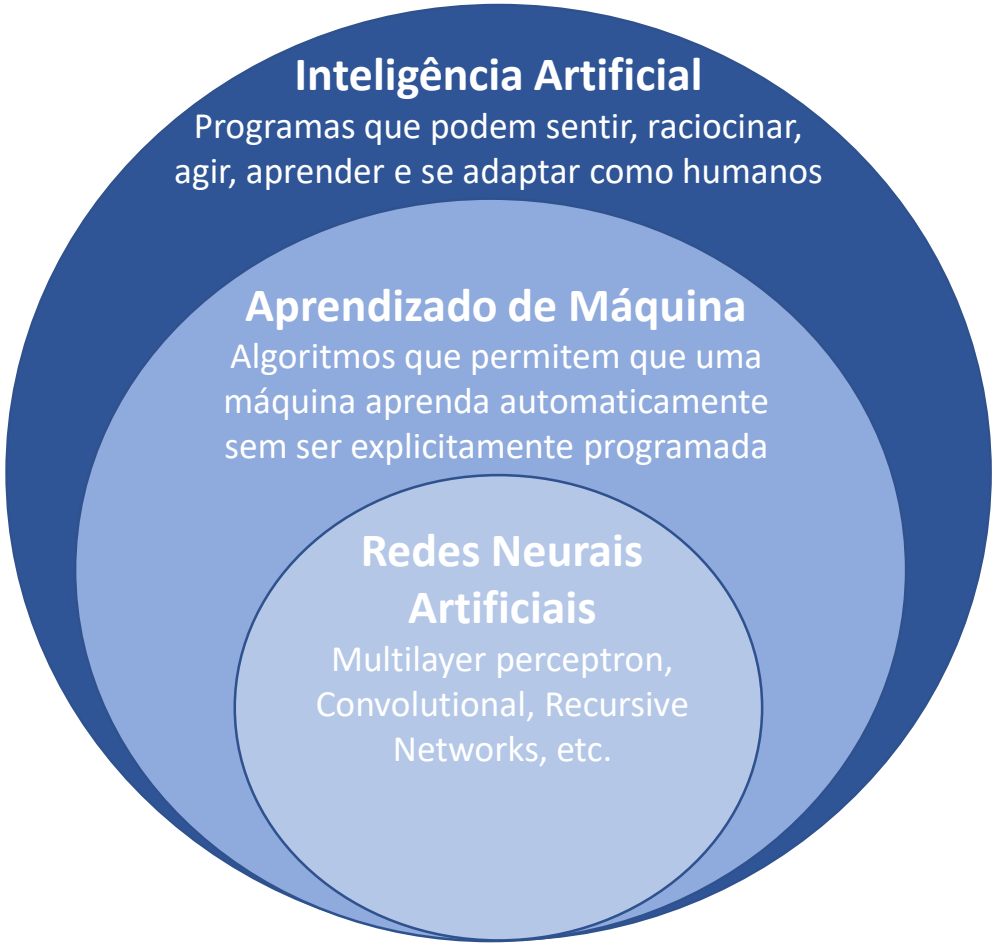
Inteligência Artificial
Programas que podem sentir, raciocinar, agir, aprender e se adaptar como humanos
Aprendizado de Máquina
Algoritmos que permitem que uma máquina aprenda automaticamente sem ser explicitamente programada
Redes Neurais Artificiais
Multilayer perceptron, Convolutional, Recursive Networks, etc.

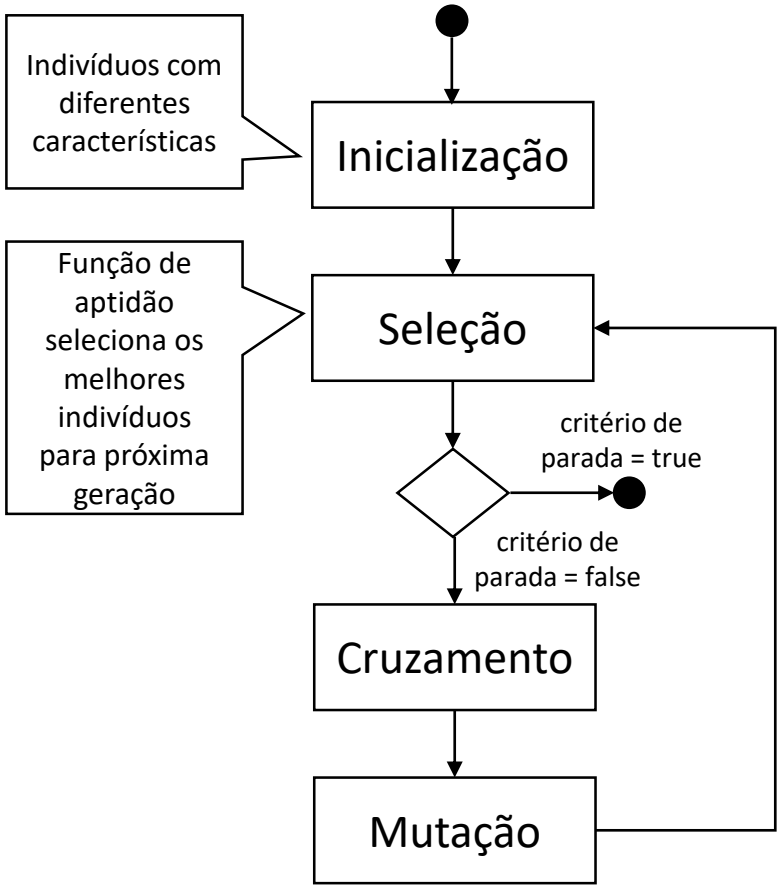
Indivíduos com diferentes características
Inicialização
Função de aptidão seleciona os melhores indivíduos para próxima geração
Seleção
critério de parada = true
critério de parada = false
Cruzamento
Mutação