


T319 - Introdução ao Aprendizado de Máquina: *Regressão Linear (Parte I)*



Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

Motivação

- **Exemplo 1:** Estimar o preço de casas.

5 quartos, 3 vagas na garagem, 1 piscina, cond. de luxo, 500 m^2



R\$ 1.000.000,00

1 quarto, sem vaga na garagem, bairro afastado, 70 m^2



R\$ 200.000,00

2 quartos, 1 vaga na garagem, centro, 200 m^2




???

- Podemos usar **regressão** para encontrar uma **relação matemática**, $h(x)$, entre o n° de quartos, n° de vagas na garagem, se há piscina, localização, área, etc. de uma casa e seu valor.
- **Objetivo:** agilizar o processo de avaliação de propriedades.

Motivação


- **Exemplo 2:** Estimar as vendas de picolés.



- Podemos usar **regressão** para encontrar um **mapeamento**, $h(x)$, entre a temperatura média de um dia e a quantidade de picolés vendidos.
- **Objetivo:** reduzir o desperdício e aumentar os lucros.


*Como podemos resolver esses problemas
de estimação?*

Regressão linear




- É um dos mais simples, antigos e usados algoritmos de aprendizado de máquina.
- Ela também é conhecida como ***aproximação de funções*** ou ***ajuste de curvas***.
 - Por exemplo, ajustar uma função aos dados de vendas de picolés.
- Vai nos dar ***intuições*** importantes para o ***entendimento*** de ***algoritmos mais complexos***, como ***classificadores*** e ***redes neurais***.

Qual o objetivo da regressão linear?



- **Objetivo:** encontrar uma função, $h(x)$, que **mapeie** as entradas, x , em uma variável de saída $\hat{y} = h(x)$, de tal forma que $h(x)$ se ajuste aos dados coletados de **forma ótima**.
 - Ótimo no sentido da **minimização da diferença** entre as previsões feitas por $h(x)$ e os valores de saída esperados, y .
- No contexto da regressão linear, nós chamamos as entradas, x , de **atributos** e os valores de saída esperados, y , de **rótulos**.
 - Vários pares de x e y formam o **conjunto de dados**, onde parte é usada para **treinamento**.


Relação matemática real entre x e y



Não existe realmente uma função por trás do comportamento de venda de picolés e a temperatura, mas podemos encontrar uma função que o aproxime usando regressão linear.

- Na grande maioria dos casos, *não existe uma função por trás da relação* entre os *atributos*, x , e os *rótulos*, y , de um conjunto de dados.
- Porém, mesmo nestes casos, podemos *modelar* a relação entre eles da *melhor forma possível* usando regressão.
- Nos casos onde essa função existe, a chamamos de *função verdadeira* ou *objetivo*, a qual é, normalmente, denotada por $f(x)$.


Dados ruidosos



OBS.: w representa o ruído contaminando os dados.

- Em geral, em problemas de regressão, lidamos com ***dados que estão sujeitos a ruído***.
- Exemplos de introdução de ruído aos dados:
 - **Previsão de preços de imóveis:** os preços de imóveis podem ser influenciados por mudanças na taxa de juros, inflação, preferências do comprador, valor sentimental, etc.
 - **Previsão de preços de ações:** os preços de ações podem ser influenciados por notícias, mudanças econômicas, eventos globais, etc.
 - **Detecção de símbolos:** os símbolos transmitidos passam através de um canal ruidoso.
- Nos nossos exemplos, modelaremos o ruído como uma variável aleatória Gaussiana.

O objetivo geral da regressão linear




OBS.: w representa o ruído contaminando os dados.

- Assim, o **objetivo geral** da regressão linear é encontrar uma função, $h(x)$ que descreva a relação entre x e y , **mesmo que os dados coletados estejam corrompidos por ruído**

$$y_{\text{observável}} = y + w.$$

- Em outras palavras, a regressão busca **capturar** um **padrão geral por trás dos dados**, **mesmo que ruidosos**, de forma a **se obter uma boa capacidade de generalização**.

Qual é o paradigma de aprendizado?



OBS.: w representa o ruído contaminando os dados.


- Dado que possuímos um **conjunto** de **atributos**, x , e os seus respectivos **rótulos**, y , **que tipo de aprendizado é realizado pela regressão linear?**

Qual é o paradigma de aprendizado?


***Aprendizado
supervisionado***

Por que linear?

$$h(x_1) = a_0 + a_1x_1 \text{ (reta)}$$



$$h(\mathbf{x}) = a_0 + a_1x_1 + a_2x_2 \text{ (plano)}$$



- A **regressão** é chamada de **linear** porque a **função aproximadora**, $\hat{y} = h(\mathbf{x})$, é **modelada** como sendo uma **combinação linear dos atributos**, $\mathbf{x}$, **em relação aos pesos**.
- Vejamos exemplos de funções aproximadoras:
 - Com **um atributo**, x_1 , podemos ter a equação de uma **reta**:

$$\hat{y} = h(x_1) = a_0 + a_1x_1.$$

- Com **dois atributos**, x_1 e x_2 , podemos ter a equação de um **plano**:

$$\hat{y} = h(\mathbf{x}) = a_0 + a_1x_1 + a_2x_2.$$

Por que linear?

- Uma **generalização** para qualquer **número de atributos**, K , é dada pela equação do **hiperplano**:

$$\hat{y} = h(\mathbf{x}) = a_0 + a_1 x_1 + \cdots + a_K x_K = a_0 + \sum_{i=1}^K a_i x_i.$$

- O **hiperplano** será o **primeiro formato** de **função aproximadora** que usaremos.
- No contexto do aprendizado de máquina, a **função aproximadora** é chamada de **modelo**.
- O **modelo** é definido pela **equação** e pelos seus **pesos**, $a_i, \forall i$.
- Existe outro formato bastante usado, os **polinômios**, o qual veremos mais adiante e que modelará **relações não lineares** entre os atributos e a saída do modelo, $\hat{y}$.

Por que linear?


- A palavra **linear** no contexto da regressão significa “**linear com relação aos pesos**” e não com relação aos **atributos**, x .
 - Em outras palavras, **a saída é uma combinação linear dos pesos**.
- Desta forma, os seguintes **modelos**, mesmo não tendo **mapeamentos lineares dos atributos na saída**, são lineares com relação aos pesos:
 - ✓ $\hat{y} = h(x) = a_0 + a_1 \log x_1 + a_2 \cos x_2$
 - ✓ $\hat{y} = h(x) = a_0 + a_1 e^{x_1}$
 - ✓ $\hat{y} = h(x) = a_0 + a_1 x_1 + a_2 x_1^2 + a_3 x_1^3$
- Exemplo de um modelo **não-linear em relação aos pesos**: $h(x) = \frac{a_1 x_1}{1 + e^{-a_1 x_2}}$.
- Em geral, não é possível aplicar algumas das técnicas de regressão que veremos em breve a modelos não-lineares em relação aos pesos.

O peso está no exponencial: se um peso aparece dentro de uma função não linear, o modelo é não linear nos pesos.

Função hipótese

- No contexto da regressão, a **função aproximadora**, $h(x)$, é chamada de **função hipótese**, pois refere-se à **explicação proposta para a relação entre as entradas**, x e a **saída esperada**, y .
 - Por exemplo, anteriormente, **hipotetizamos** que uma **reta** explicaria bem a relação entre a temperatura média de um dia e o número de picolés vendidos.
- O conjunto de todas as possíveis **funções hipótese** é chamado de **espaço de hipóteses**, H .
- Em outras palavras, é o **espaço** criado por **todas as combinações possíveis de atributos e valores dos pesos**.
- A solução que **melhor mapeia** x em y encontra-se dentro do **espaço de hipóteses** e **nosso objetivo é encontra-la**.

Espaço de hipóteses



A figura mostra algumas possíveis funções hipótese que modelam o relacionamento entre x e y .

- No exemplo da previsão da quantidade de picolés vendidos, onde usamos a **equação de uma reta** como **função hipótese**,

$$\hat{y} = h(x) = a_0 + a_1 x_1,$$

- o **(sub)espaço de hipóteses contém todas as possíveis retas** (restringimos o espaço) que podem ser usadas para mapear os dados.
- Porém, claro, **apenas uma reta é a melhor segundo o critério de minimização da diferença entre a saída do modelo e o valor esperado**.

Refinando o objetivo da regressão linear

- Agora que temos um formato definido para o **modelo**, $h(x)$, podemos refinar o objetivo da regressão um pouco mais.
- **Objetivo:** **Encontrar** os **pesos**, $a_0, a_1, \dots, a_K$, que façam com que $h(x)$ se **ajuste de forma ótima** ao conjunto de dados coletado.
 - **Ótima** no sentido em que $h(x)$ minimiza o erro entre os valores de saída do modelo, $\hat{y}$, e os esperados, y .
 - **OBS.:** No início do curso, definiremos a equação de $h(x)$ e encontraremos seus pesos.
- Na sequência, definiremos uma **função de erro** que nos ajudará a encontrar os **pesos ótimos** do modelo.
 - **Pesos ótimos:** conjunto de pesos da função hipótese, $h(x)$, que fazem com que o erro seja minimizado.

Definição formal do problema

Informação disponível

- Conjunto de N ***pares de amostras***: $\{x(i), y(i)\}$, $i = 0, \dots, N - 1$, onde
 - $x(i) = [x_1(i), \dots, x_K(i)]^T \in \mathbb{R}^{K \times 1}$ é o i -ésimo ***vetor de atributos***.
 - $y(i) \in \mathbb{R}$ é o i -ésimo ***rótulo*** referente ao vetor de atributos, $x(i)$.
- Os N pares de amostras formam o ***conjunto de dados que usaremos para treinar e validar o modelo***.

Definição formal do problema

Modelo

- Função do hiperplano

$$\hat{y}(i) = h(\mathbf{x}(i)) = \sum_{i=0}^K a_i x_i = \mathbf{a}^T \mathbf{x}(i),$$

Representação vetorial

onde $\mathbf{a} = [a_0, \dots, a_K]^T \in \mathbb{R}^{K+1 \times 1}$ é um vetor com os **pesos** da **função hipótese** e o vetor de atributos passa a ter mais um elemento $\mathbf{x}(i) = [1, x_1(i), \dots, x_K(i)]^T \in \mathbb{R}^{K+1 \times 1}$.

Observações

- a_0 é o **coeficiente linear**, ou seja, é o valor de $h(\mathbf{x})$ que intercepta o eixo das ordenadas, y , a_0 é conhecido também como **intercept** ou **bias**.
- Como a_0 não tem um **atributo** relacionado a ele, para **possibilitar a representação vetorial**, criamos um **atributo falso**, x_0 , chamado de **atributos de bias**, com valor constante igual a 1.

Definição formal do problema

Objetivo

- Encontrar o **vetor de pesos**, $\mathbf{a}$, que minimize o **erro**, dado por uma **função de erro**, $J_e(\mathbf{a})$, entre a aproximação, $\hat{y}(i)$, e o valor esperado, $y(i)$, **para todos os exemplos do conjunto de treinamento**.
- Ou seja, o **treinamento** do modelo **envolve** a **minimização de uma função de erro**.
- Isso pode ser escrito como um problema de otimização

$$\min_{\mathbf{a} \in \mathbb{R}^{K+1 \times 1}} J_e(\mathbf{a}).$$

- Portanto, para que consigamos treinar o modelo, precisamos **definir** uma **função de erro**.

Função de erro

- Existem várias possibilidades para a *função de erro*.
- Porém, em problemas de regressão, a função mais comum é a do *erro quadrático médio (EQM)*

$$J_e(\mathbf{a}) = \frac{1}{N} \sum_{i=0}^{N-1} (y(i) - \hat{y}(i))^2 = \frac{1}{N} \sum_{i=0}^{N-1} (y(i) - h(\mathbf{x}(i), \mathbf{a}))^2 ,$$

onde N é o número de amostras.

- O *EQM* nada mais é do que a *média aritmética do quadrado dos erros entre as saídas esperadas e as saídas da função hipótese*.

Função de erro

$$J_e(\mathbf{a}) = \frac{1}{N} \sum_{i=0}^{N-1} (y(i) - \hat{y}(i))^2 = \frac{1}{N} \sum_{i=0}^{N-1} (y(i) - h(\mathbf{x}(i), \mathbf{a}))^2 ,$$

- Veremos mais adiante a razão pela qual o **EQM** é utilizado.
- O vetor de pesos foi colocado em evidência na função hipótese para deixar claro que o **erro varia com o valor dos pesos**.
 - Variando os pesos, ficamos mais próximos ou mais distantes da função hipótese que minimiza o erro, i.e., da **função hipótese ótima**.
 - A variação dos pesos faz com que caminhemos no espaço de hipóteses.

Função de erro

- A **função de erro** pode ser reescrita em **formato matricial** como


$$J_e(\mathbf{a}) = \frac{1}{N} \|\mathbf{y} - \mathbf{X}\mathbf{a}\|^2,$$

onde $\mathbf{y} = [y(0), \dots, y(N-1)]^T \in \mathbb{R}^{N \times 1}$ é o **vetor de rótulos** contendo todos os N valores esperados e $\mathbf{X} = [\mathbf{x}(0), \dots, \mathbf{x}(N-1)]^T \in \mathbb{R}^{N \times K+1}$ é a **matriz de atributos** contendo todos os vetores de atributo.

- Então, para encontrarmos o **vetor de pesos**, $\mathbf{a}$, devemos **minimizar a função de erro**

$$\mathbf{a} \in \mathbb{R}^{K+1 \times 1} \min \frac{1}{N} \|\mathbf{y} - \mathbf{X}\mathbf{a}\|^2.$$

Resumo do problema da regressão




- Nosso objetivo é **treinar** um **modelo**, a partir de um **conjunto de treinamento**, que **minimize o erro de aproximação**.
- Assim, para **treinar** o modelo, precisamos encontrar **maneiras** de **ajustar seus pesos** de forma que o erro seja minimizado.
- Na sequência veremos duas formas de se encontrar o **conjunto de pesos ótimo** através da **minimização da função de erro**.

Como encontramos os pesos que minimizam a função de erro?

Como minimizar a função de erro?


Exemplo da variação de uma função de erro
qualquer com apenas um peso.



- Da disciplina de cálculo, sabemos que derivando a **função de erro** em relação ao vetor $\mathbf{a}$ e igualando a derivada à 0, nós encontramos o **ponto** (i.e., os valores dos pesos) onde a **taxa de variação da função é nula** (i.e., não cresce ou decresce mais)

$$\frac{\partial J_e(\mathbf{a})}{\partial \mathbf{a}} = \frac{\partial \|\mathbf{y} - \mathbf{X}\mathbf{a}\|^2}{\partial \mathbf{a}} = 0.$$

Como minimizar a função de erro?




A reta vermelha é **tangente** à curva no ponto P (roxo). Sua **inclinação** é dada pela **derivada parcial** da função naquele ponto.

- Após aplicarmos a derivada parcial, chegamos à seguinte equação

$$2\mathbf{a}^T \mathbf{X}^T \mathbf{X} - 2\mathbf{y}^T \mathbf{X} = 0.$$

- A resolução dessa derivada também é interpretada como sendo o **ponto**, i.e., $\mathbf{a}$, onde a **inclinação de um hiperplano tangente à função de erro é nula**.
 - Na figura temos uma **reta**, pois existe apenas **um peso**.

Como minimizar a função de erro?



- Porém, o **ponto** onde a **taxa de variação da função de erro é nula** pode ocorrer tanto em um **mínimo** quanto em um **máximo** da **função**, pois a inclinação da reta tangente é nula em ambos os casos.
- Entretanto, no nosso caso, estamos interessados no **ponto** onde a **função de erro tem o seu menor valor**.
 - Ponto de mínimo.
- É nesse ponto que encontramos os pesos que nos dão a **função hipótese ótima**.

Então, como sabemos se o ponto encontrado é um mínimo ou um máximo da função?

Como minimizar a função de erro?

- Se a *inclinação da reta tangente* é **nula** e a *derivada parcial de segunda ordem* da função for **positiva**, então o **ponto** nos dá o **mínimo** da função,

$$\frac{\partial^2 \|y - Xa\|^2}{\partial^2 a} = 2X^T X.$$

- Se a **matriz de atributos**, X , tiver **posto** igual a $K + 1$, então a matriz $X^T X$ é **positiva definida** e, portanto, o **ponto** encontrado é **o ponto de mínimo** da *função de erro*.
 - **Posto de uma matriz**: é o número de linhas ou colunas linearmente independentes da matriz.
 - Uma matriz quadrada $X^T X$ é **positiva definida** se $z^T X^T X z = \|Xz\|_2^2 > 0, \forall z \neq 0$.

Equação normal

- Então se a matriz de atributos, $\mathbf{X}$, tiver $K + 1$ *colunas linearmente independentes*, encontramos o *ponto de mínimo da função de erro* através da sua *derivada parcial*.
- Assim, resolvendo a equação da derivada parcial em função de $\mathbf{a}$, temos

$$\mathbf{a}_{\text{opt}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y},$$

onde é $\mathbf{a}_{\text{opt}} \in \mathbb{R}^{K+1 \times 1}$ é o *vetor de pesos ótimo*, que corresponde ao *ponto* mais baixo da função de erro.

Equação normal

$$\mathbf{a}_{\text{opt}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}.$$

- Essa equação é conhecida como **equação normal** e nos dá a **solução ótima** em **relação a minimização do erro quadrático médio** para um dado **sistema de equações lineares**.
- Notem que só precisamos do conjunto de amostras coletadas, $\mathbf{X}$ e $\mathbf{y}$, para encontrar o **vetor de pesos ótimo**, $\mathbf{a}_{\text{opt}}$.

Observações quanto a equação normal

1. A **equação normal** encontra uma **solução única** se e somente se a matriz, $X^T X$, for **invertível** (i.e., **não-singular**).
 - Para que a matriz seja invertível, ela deve ter **posto** igual a $K + 1$.
2. A **equação normal** só funciona para sistemas **determinados ou sobredeterminados**, ou seja, quando o número de amostras, N é **igual ou maior** do que o número de pesos (i.e., incógnitas), i.e., $N \geq K + 1$.
3. Para sistemas **subdeterminados**, ou seja, que têm menos amostras do que pesos ($N < K + 1$), a matriz $X^T X$ tem **posto** menor do que $K + 1$ e, portanto, é **singular** (i.e., a matriz $X^T X$ não é invertível).
 - Neste caso, não existe solução ou ela não é única.

Superfície de erro

$$J_e(\mathbf{a}) = \frac{1}{N} \|\mathbf{y} - \mathbf{X}\mathbf{a}\|^2$$

- Notem que o EQM é **função do vetor de pesos**, $\mathbf{a}$, pois o **conjunto de amostras é fixo (dados do problema)**.
- Ou seja, o erro varia conforme os valores dos pesos mudam.
- $J_e(\mathbf{a})$ mapeia o **vetor de pesos** no **erro correspondente**:
 - $J_e(\mathbf{a}): \mathbb{R}^{K+1 \times 1} \rightarrow \mathbb{R}$
- Se nós calcularmos o EQM para diversos valores de $\mathbf{a}$ e **plotarmos esses erros em função dos valores dos pesos**, nos obtemos uma **representação geométrica** da função de erro conhecida como **superfície de erro**.

***Que formato vocês acham que essa
superfície tem?***

Superfície de erro


- É fácil descobrir se analisarmos a equação do EQM.
- Se expandirmos $J_e(\mathbf{a})$ notamos que ela possui a forma *quadrática* com relação ao **vetor de pesos, $\mathbf{a}$** .

$$J_e(\mathbf{a}) = \frac{1}{N} \|\mathbf{y} - \mathbf{X}\mathbf{a}\|^2 = \frac{1}{N} (\mathbf{y}^T \mathbf{y} - \mathbf{y}^T \mathbf{X}\mathbf{a}^T - \mathbf{a}^T \mathbf{X}^T \mathbf{y} + \boxed{\mathbf{a}^T \mathbf{X}^T \mathbf{X} \mathbf{a}}).$$

Termo
quadrático,
 $\|\mathbf{X}\mathbf{a}\|^2$.


- O gráfico de uma função quadrática é uma *parábola*.
- No caso do EQM, essa parábola tem a *concavidade voltada para cima*, pois $\|\mathbf{X}\mathbf{a}\|^2 \geq 0$.
- O que isso significa?

Superfície de erro




- Isso significa que a **superfície de erro** tem o formato de uma **parábola convexa** (i.e., tem formato de **tigela** ou **vale**).
- A figura ao lado mostra o formato da **superfície de erro para uma função hipótese com apenas um peso**.
- Para funções hipótese com mais pesos, teremos superfícies em 3 ou mais dimensões.

Superfície de erro




- Vejam que a superfície possui **um único valor mínimo** (i.e., o **vértice** da parábola).
- Esse ponto da superfície é chamado de **ponto de mínimo**.
- Ele também é chamado de **ponto de mínimo global**, pois não há outro valor de a , que resulte em um erro menor.
- Toda **superfície convexa só possui um ponto de mínimo**, o **global**.
 - Não importando a quantidade de pesos!
- Todos os outros valores têm erro maior.

Superfície de erro




- Este é o motivo de usarmos o **erro quadrático médio** como **função de erro**, pois
 - a superfície resultante é convexa
 - e, consequentemente, **só existe um único vetor de pesos** que **minimiza a função de erro**, o $a_{\text{ótimo}}$.

Superfície de erro



- O **vetor de pesos ótimo** é encontrado
 - através da **equação normal**.
 - em alguns casos, **visualmente**, se plotarmos a superfície, pois basta **localizar seu ponto mais baixo**.
 - ou através do **gradiente descendente**, um **algoritmo de otimização iterativo** que caminha sempre em direção à parte mais baixa da superfície.

Superfície de erro



- O entendimento do **formato** e da questão da superfície ter **apenas um único ponto de mínimo** nos ajudará a entender como o **gradiente descendente** funciona.
- Na sequência, plotamos a superfície de erro para uma dada função hipótese.

Plotando a superfície de erro

- Vamos usar a seguinte **função observável**

$$y_{\text{noisy}}(n) = y(n) + w(n),$$

onde $w(n) \sim N(0, 1)$ e $y(n)$ é a **função objetivo** (ou **modelo gerador**) dada por


$$y(n) = a_1 x_1(n) + a_2 x_2(n),$$

onde $x_1(n)$ e $x_2(n) \sim U(-1, 1)$ e $a_1 = a_2 = 1$.

- Agora, suponhamos que nós quiséssemos aproximar a **função objetivo** a partir, apenas, de suas **amostras ruidosas** com a seguinte **função hipótese**


$$h(\mathbf{x}(n), \hat{\mathbf{a}}) = \hat{y}(n) = \hat{a}_1 x_1(n) + \hat{a}_2 x_2(n).$$

- Como encontraríamos os valores de $\hat{a}_1$ e $\hat{a}_2$?



OBS.: para não confundirmos com os pesos originais, a_1 e a_2 , vamos usar $\hat{a}_1$ e $\hat{a}_2$ para nos referir aos pesos da função hipótese, i.e., as estimativas/aproximações de a_1 e a_2 .

Plotando a superfície de erro




- Até o momento, conseguiríamos encontrar o **ponto de mínimo** com a **equação normal** ou **visualmente**, plotando a **superfície de erro** a partir da função do EQM

$$\begin{aligned} J_e(\hat{a}_1, \hat{a}_2) &= \frac{1}{N} \sum_{n=0}^{N-1} \left(y_{\text{noisy}}(n) - \hat{y}(n) \right)^2 \\ &= \frac{1}{N} \sum_{n=0}^{N-1} \left(y_{\text{noisy}}(n) - (\hat{a}_1 x_1(n) + \hat{a}_2 x_2(n)) \right)^2. \end{aligned}$$


e **procurando por sua parte mais baixa**.

Plotando a superfície de erro



- Os valores de erro, $J_e(\hat{a}_1, \hat{a}_2)$, para plotarmos a **superfície de erro** são obtidos variando-se $\hat{a}_1$ e $\hat{a}_2$ na equação do EQM.
- Para este exemplo, onde temos dois atributos, a **superfície de erro** é **representada por uma figura em 3 dimensões**, onde cada par de valores $\hat{a}_1$ e $\hat{a}_2$ corresponde a um erro, $J_e(\hat{a}_1, \hat{a}_2)$.


Plotando a superfície de erro



- Devido a superfície ser **convexa**, temos apenas **um ponto de mínimo**, o **mínimo global**.
- O **mínimo global** é ponto mais baixo da superfície e nos dá a solução ótima.
- **Observações**
 - Só conseguimos encontrar o ponto de mínimo de **forma visual** se tivermos funções hipóteses com até 2 atributos.
 - Além disso, é uma **solução com altíssima complexidade computacional**, pois usa a força bruta para encontrar o ponto ótimo.
 - Assim, em geral, usamos a forma fechada ou iterativa (gradiente descendente).

Plotando a superfície de contorno

- Outra figura importante que plotamos a partir dos resultados obtidos para plotar a superfície de erro é chamada de **superfície de contorno**.
- Uma superfície de contorno contém várias **linhas de contorno**.
 - Uma **linha de contorno** é uma **curva ao longo da qual uma função tem um valor constante**.
- Na superfície de erro, cada linha indica uma curva ao longo da qual o **erro é constante**.
- Ou seja, **qualquer par de valores $\hat{a}_1$ e $\hat{a}_2$ ao longo de uma mesma curva terá o mesmo valor de erro**.



***Porém, nem tudo são flores com a
equação normal...***

Desvantagens da equação normal


- **Alta complexidade computacional:** a solução da *equação normal* envolve o *cálculo da inversa* de $X^T X$.
- Esse cálculo tem complexidade computacional aproximadamente cúbica, $O(K^3)$, onde K é o número de atributos.
 - “Big O” é uma notação usada para analisar como o *tempo de execução de um algoritmo cresce à medida que o número de entradas aumenta*.
 - **Exemplo:** Se o número de *atributos*, K , passar de 1 para 2, o tempo para cálculo aumenta em aproximadamente $2^3 = 8$ vezes.
- Alguns conjuntos de dados podem ter centenas ou até milhares de atributos!
 - **House Prices** é um dataset com informações de casas que possui 79 atributos.
 - **ImageNet** é um dataset com imagens, onde cada imagem tem em média $256 \times 256 = 65536$ *pixels* e cada *pixel* é considerado um atributo.

Desvantagens da equação normal

- Além disso, dependendo do número de ***exemplos do conjunto de treinamento***, N , e de ***atributos***, x , a matriz de atributos, X , pode se tornar ***muito grande***.
- Consequentemente, a inversão de matrizes e os cálculos associados à equação normal podem ***consumir muita CPU e memória***.
 - O que pode ser um limitante para dispositivos com recursos restritos (e.g., IoT).
- Adicionalmente, para irmos ***além dos modelos lineares*** (i.e., modelos não-lineares como classificadores e redes neurais) precisamos lidar com o fato de que ***nem sempre existem formas fechadas*** como a ***equação normal***.
- **Portanto, a equação normal não é escalonável e muito menos flexível!**


***Então o que pode ser feito para
encontramos a solução ótima?***

Abordagens iterativas de otimização



- Podemos usar um *algoritmo de otimização iterativo*, chamado de *gradiente descendente (GD)*.
- Ele tem *complexidade menor e ajustável* e é *flexível* o suficiente para trabalhar com modelos lineares e não lineares.

Abordagens iterativas de otimização






- Ele é *inicializado com pesos aleatórios*, i.e., em um ponto qualquer da superfície de erro.
- E, a *cada iteração*, *refina* os valores dos pesos, ficando mais e mais próximo do *ponto de mínimo*.
- Em resumo, o GD “*procura*” *iterativamente*, a partir de um ponto inicial, o *ponto mais baixo da superfície de erro*, i.e., o ponto de mínimo.
 - No caso do EQM, ele busca o mínimo global.

Tarefas

- **Quiz:** “*T319 - Quiz - Regressão: Parte I*” que se encontra no MS Teams.
- **Exercício Prático:** [**Laboratório #2**](#).
 - Pode ser acessado através do link acima (Google Colab) ou no GitHub.
 - Vídeo explicando o laboratório: Arquivos -> Recordings -> Laboratório #2
 - Se atentem aos prazos de entrega.
 - [Instruções para resolução e entrega dos laboratórios](#).

Obrigado!



Albert Einstein: Insanity Is Doing
the Same Thing Over and Over Again
and Expecting Different Results

Machine learning:



