T319 - Introdução ao Aprendizado de Máquina: *Regressão Linear (Parte I)*

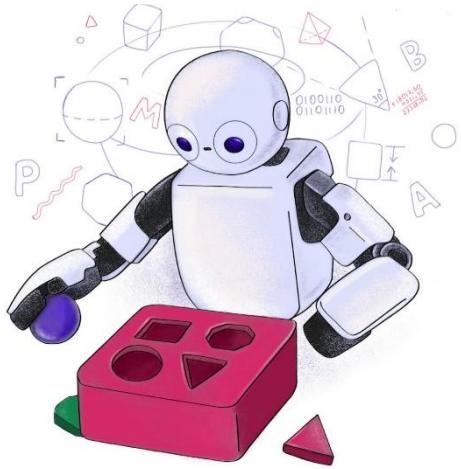

Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

Motivação

- **Exemplo 1**: Estimar o preço de casas.

5 quartos, 3 vagas na garagem, 1 piscina, cond. de luxo, 500 m^2

R$ 1.000.000,00

1 quarto, sem vaga na garagem, bairro afastado, 70 m^2

R$ 200.000,00

2 quartos, 1 vaga na garagem, centro, 200 m^2

???

- Podemos usar ***regressão*** para encontrar uma ***relação matemática***, $h(\boldsymbol{x})$, entre o n° de quartos, n° de vagas na garagem, se tem piscina, localização, área, etc. de uma casa e seu valor.
- **Objetivo**: agilizar o processo de avaliação de propriedades.

Motivação

- **Exemplo 2**: Estimar as vendas de picolés.

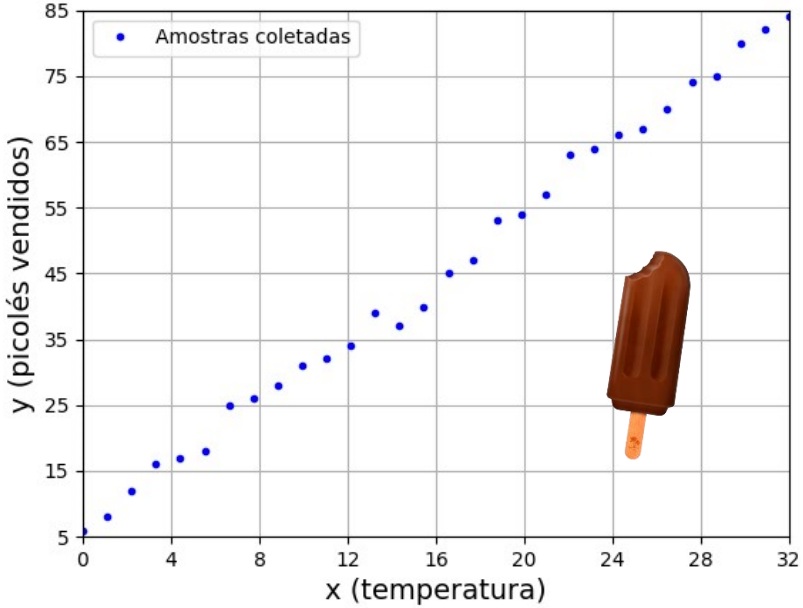

- Podemos usar ***regressão*** para encontrar um ***mapeamento***, $h(\boldsymbol{x})$, entre a temperatura média de um dia e a quantidade de picolés vendidos.
- **Objetivo**: reduzir o desperdício e aumentar os lucros.

Como podemos resolver esses problemas de estimação?

Regressão linear

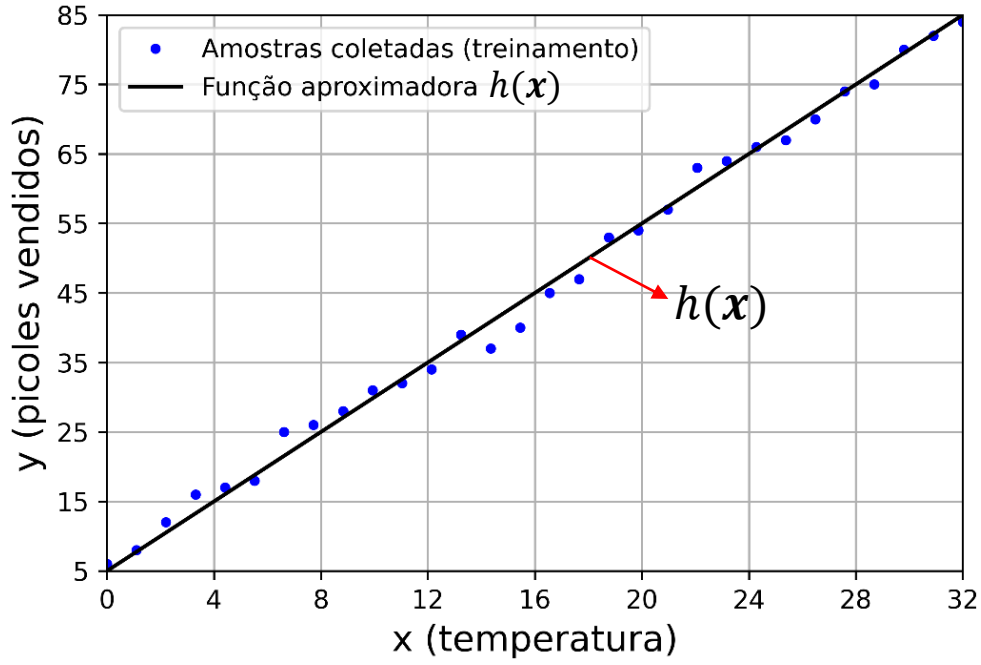

- É um dos mais simples, antigos e usados algoritmos de aprendizado de máquina.
- Ela também é conhecida como ***aproximação de funções*** ou ***ajuste de curvas***.
  - Por exemplo, ajustar uma função aos dados de vendas de picolés.
- Vai nos dar ***intuições*** importantes para o ***entendimento*** de ***algoritmos mais complexos***, como ***classificadores*** e ***redes neurais***.

Qual o objetivo da regressão linear?

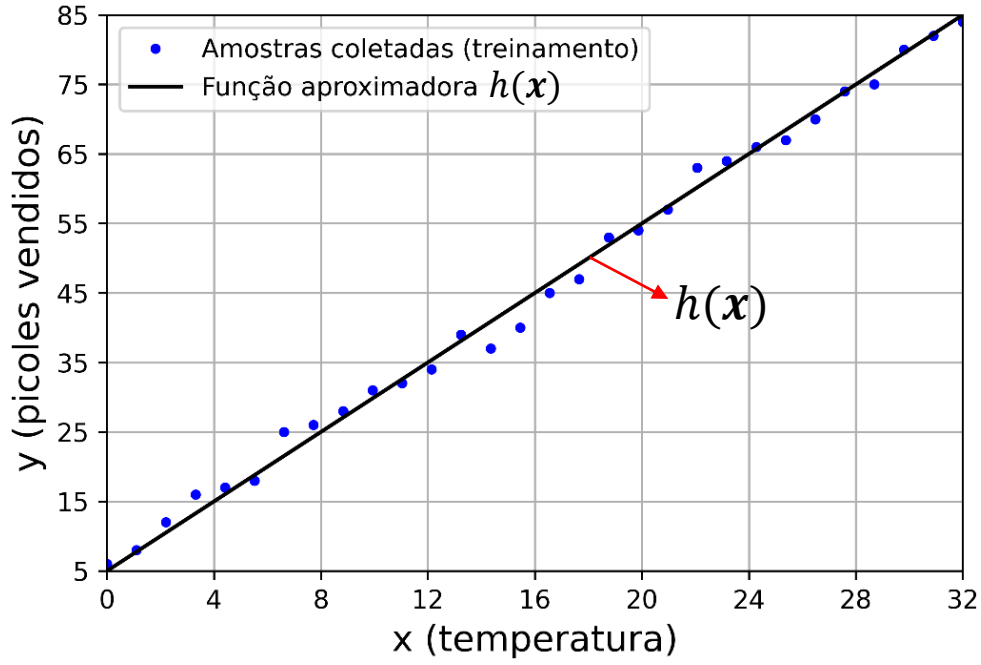

- **Objetivo**: encontrar uma função, $h(\boldsymbol{x})$, que ***mapeie*** as entradas, $\boldsymbol{x}$, em uma variável de saída $\hat{y} = h(\boldsymbol{x})$, de tal forma que $h(\boldsymbol{x})$ se ajuste aos dados coletados de ***forma ótima***.
  - Ótimo no sentido da ***minimização da diferença*** entre as predições feitas por $h(\boldsymbol{x})$ e os valores de saída esperados, y.
- No contexto da regressão linear, nós chamamos as entradas, $\boldsymbol{x}$, de ***atributos*** e os valores de saída esperados, y, de ***rótulos***.
  - Vários pares de $\boldsymbol{x}$ e y formam o ***conjunto de dados***, onde parte é usada para ***treinamento***.

Relação matemática real entre $\boldsymbol{x}$ e y

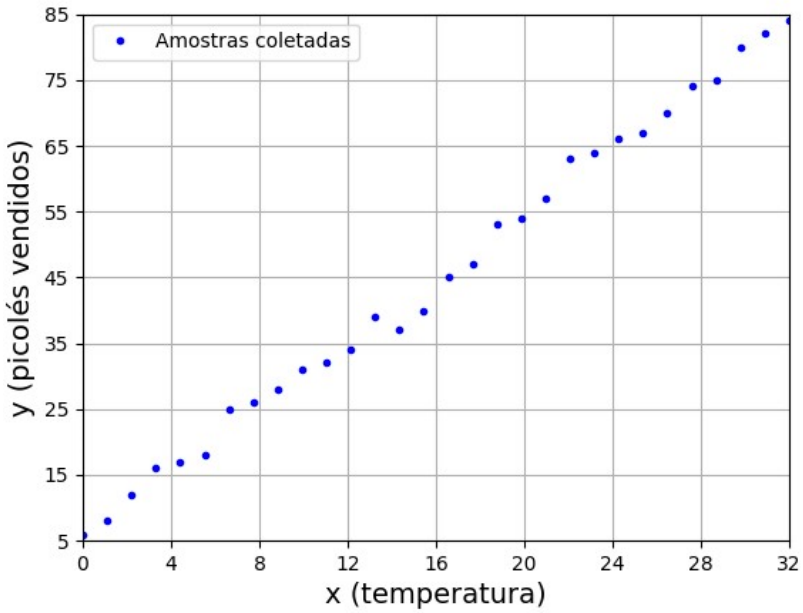

Não existe realmente uma função por trás do comportamento de venda de picolés e a temperatura, mas podemos encontrar uma função que o aproxime usando regressão.

- Na grande maioria dos casos, ***não existe uma função por trás da relação*** entre os ***atributos***, $\boldsymbol{x}$, e os ***rótulos***, y, de um conjunto de dados.
- Porém, mesmo nestes casos, podemos ***modelar*** a relação entre eles da ***melhor forma possível*** usando regressão.
- Nos casos onde essa função existe, a chamamos de ***função verdadeira*** ou ***objetivo***, a qual é, normalmente, denotada por $f(\boldsymbol{x})$.

Dados ruidosos

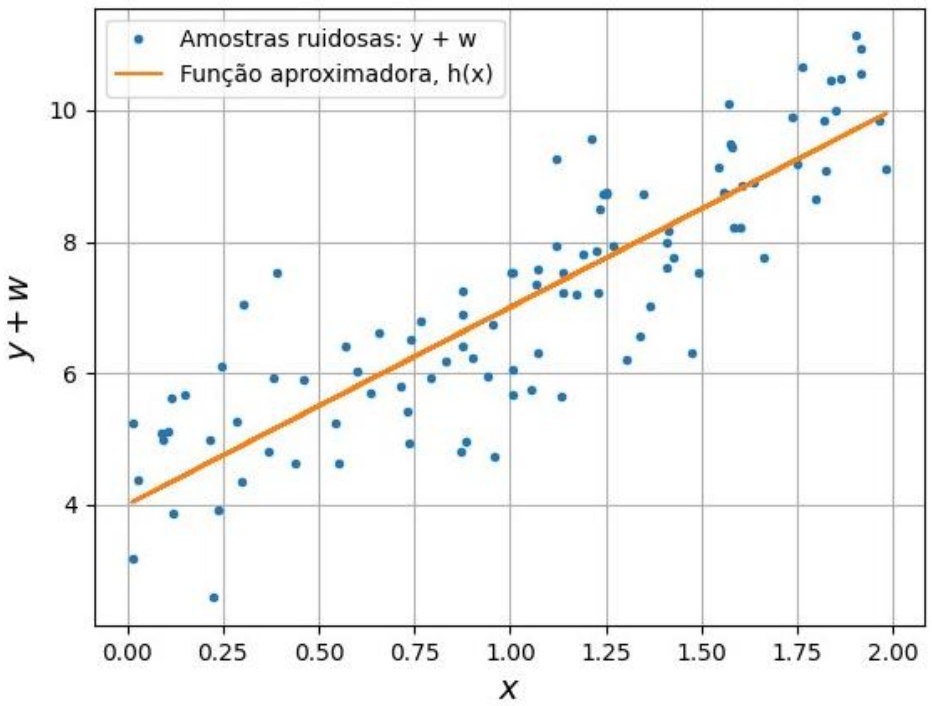

OBS.: w representa o ruído contaminando os dados.

- Em geral, em problemas de regressão, lidamos com ***dados que estão sujeitos a ruído***.
- Exemplos de introdução de ruído aos dados:
  - **Previsão de preços de imóveis:** os preços de imóveis podem ser influenciados por mudanças na taxa de juros, inflação, preferências do comprador, valor sentimental, etc.
  - **Previsão de preços de ações:** os preços de ações podem ser influenciados por notícias, mudanças econômicas, eventos globais, etc.
  - **Detecção de símbolos**: os símbolos transmitidos passam através de um canal ruidoso.
- Nos nossos exemplos, modelaremos o ruído como uma variável aleatória Gaussiana.

O objetivo geral da regressão linear

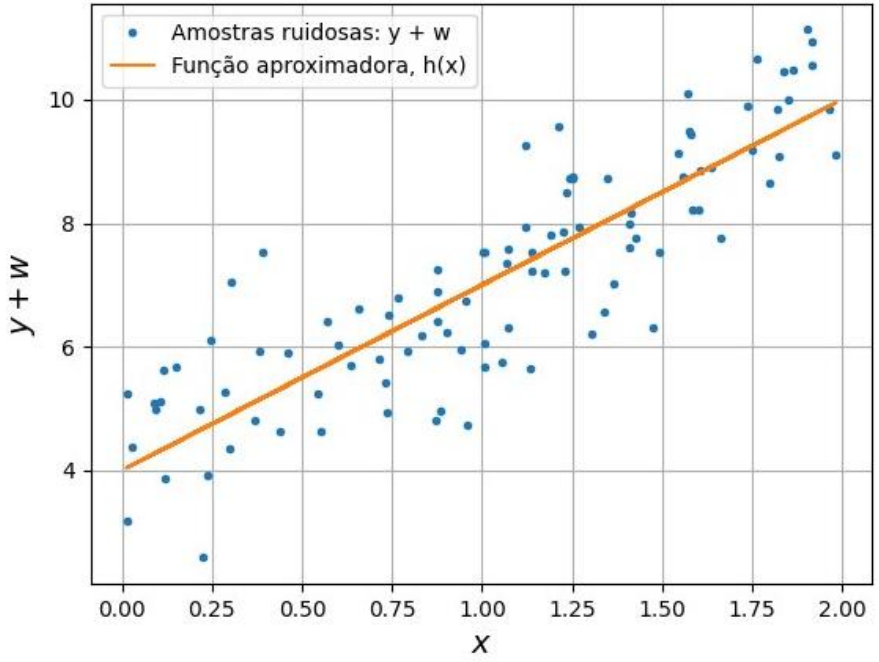

OBS.: w representa o ruído contaminando os dados.

- Assim, o ***objetivo geral*** da regressão linear é encontrar uma função, $h(\boldsymbol{x})$ que descreva a relação entre $\boldsymbol{x}$ e y, ***mesmo que os dados coletados estejam corrompidos por ruído***

$$y_{\text{observável}} = y + w.$$

- Em outras palavras, a regressão busca ***capturar*** um ***padrão geral por trás dos dados, mesmo que ruidosos, de forma a se obter uma boa capacidade de generalização***.

Qual é o paradigma de aprendizado?

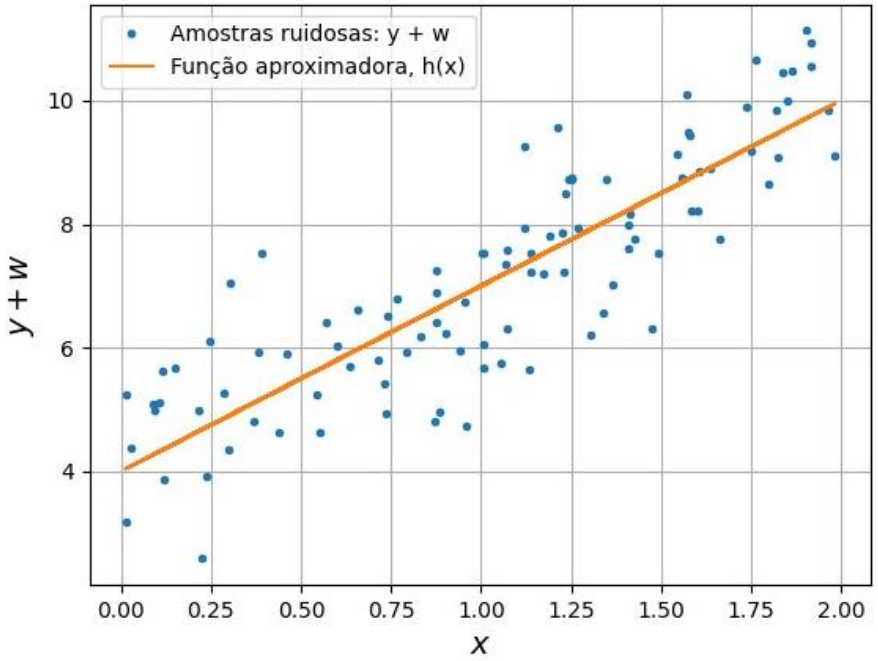

OBS.: w representa o ruído contaminando os dados.

- Dado que possuímos um ***conjunto*** de ***atributos***, $\boldsymbol{x}$, e os seus respectivos ***rótulos***, y, ***que tipo de aprendizado é realizado pela regressão linear?***

Qual é o paradigma de aprendizado?

Aprendizado supervisionado

Por que linear?

$h(x_1) = a_0 + a_1 x_1$ (reta)

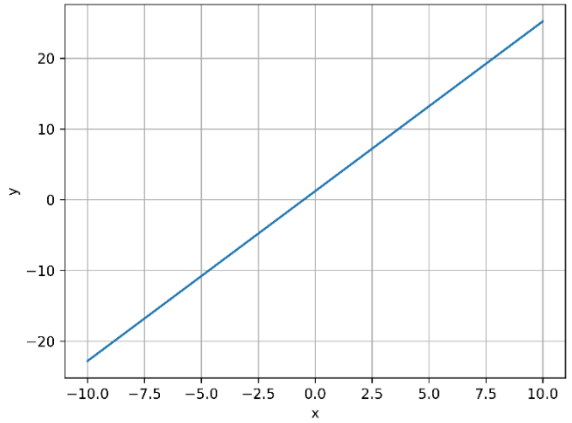

$h(\boldsymbol{x}) = a_0 + a_1 x_1 + a_2 x_2$ (plano)

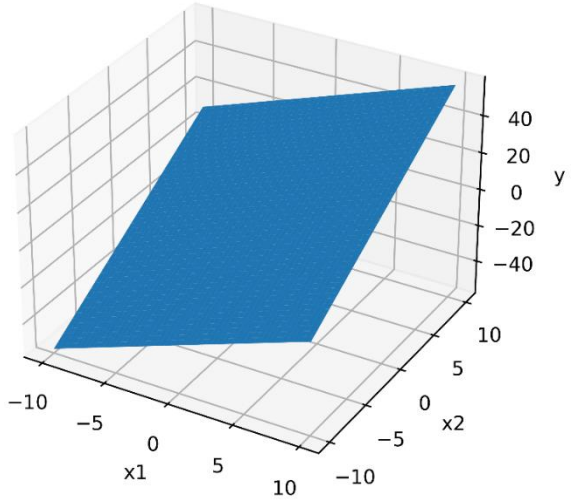

- A ***regressão*** é chamada de ***linear*** porque a saída da ***função aproximadora***, $\hat{y} = h(\boldsymbol{x})$, é ***modelada*** como sendo uma ***combinação linear dos atributos***, $\boldsymbol{x}$, ***em relação aos pesos***.
- Vejamos exemplos de funções aproximadoras:
  - Com ***um atributo***, x_1, podemos ter a equação de uma ***reta***:

$$\hat{y} = h(\boldsymbol{x}) = a_0 + a_1 x_1.$$

  - Com ***dois atributos***, x_1 e x_2, podemos ter a equação de um ***plano***:

$$\hat{y} = h(\boldsymbol{x}) = a_0 + a_1 x_1 + a_2 x_2.$$

Por que linear?

- Uma ***generalização*** para qualquer ***número de atributos***, K, é dada pela equação do ***hiperplano***:

$$\hat{y} = h(\boldsymbol{x}) = a_0 + a_1 x_1 + \cdots + a_K x_K = a_0 + \sum_{i=1}^{K} a_i \, x_i.$$

- O ***hiperplano*** será o ***primeiro formato*** de ***função aproximadora*** que usaremos.
- No contexto do aprendizado de máquina, a ***função aproximadora*** é chamada de ***modelo***.
- O ***modelo*** é definido pela ***equação*** e pelos seus ***pesos***, $a_i, \forall i$.
- Existe outro formato bastante usado, os ***polinômios***, o qual veremos mais adiante e que modelará ***relações não lineares*** entre os atributos e a saída do modelo, $\hat{y}$.

Por que linear?

- A palavra ***linear*** no contexto da regressão significa "***linear com relação aos pesos***" e não com relação aos ***atributos***, $\boldsymbol{x}$.
  - Em outras palavras, a ***relação entre os pesos e a saída é linear***.
- Desta forma, os seguintes ***modelos***, mesmo não tendo ***mapeamentos lineares dos atributos na saída***, são lineares com relação aos pesos:

  ✓ $\hat{y} = h(\boldsymbol{x}) = a_0 + a_1 \log x_1 + a_2 \cos x_2$

  ✓ $\hat{y} = h(\boldsymbol{x}) = a_0 + a_1 e^{x_1}$

  ✓ $\hat{y} = h(\boldsymbol{x}) = a_0 + a_1 x_1 + a_2 x_1^2 + a_3 x_1^3$

Os pesos estão no denominador e no expoente

- Exemplo de um modelo ***não-linear com relação aos pesos***: $h(\boldsymbol{x}) = \dfrac{a_1 x_1}{1 + e^{-a_1 x_2}}$.
- Em geral, não é possível aplicar algumas das técnicas de regressão que veremos em breve a modelos não-lineares em relação aos pesos.

Função hipótese

- No contexto da regressão, a ***função aproximadora***, $h(\boldsymbol{x})$, é chamada de ***função hipótese***, pois refere-se à ***explicação proposta para a relação entre as entradas***, $\boldsymbol{x}$ e a ***saída esperada***, y.
  - Por exemplo, anteriormente, ***hipotetizamos*** que uma ***reta*** explicaria bem a relação entre a temperatura média de um dia e o número de picolés vendidos.
- O conjunto de todas as possíveis ***funções hipótese*** é chamado de ***espaço de hipóteses,*** $\boldsymbol{H}$.
- Em outras palavras, é o ***espaço*** criado por ***todas as combinações possíveis de atributos e valores dos pesos***.
- A solução que ***melhor mapeia*** $\boldsymbol{x}$ em y encontra-se dentro do ***espaço de hipóteses*** e ***nosso objetivo é encontra-la***.

Espaço de hipóteses

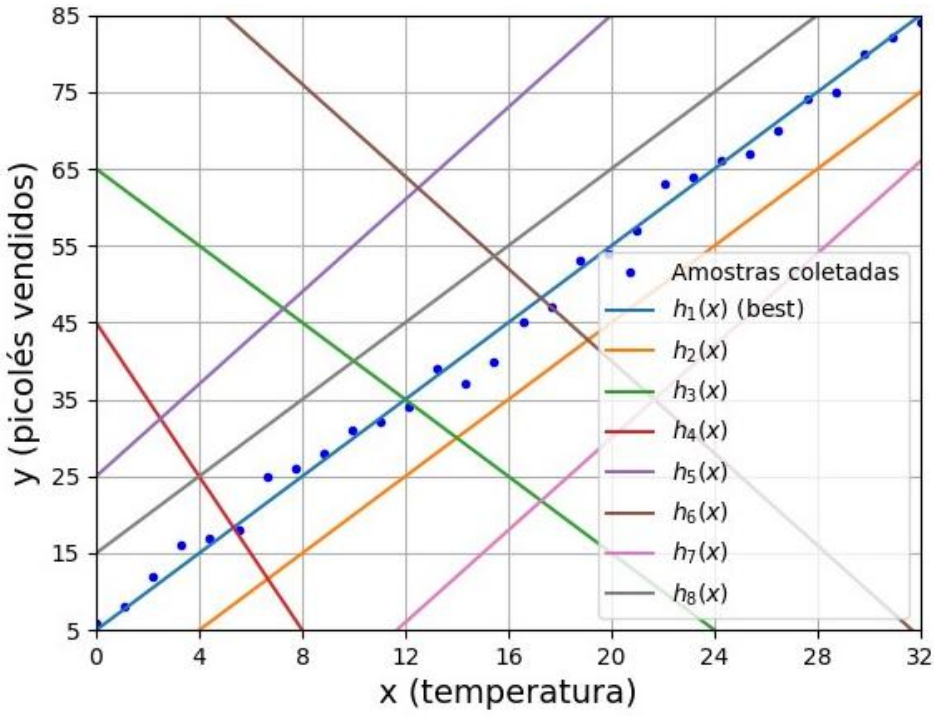

A figura mostra algumas possíveis funções hipótese que modelam o relacionamento entre x e y.

- No exemplo da previsão da quantidade de picolés vendidos, onde usamos a ***equação de uma reta*** como ***função hipótese***,

$$\hat{y} = h(\boldsymbol{x}) = a_0 + a_1 x_1,$$

o ***(sub)espaço de hipóteses contém todas as possíveis retas*** (restringimos o espaço) que podem ser usadas para mapear os dados.

- Porém, claro, ***apenas uma reta é a melhor segundo o critério de minimização da diferença entre a saída do modelo e o valor esperado***.

Refinando o objetivo da regressão linear

- Agora que temos um formato definido para o ***modelo***, $h(\boldsymbol{x})$, podemos refinar o objetivo da regressão um pouco mais.
- **Objetivo**: ***Encontrar*** os ***pesos***, a_0, a_1, …, a_K, que façam com que $h(\boldsymbol{x})$ se ***ajuste de forma ótima*** ao conjunto de dados coletado.
  - ***Ótima*** no sentido em que $h(\boldsymbol{x})$ minimiza o erro entre os valores de saída do modelo, $\hat{y}$, e os esperados, y.
- Na sequência, definiremos uma ***função de erro*** que nos ajudará a encontrar os ***pesos ótimos*** do modelo.
  - **Pesos ótimos**: conjunto de pesos da função hipótese, $h(\boldsymbol{x})$, que fazem com que o erro seja minimizado.

Definição formal do problema

Informação disponível

- Conjunto de N ***pares de amostras***: $\{\boldsymbol{x}(i), y(i)\}$, $i = 0, \dots, N-1$, onde
  - $\boldsymbol{x}(i) = [1, x_1(i), \dots, x_K(i)]^T \in \mathbb{R}^{K+1\times 1}$ é o i-ésimo ***vetor de atributos***.
  - $y(i) \in \mathbb{R}$ é o i-ésimo ***rótulo*** referente ao vetor de atributos, $\boldsymbol{x}(i)$.
- As N amostras formam o ***conjunto de dados que usaremos para treinar e validar o modelo***.
- Notem que o ***vetor de atributos*** tem sempre um elemento a mais do que o número real de atributos, K.
- Esse elemento, o primeiro do vetor, tem valor constante igual a 1 para que possamos representar o ***modelo*** em ***formato vetorial***.

Definição formal do problema

Modelo

- Função do hiperplano

Representação vetorial

$$\hat{y}(i) = h(\boldsymbol{x}(i)) = \sum_{i=0}^{K} a_i\, x_i = \boxed{\boldsymbol{a}^T \boldsymbol{x}(i)},$$

onde $\boldsymbol{a} = [a_0, \dots, a_K]^T \in \mathbb{R}^{K+1\times 1}$ é um vetor contendo os ***pesos*** da ***função hipótese***.

Observações

- a_0 é o ***coeficiente linear***, ou seja, é o valor de $h(\boldsymbol{x})$ que intercepta o eixo das ordenadas, y, a_0 é conhecido também como ***intercept*** ou ***bias***.
- Como a_0 não tem um ***atributo*** relacionado a ele, para ***facilitar a representação vetorial***, criamos um ***atributo falso***, x_0, chamado de ***atributos de bias***, com valor constante igual a $x_0 = 1$.

Definição formal do problema

Objetivo

- Encontrar o ***vetor de pesos***, $\boldsymbol{a}$, que minimize o ***erro***, dado por uma ***função de erro***, $J_e(\boldsymbol{a})$, entre a aproximação, $\hat{y}(i)$, e o valor esperado, $y(i)$, ***para todos os exemplos do conjunto de treinamento***.
- Ou seja, o ***treinamento*** do modelo ***envolve*** a ***minimização de uma função de erro***.
- Isso pode ser escrito como um problema de otimização

$$\min_{\boldsymbol{a} \in \mathbb{R}^{K+1\times 1}} J_e(\boldsymbol{a}).$$

- Portanto, para que consigamos treinar o modelo, precisamos ***definir*** uma ***função de erro***.

Função de erro

- Existem várias possibilidades para a ***função de erro***.
- Porém, em problemas de regressão, a função mais comum é a do ***erro quadrático médio (EQM)***

$$J_e(\boldsymbol{a}) = \frac{1}{N}\sum_{i=0}^{N-1}(y(i) - \hat{y}(i))^2 = \frac{1}{N}\sum_{i=0}^{N-1}\big(y(i) - h(\boldsymbol{x}(i), \boldsymbol{a})\big)^2,$$

onde N é o número de amostras.

- O ***EQM*** nada mais é do que a ***média aritmética do quadrado dos erros entre as saídas esperadas e as saídas da função hipótese***.

Função de erro

$$J_e(\boldsymbol{a}) = \frac{1}{N}\sum_{i=0}^{N-1}(y(i) - \hat{y}(i))^2 = \frac{1}{N}\sum_{i=0}^{N-1}\big(y(i) - h(\boldsymbol{x}(i), \boldsymbol{a})\big)^2,$$

- Veremos mais adiante a razão pela qual o ***EQM*** é utilizado.
- O vetor de pesos foi colocado em evidência na função hipótese para deixar claro que o ***erro varia com o valor dos pesos***.
  - Variando os pesos, ficamos mais próximos ou mais distantes da função hipótese que minimiza o erro, i.e., da ***função hipótese ótima***.
  - A variação dos pesos faz com que caminhemos no espaço de hipóteses.

Função de erro

- A ***função de erro*** pode ser reescrita em ***formato matricial*** como

$$J_e(\boldsymbol{a}) = \frac{1}{N}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{a}\|^2,$$

onde $\boldsymbol{y} = [y(0), \dots, y(N-1)]^T \in \mathbb{R}^{N\times 1}$ é o ***vetor de rótulos*** contendo todos os N valores esperados e $\boldsymbol{X} = [\boldsymbol{x}(0), \dots, \boldsymbol{x}(N-1)]^T \in \mathbb{R}^{N\times K+1}$ é a ***matriz de atributos*** contendo todos os vetores de atributo.

- Então, para encontrarmos o ***vetor de pesos***, $\boldsymbol{a}$, devemos ***minimizar a função de erro***

$$\min_{\boldsymbol{a} \in \mathbb{R}^{K+1\times 1}} \frac{1}{N}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{a}\|^2 .$$

Resumo do problema da regressão

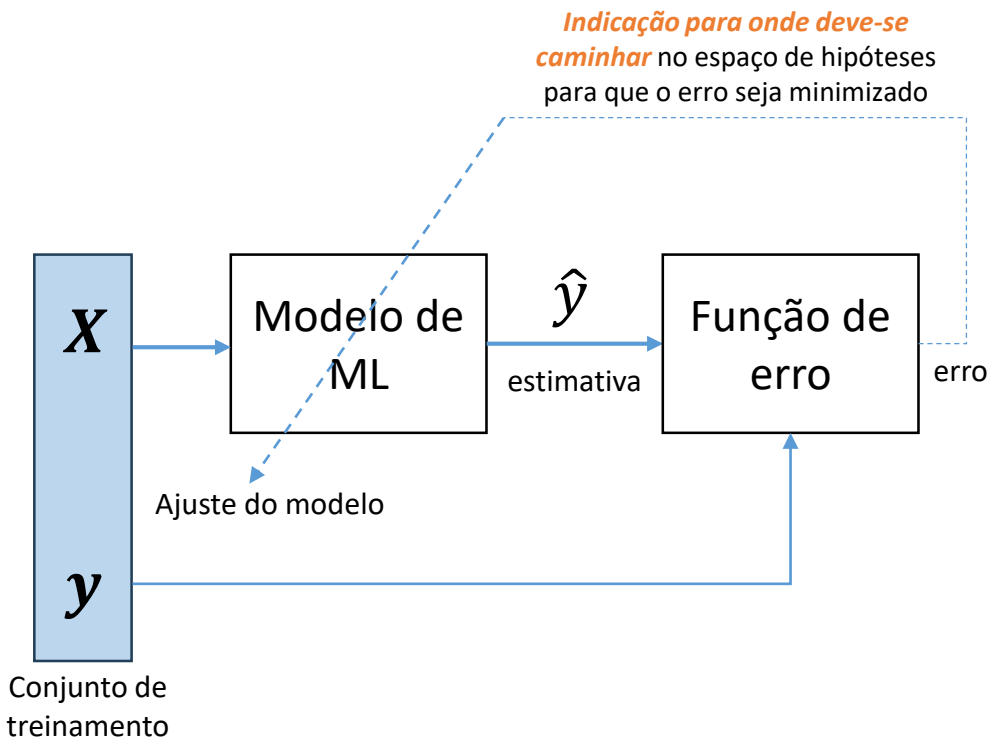

- Nosso objetivo é ***treinar*** um ***modelo***, a partir de um ***conjunto de treinamento***, que ***minimize o erro de aproximação***.
- Assim, para ***treinar*** o modelo, precisamos encontrar ***maneiras*** de ***ajustar seus pesos*** de forma que o erro seja minimizado.
- Na sequência veremos duas formas de se encontrar o ***conjunto de pesos ótimo*** através da ***minimização da função de erro***.

Como encontramos os pesos que minimizam a função de erro?

Como minimizar a função de erro?

Exemplo da variação de uma função de erro qualquer com apenas um peso.

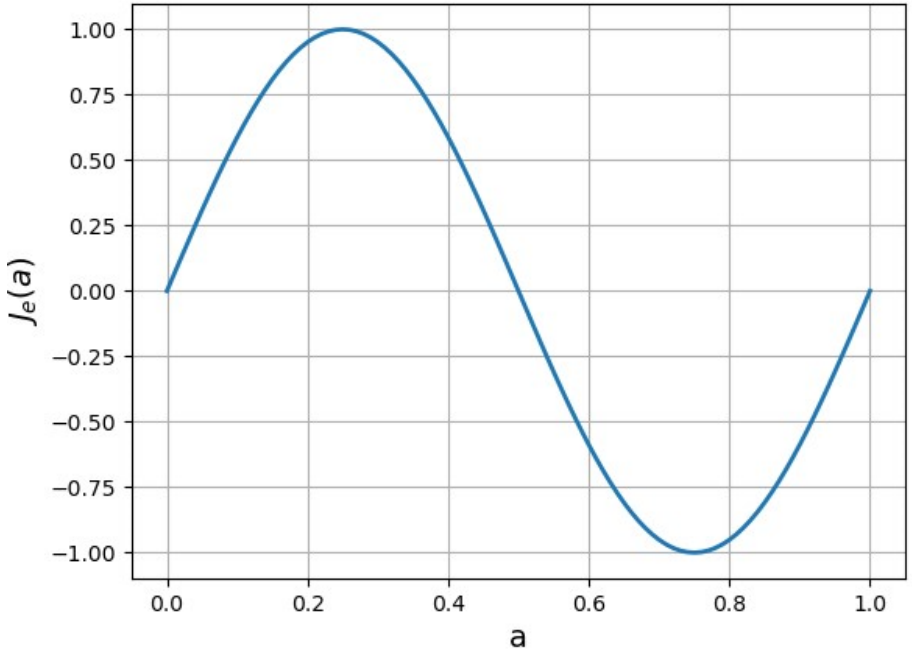

- Da disciplina de cálculo, sabemos que derivando a ***função de erro*** em relação ao vetor $\boldsymbol{a}$ e igualando a derivada à 0, nós encontramos o ***ponto*** (i.e., os valores dos pesos) onde a ***taxa de variação da função é nula*** (i.e., não cresce ou decresce mais)

$$\frac{\partial J_e(\boldsymbol{a})}{\partial \boldsymbol{a}} = \frac{\partial \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{a}\|^2}{\partial \boldsymbol{a}} = 0.$$

Como minimizar a função de erro?

Exemplo da variação da função de erro com apenas um peso.

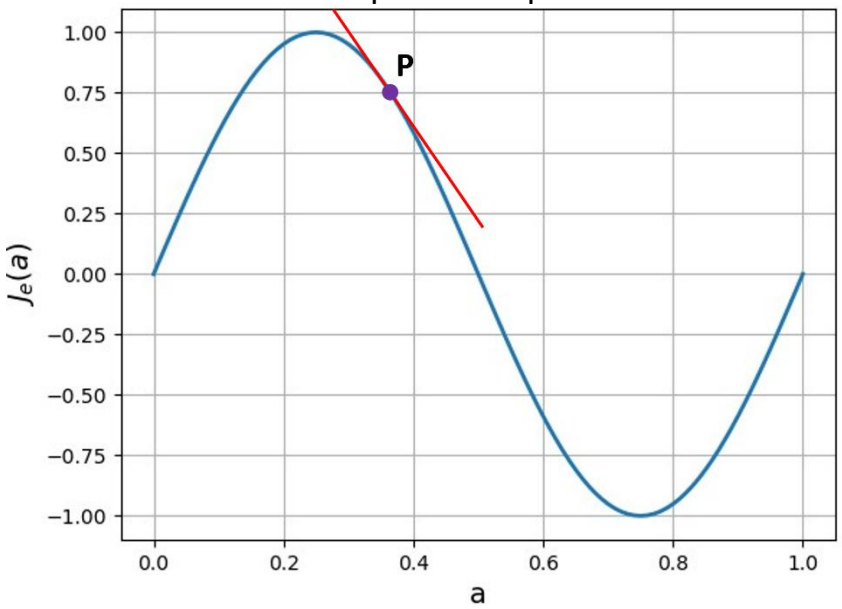

A reta vermelha é **tangente** à curva no ponto **P** (roxo). Sua **inclinação** é dada pela **derivada parcial** da função naquele ponto.

- Após aplicarmos a derivada parcial, chegamos à seguinte equação

$$2\boldsymbol{a}^T\boldsymbol{X}^T\boldsymbol{X} - 2\boldsymbol{y}^T\boldsymbol{X} = 0.$$

- A resolução dessa derivada também é interpretada como sendo o ***ponto*** onde a ***inclinação de um hiperplano tangente à função de erro é nula***.
  - Na figura temos uma ***reta***, pois existe apenas ***um peso***.

Como minimizar a função de erro?

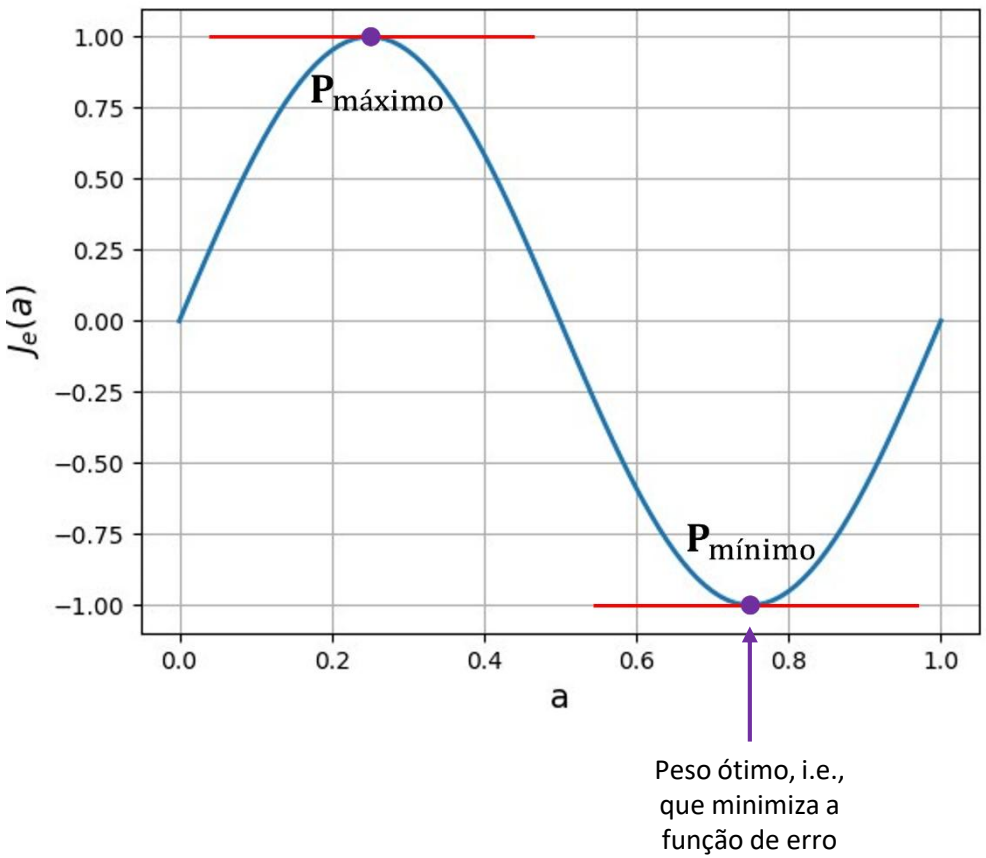

- Porém, o ***ponto*** onde a ***taxa de variação da função de erro é nula*** pode ocorrer tanto em um ***mínimo*** quanto em um ***máximo*** da ***função***, pois a inclinação da reta tangente é nula em ambos os casos.
- Entretanto, no nosso caso, estamos interessados no ***ponto*** onde a ***função de erro tem o seu menor valor***.
  - Ponto de mínimo.
- É nesse ponto que encontramos os pesos que nos dão a ***função hipótese ótima***.

Então, como sabemos se o ponto encontrado é um mínimo ou um máximo da função?

Como minimizar a função de erro?

- Se a ***inclinação da reta tangente é nula E*** a ***derivada parcial de segunda ordem*** da função for ***positiva***, então o ***ponto*** nos dá o ***mínimo*** da função,

$$\frac{\partial^2 \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{a}\|^2}{\partial^2 \boldsymbol{a}} = 2\boldsymbol{X}^T\boldsymbol{X}.$$

- Se a ***matriz de atributos***, $\boldsymbol{X}$, tiver ***posto*** igual a $K + 1$, então a matriz $\boldsymbol{X}^T\boldsymbol{X}$ é ***positiva semi-definida*** e, portanto, o ***ponto*** encontrado é ***o ponto de mínimo*** da ***função de erro***.
  - **Posto de uma matriz**: é o número de linhas ou colunas linearmente independentes da matriz.
  - Uma matriz quadrada $\boldsymbol{X}^T\boldsymbol{X}$ é ***positiva semi-definida*** se $\boldsymbol{z}^T\boldsymbol{X}^T\boldsymbol{X}\boldsymbol{z} = \|\boldsymbol{X}\boldsymbol{z}\|_2^2 \geq 0, \forall \boldsymbol{z} \neq \boldsymbol{0}$.

Equação normal

- Então se a matriz de atributos, $\boldsymbol{X}$, tiver $K+1$ ***colunas linearmente independentes*** encontramos o ***ponto de mínimo da função de erro*** através da sua ***derivada parcial***.
- Assim, resolvendo a equação da derivada parcial em função de $\boldsymbol{a}$, temos

$$\boldsymbol{a}_{\text{opt}} = (\boldsymbol{X}^T\boldsymbol{X})^{-1}\,\boldsymbol{X}^T\boldsymbol{y},$$

onde é $\boldsymbol{a}_{\text{opt}} \in \mathbb{R}^{K+1\times 1}$é o ***vetor de pesos ótimo***, que correspondente ao ***ponto*** mais baixo da função de erro.

Equação normal

$$\boldsymbol{a}_{\text{opt}} = (\boldsymbol{X}^T\boldsymbol{X})^{-1}\,\boldsymbol{X}^T\boldsymbol{y}.$$

- Essa equação é conhecida como ***equação normal*** e nos dá a ***solução ótima*** em ***relação a minimização do erro quadrático médio*** para um dado ***sistema de equações lineares***.
- Notem que só precisamos do conjunto de amostras coletadas, $\boldsymbol{X}$ e $\boldsymbol{y}$, para encontrar o ***vetor de pesos ótimo***, $\boldsymbol{a}_{\text{opt}}$.

Observações quanto a equação normal

1. A ***equação normal*** encontra uma ***solução única*** se e somente se a matriz, $\boldsymbol{X}^T\boldsymbol{X}$, for ***invertível*** (i.e., ***não-singular***).
   - Para que a matriz seja invertível, ela deve ter ***posto*** igual a $K+1$.
2. A ***equação normal*** só funciona para sistemas ***determinados ou sobredeterminados***, ou seja, quando o número de amostras, N é ***igual ou maior*** do que o número de pesos (i.e., incógnitas), i.e., $N \geq K+1$.
3. Para sistemas ***subdeterminados***, ou seja, que têm menos amostras do que pesos ($N < K+1$), a matriz $\boldsymbol{X}^T\boldsymbol{X}$ tem ***posto*** menor do que $K+1$ e, portanto, é ***singular*** (i.e., a matriz $\boldsymbol{X}^T\boldsymbol{X}$ não é invertível).
   - Neste caso, não existe solução ou ela não é única.

Exemplo: normal_equation_example1.ipynb

Superfície de erro

$$J_e(\boldsymbol{a}) = \frac{1}{N}\|\boldsymbol{y} - \boldsymbol{X}\boxed{\boldsymbol{a}}\|^2$$

- Notem que o EQM é ***função do vetor de pesos***, $\boldsymbol{a}$, pois o ***conjunto de exemplos é fixo (dado do problema)***.
- Ou seja, o erro varia conforme os valores dos pesos mudam.
- $J_e(\boldsymbol{a})$ faz o ***mapeamento*** entre o ***vetor de pesos*** e o ***erro correspondente***:
  - $J_e(\boldsymbol{a}): \mathbb{R}^{K+1\times 1} \rightarrow \mathbb{R}$
- Se nós calcularmos o EQM para diversos valores de $\boldsymbol{a}$ e ***plotarmos esses erros em função dos valores dos pesos***, nos obtemos uma superfície chamada de ***superfície de erro***.

Que formato vocês acham que essa superfície tem?

Superfície de erro

- É fácil descobrir se analisarmos a equação do EQM.
- Se expandirmos $J_e(\boldsymbol{a})$ notamos que ela possui forma ***quadrática*** com relação ao ***vetor de pesos***, $\boldsymbol{a}$.

Termo quadrático, $\|\boldsymbol{Xa}\|^2$.

$$J_e(\boldsymbol{a}) = \frac{1}{N}\|\boldsymbol{y} - \boldsymbol{Xa}\|^2 = \frac{1}{N}(\boldsymbol{y}^T\boldsymbol{y} - \boldsymbol{y}^T\boldsymbol{Xa}^T - \boldsymbol{a}^T\boldsymbol{X}^T\boldsymbol{y} + \boxed{\boldsymbol{a}^T\boldsymbol{X}^T\boldsymbol{Xa}}).$$

- O gráfico de uma função quadrática é uma ***parábola***.
- Essa parábola tem a ***concavidade voltada para cima***, pois $\|\boldsymbol{Xa}\|^2 \geq 0$.
- O que isso significa?

Superfície de erro

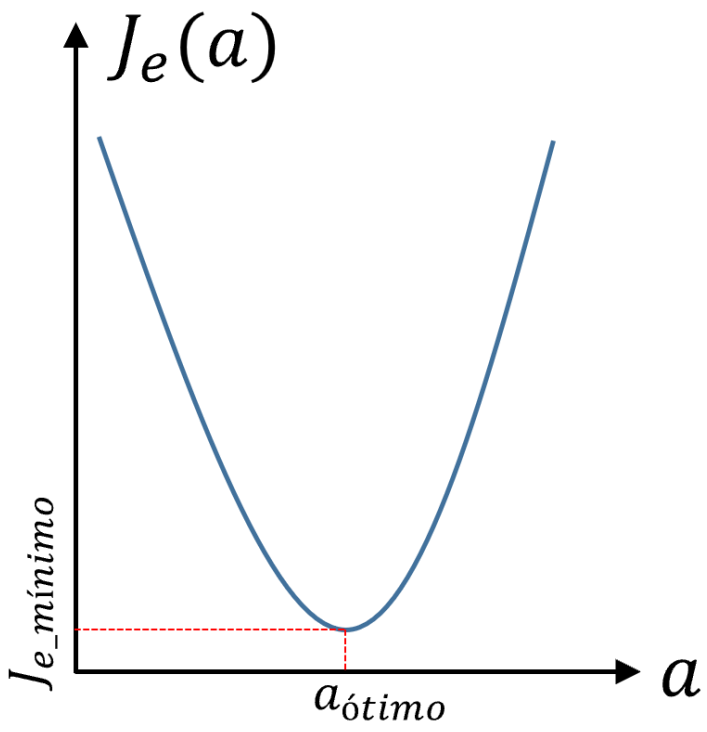

- Isso significa que a ***superfície de erro*** tem o formato de uma ***parábola convexa*** (i.e., tem formato de ***tigela*** ou ***vale***).
- A figura ao lado mostra o formato da ***superfície de erro para uma função hipótese com apenas um peso***.
- Para funções hipótese com mais pesos, teremos superfícies em 3 ou mais dimensões.

Superfície de erro

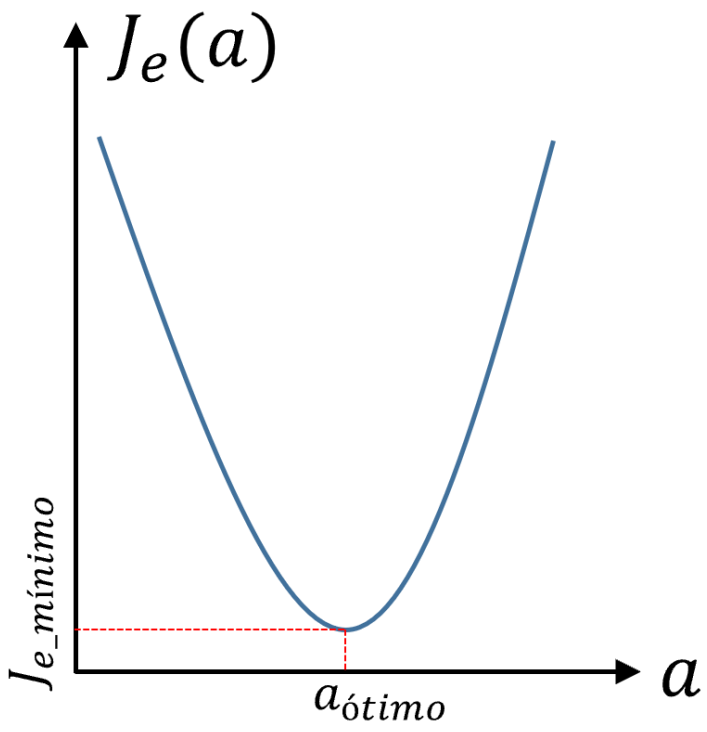

- Vejam que a superfície possui ***um único valor mínimo*** (i.e., o ***vértice*** da parábola).
- Esse ponto onde a superfície (i.e., a função de erro) tem o seu menor valor é chamado de ***ponto de mínimo***.
- Ele também é chamado de ***mínimo global***, pois não há outro valor do peso, a, que resulte em um erro menor.
- Toda ***superfície convexa só possui um mínimo***, o ***global***.
- Todos os outros valores têm erro maior.

Superfície de erro

- Este é o motivo de usarmos o ***erro quadrático médio*** como ***função de erro***, pois
  - a superfície resultante é convexa
  - e, consequentemente, ***só existe um único vetor de pesos***, $\boldsymbol{a}$, que ***minimiza a função de erro***.
- O ponto de mínimo nos dá o ***valor ótimo*** dos pesos da função hipótese.

- Este é o motivo de usarmos o ***erro quadrático médio*** como ***função de erro***, pois
  - a superfície resultante é convexa
  - e, consequentemente, ***só existe um único vetor de pesos***, $\boldsymbol{a}$, que ***minimiza a função de erro***.
- O ponto de mínimo nos dá o ***valor ótimo*** dos pesos da função hipótese.

Superfície de erro

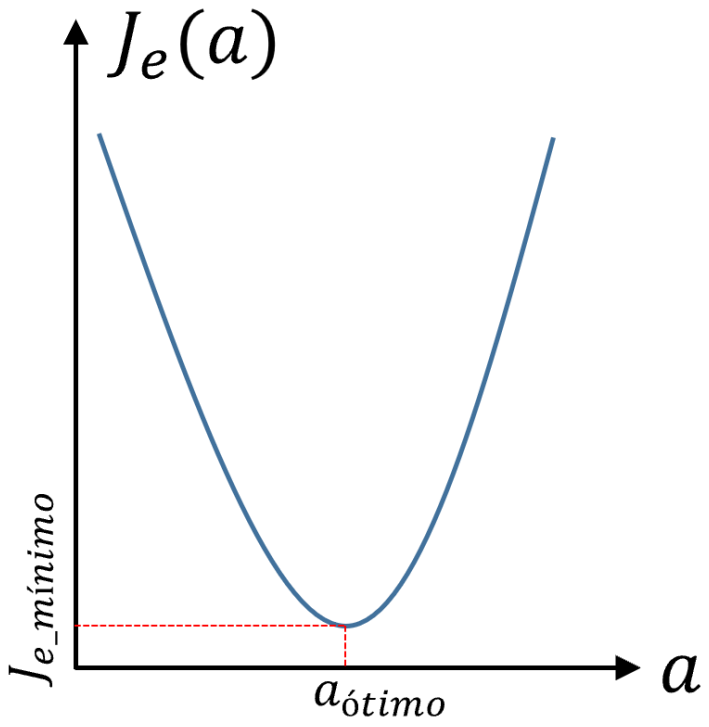

- O ***valor ótimo*** é encontrado
  - através da ***equação normal***.
  - ***visualmente***, em alguns casos, se plotarmos a superfície, pois basta ***localizar seu ponto mais baixo***.
  - ou através de um ***algoritmo de otimização iterativo*** que caminha sempre em direção à parte mais baixa da superfície.

Superfície de erro

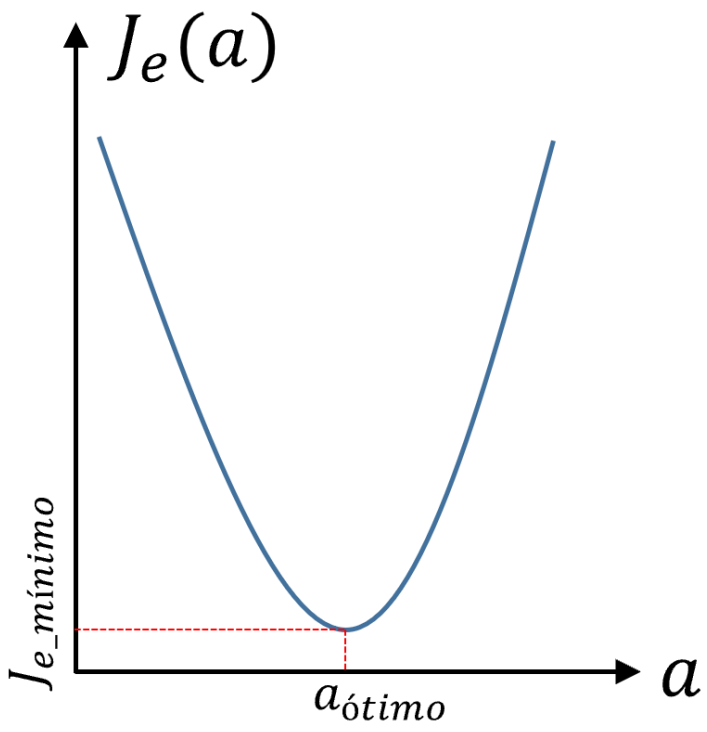

- O entendimento do ***formato*** e da questão da superfície ter ***apenas um único ponto de mínimo*** nos ajudará a entender como o ***algoritmo de otimização iterativa*** que vamos aprender em breve funciona.
- Na sequência, plotamos a superfície de erro para uma dada função hipótese.

Plotando a superfície de erro

- Vamos supor a seguinte ***função observável***

$$y_{\text{noisy}}(n) = y(n) + w(n),$$

onde $w(n) \sim N(0,1)$ e $y(n)$ é a ***função objetivo*** (ou ***modelo gerador***) dada por

$$y(n) = a_1 x_1(n) + a_2 x_2(n),$$

onde $x_1(n)$ e $x_2(n) \sim U(-1,1)$ e $a_1 = a_2 = 1$.

- Agora, suponhamos que nós quiséssemos aproximar a ***função objetivo*** a partir, apenas, de suas ***amostras ruidosas*** com a seguinte ***função hipótese***

$$h(\boldsymbol{x}(n), \hat{\boldsymbol{a}}) = \hat{y}(n) = \hat{a}_1 x_1(n) + \hat{a}_2 x_2(n).$$

- **Como encontraríamos os valores de $\hat{a}_1$ e $\hat{a}_2$?**

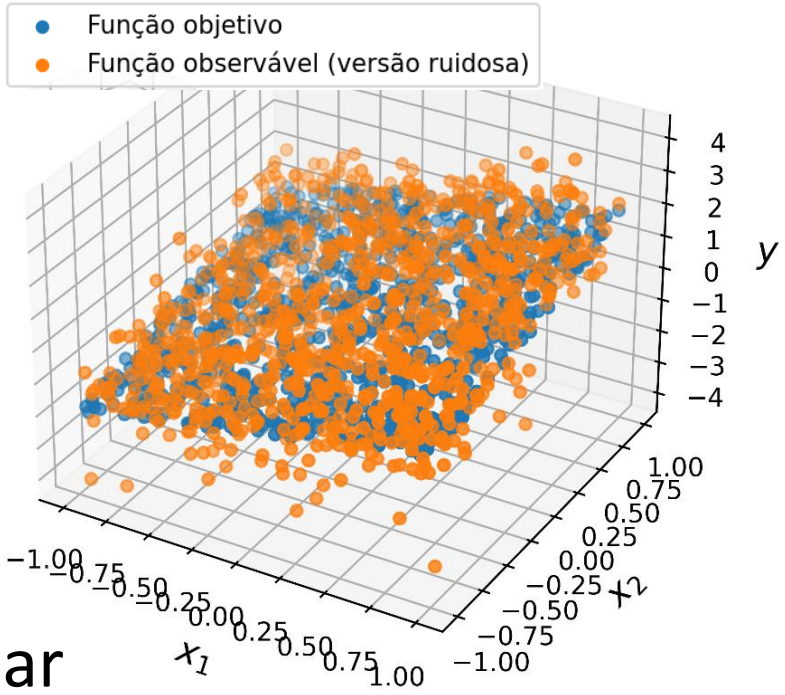

OBS.: para não confundirmos com os pesos originais, a_1 e a_2, vamos usar $\hat{a}_1$ e $\hat{a}_2$ para nos referir aos pesos da função hipótese, i.e., as estimativas de a_1 e a_2.

Exemplo: error_surface_example2.ipynb

Plotando a superfície de erro

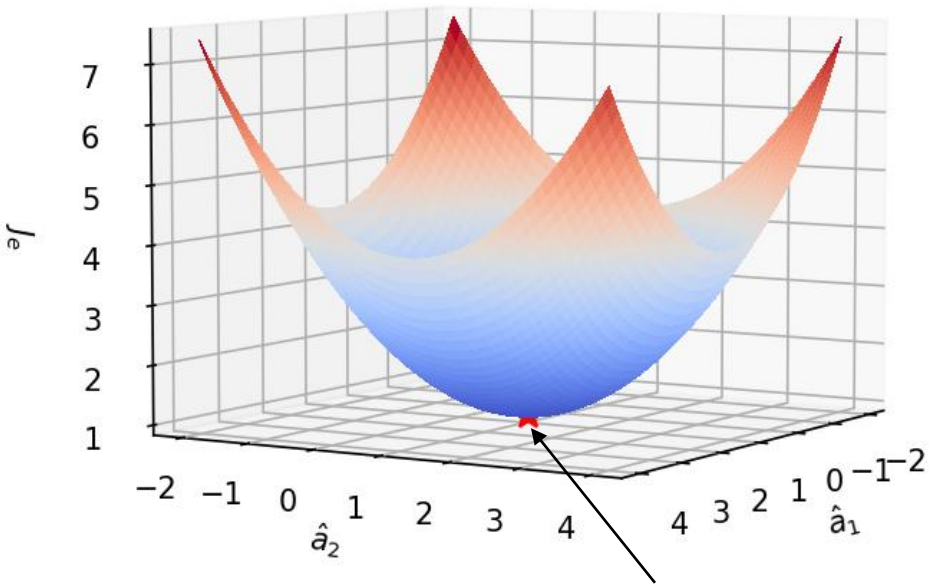

solução ótima
=
ponto mais baixo
da superfície

- Até o momento, conseguiríamos encontrar o ***ponto de mínimo*** com a ***equação normal*** ou ***visualmente***, plotando a ***superfície de erro*** a partir da função do EQM

$$J_e(\hat{a}_1, \hat{a}_2) = \frac{1}{N}\sum_{n=0}^{N-1}\Big(y_{\text{noisy}}(n) - \hat{y}(n)\Big)^2$$

$$= \frac{1}{N}\sum_{n=0}^{N-1}\Big(y_{\text{noisy}}(n) - (\hat{a}_1 x_1(n) + \hat{a}_2 x_2(n))\Big)^2 .$$

e ***procurando por sua parte mais baixa***.

Plotando a superfície de erro

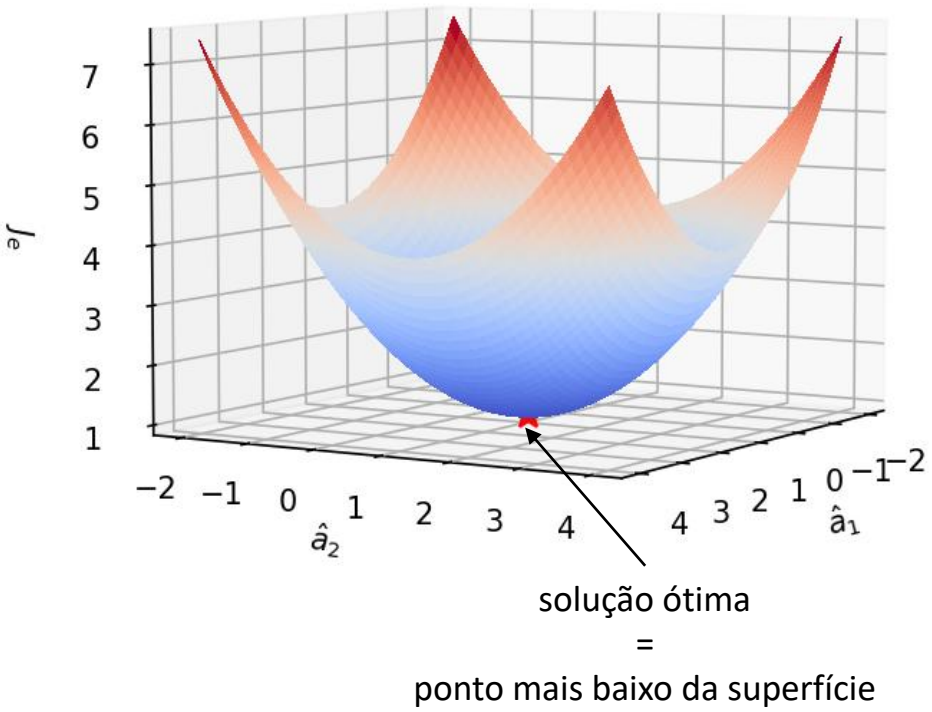

- Os valores de erro, $J_e(\hat{a}_1, \hat{a}_2)$, para plotarmos a ***superfície de erro*** são obtidos variando-se $\hat{a}_1$ e $\hat{a}_2$ na equação do EQM.
- Para este exemplo, onde temos dois atributos, a ***superfície de erro*** é ***representada por uma figura em 3 dimensões***, onde cada par de valores $\hat{a}_1$ e $\hat{a}_2$ corresponde a um erro, $J_e(\hat{a}_1, \hat{a}_2)$.

Plotando a superfície de erro

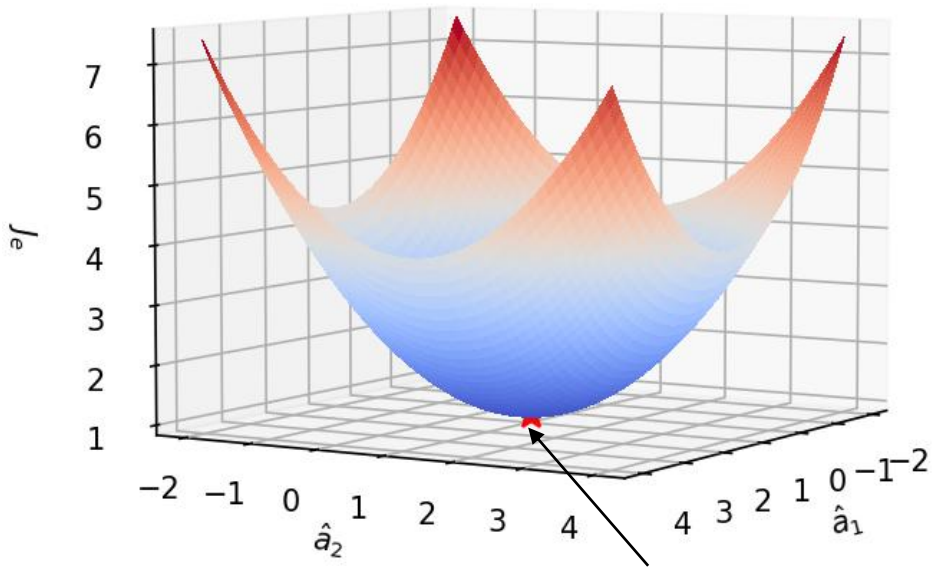

solução ótima
=
ponto mais baixo da superfície

- Devido a superfície ser ***convexa***, temos apenas ***um ponto de mínimo***, o ***mínimo global***.
- O ***mínimo global*** é ponto mais baixo da superfície e nos dá a solução ótima.
- ***Observações***
  - Só conseguimos encontrar o ponto de mínimo de ***forma visual*** se tivermos funções hipóteses com até 2 atributos.
  - Além disso, é uma ***solução com altíssima complexidade computacional***, pois usa a força bruta para encontrar o ponto ótimo.
  - Assim, em geral, usamos a forma fechada.

Plotando a superfície de contorno

- Outra figura importante que plotamos a partir dos resultados obtidos para plotar a superfície de erro é chamada de ***superfície de contorno***.
- Uma superfície de contorno contém várias ***linhas de contorno***.
  - Uma ***linha de contorno*** é uma ***curva ao longo da qual uma função tem um valor constante***.
- Na superfície de erro, cada linha indica uma curva ao longo da qual o ***erro*** é ***constante***.
- Ou seja, ***qualquer par de valores*** $\hat{a}_1$ e $\hat{a}_2$ ao longo de uma mesma curva ***terá o mesmo valor de erro***.

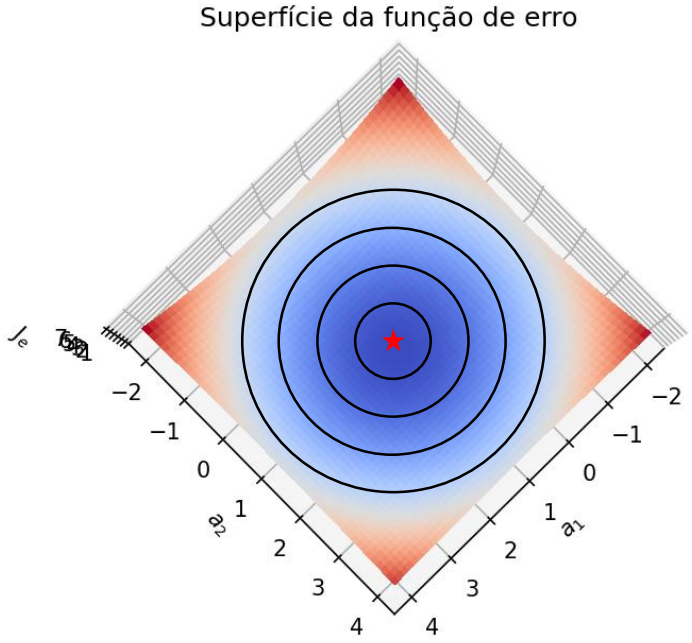

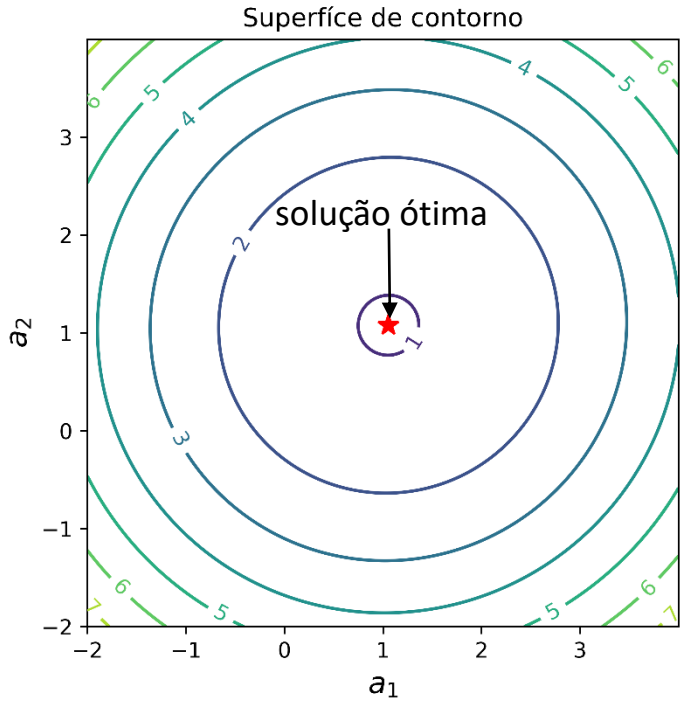

Porém, nem tudo são flores com a equação normal...

Desvantagens da equação normal

- **Alta complexidade computacional**: a solução da ***equação normal*** envolve o ***cálculo da inversa*** de $\boldsymbol{X}^T\boldsymbol{X}$.
- Esse cálculo tem complexidade computacional que varia de $O(K^{2.4})$ a $O(K^3)$, onde K é o número de atributos.
  - "*Big O*" é uma notação usada para analisar como o ***tempo de execução de um algoritmo cresce à medida que o número de entradas aumenta***.
  - **Exemplo**: Se o número de ***atributos***, K, passar de 1 para 2, o tempo para cálculo aumenta de $2^{2.4} = 5.3$ a $2^3 = 8$ vezes.
- Alguns conjuntos de dados podem ter centenas ou até milhares de atributos!
  - ***House Prices*** é um dataset com informações de casas que possui 79 atributos.
  - ***ImageNet*** é um dataset com imagens, onde cada imagem tem em média 256x256= 65536 *pixels* e cada *pixel* é um atributo.

Desvantagens da equação normal

- Além disso, dependendo do número de ***exemplos do conjunto de treinamento***, N, e de ***atributos***, $\boldsymbol{x}$, a matriz de atributos, $\boldsymbol{X}$, pode se tornar ***muito grande***.
- Consequentemente, a inversão de matrizes e os cálculos associados podem ***consumir muita CPU e memória***.
  - O que pode ser um limitante para dispositivos com recursos restritos (e.g., IoT).
- Adicionalmente, para irmos ***além dos modelos lineares*** (i.e., modelos não-lineares como classificadores e redes neurais) precisamos lidar com o fato de que ***nem sempre existem formas fechadas*** como a ***equação normal***.
- **Portanto, essa abordagem não é escalonável e muito menos flexível!**

Então o que pode ser feito para encontramos a solução ótima?

Abordagens iterativas de otimização

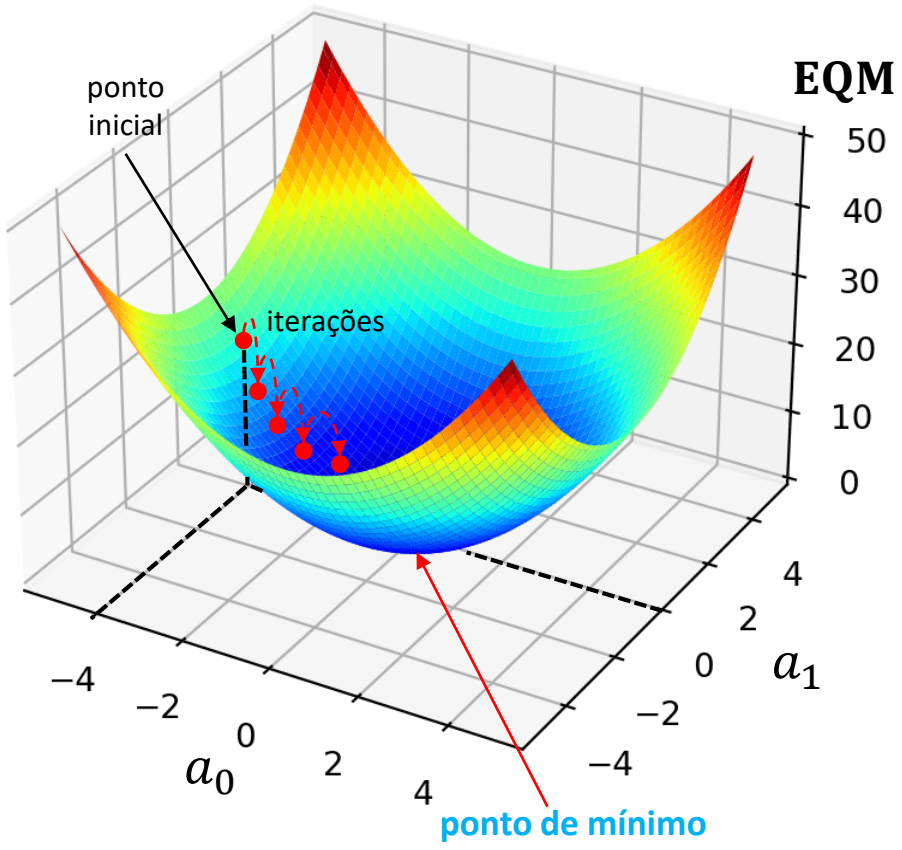

- Podemos usar ***algoritmos de otimização iterativos***.
- Eles têm ***complexidade menor e ajustável*** e são ***flexíveis*** o suficiente para trabalhar com modelos lineares e não lineares.
- Esses algoritmos "***procuram***" de forma ***iterativa*** o ***ponto mais baixo da superfície de erro***, ou seja, o ponto que nos dá os ***pesos ótimos***.

Abordagens iterativas de otimização

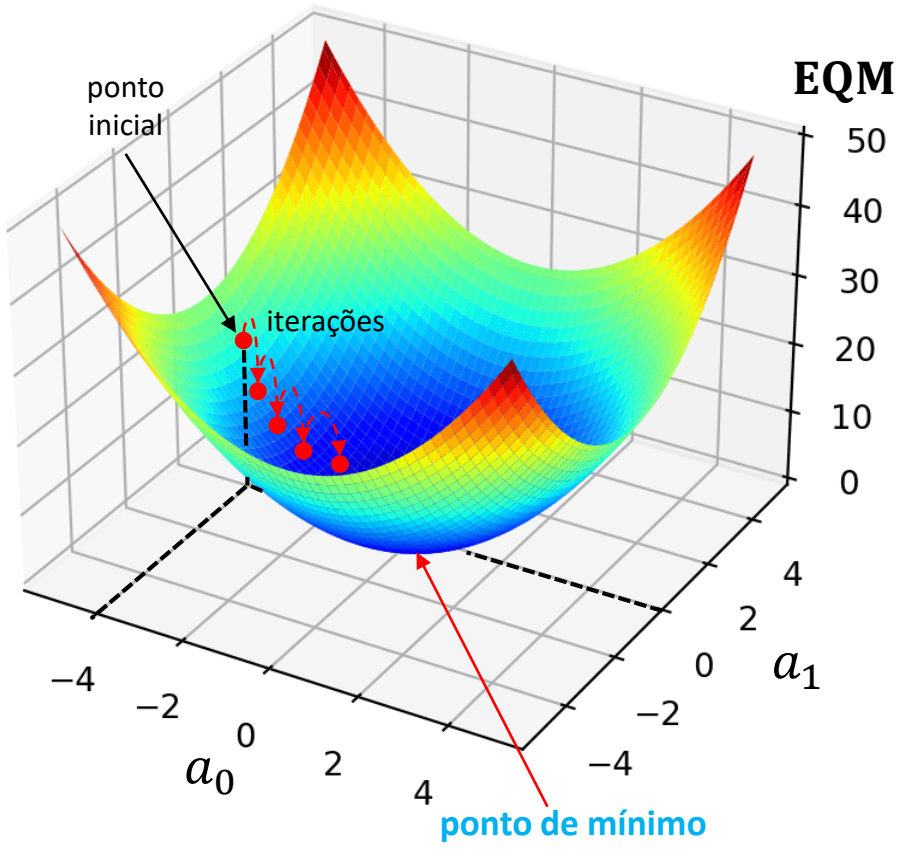

- Esses algoritmos são, em geral, ***inicializados com pesos aleatórios***.
- E, a ***cada iteração***, eles ***refinam*** os valores dos pesos, ficando mais e mais próximos do ***ponto de mínimo***.
- Um exemplo de abordagem iterativa é o algoritmo do ***gradiente descendente (GD)***.
- O GD busca ***iterativamente***, a partir de um ponto inicial, o ***ponto mais baixo da superfície de erro***.

Tarefas

- **Quiz**: *“T319 - Quiz - Regressão: Parte I”* que se encontra no MS Teams.
- **Exercício Prático**: **Laboratório #2**.
  - Pode ser acessado através do link acima (Google Colab) ou no GitHub.
  - Vídeo explicando o laboratório: Arquivos -> Recordings -> Laboratório #2
  - Se atentem aos prazos de entrega.
  - Instruções para resolução e entrega dos laboratórios.

Obrigado!

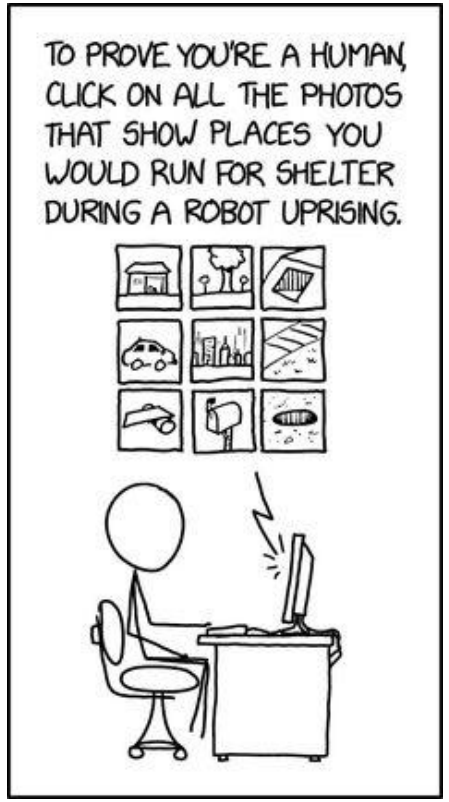

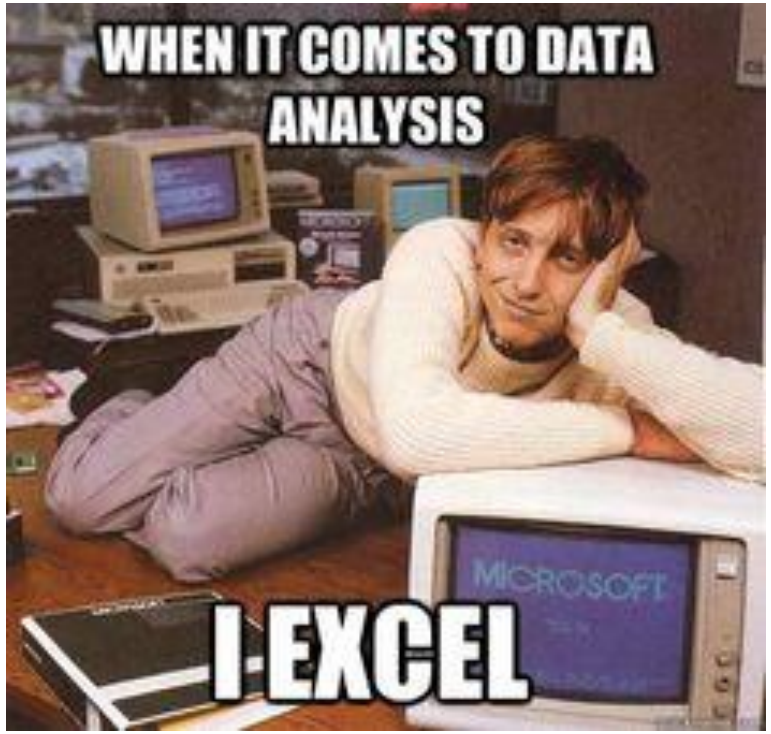

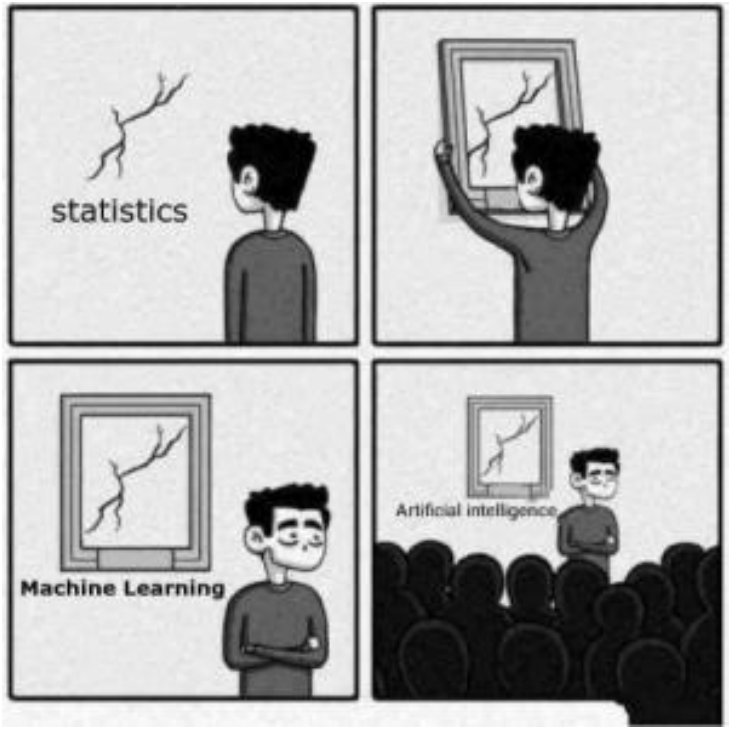

Albert Einstein: Insanity Is Doing the Same Thing Over and Over Again and Expecting Different Results

Machine learning:

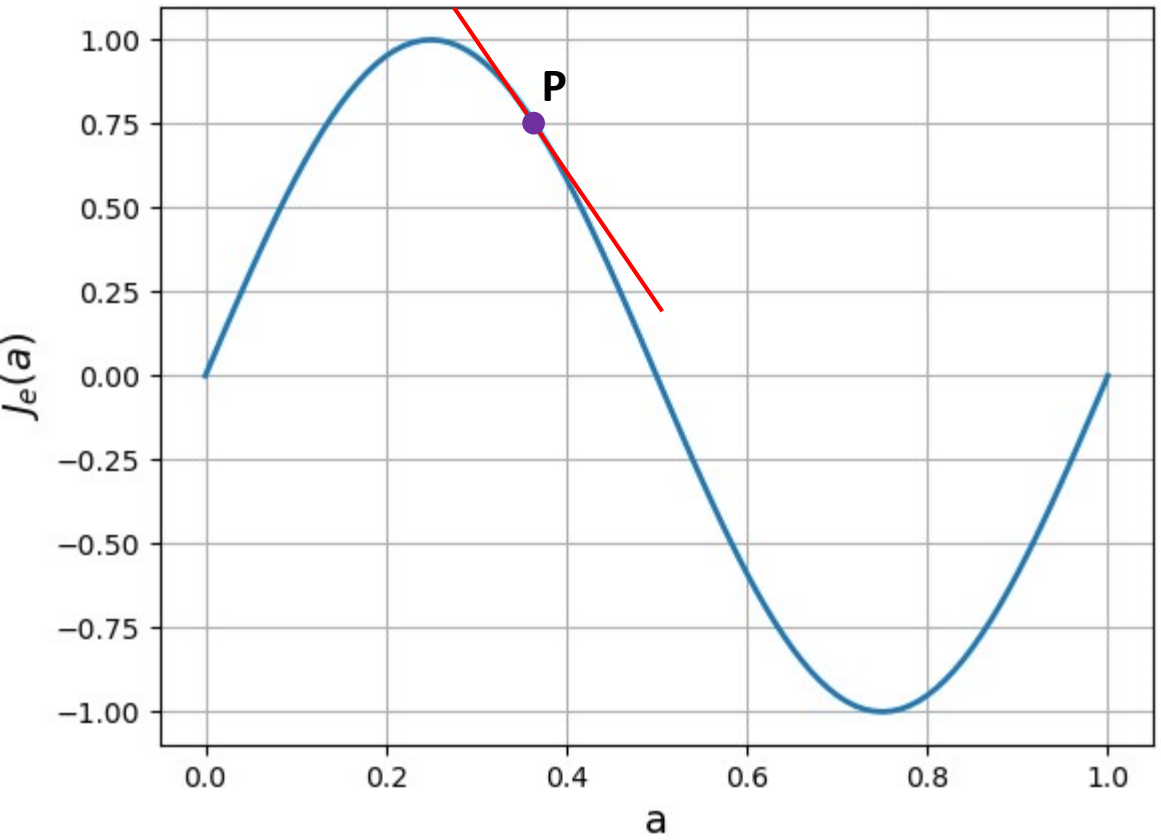
P
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00
$J_e(a)$
0.0
0.2
0.4
0.6
0.8
1.0
a

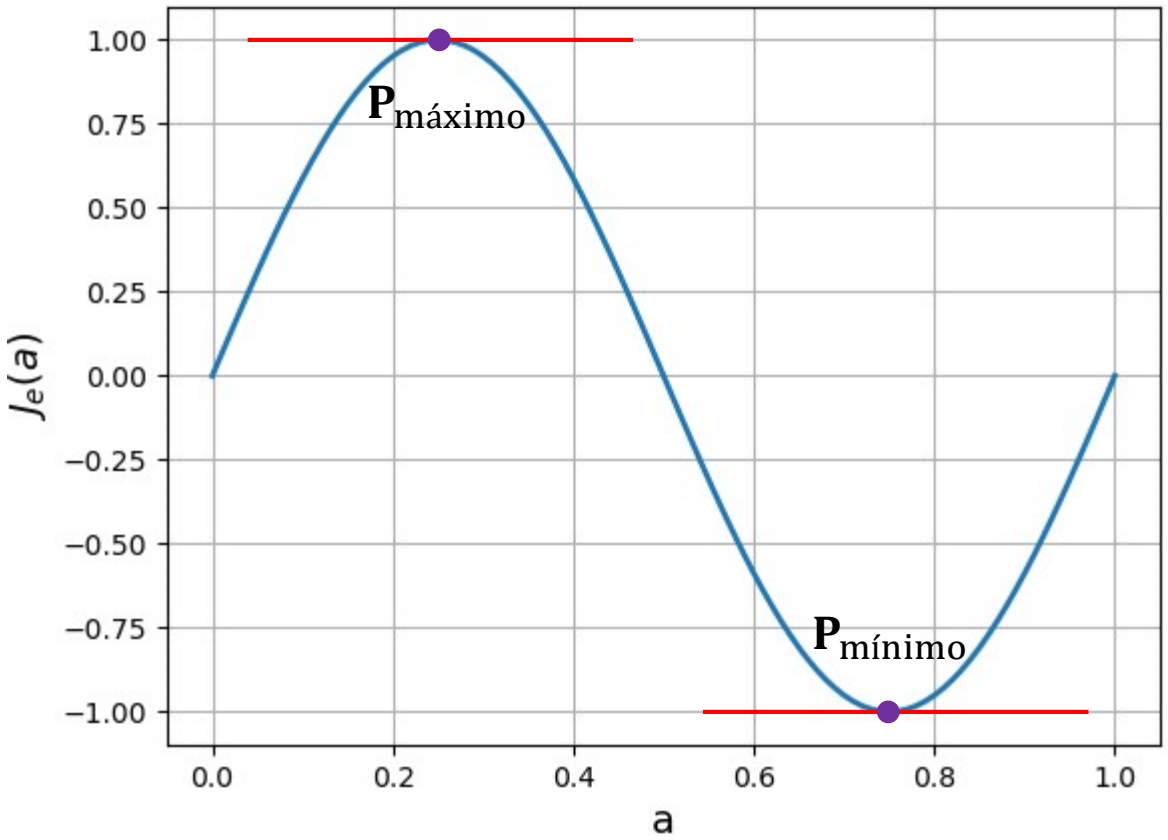
$P_{máximo}$
$P_{mínimo}$
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00
$J_e(a)$
0.0
0.2
0.4
0.6
0.8
1.0
a

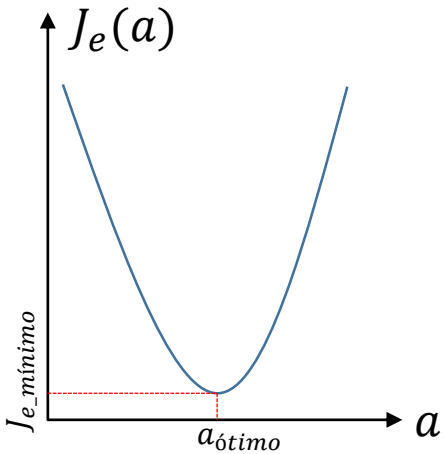
$J_e(a)$
$J_{e_mínimo}$
$a_{ótimo}$
a