


T319 - Introdução ao Aprendizado de Máquina: *Regressão Linear (Parte III)*




Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

Recapitulando

- No tópico anterior, falamos sobre o vetor gradiente.
- Aprendemos dois algoritmos que usam o vetor gradiente para a resolução de problemas de otimização:
 - ***Gradiente ascendente*** para problemas de **maximização**.
 - ***Gradiente descendente*** para problemas de **minimização**.
- Aprendemos as três versões do gradiente descendente:
 - Batelada
 - Estocástico
 - Mini-batch
- Neste tópico, discutiremos o quão importante é o ajuste da taxa de aprendizagem, α .

Escolha da taxa de aprendizagem



- Conforme nós vimos antes, no gradiente descendente, o **negativo** do **veter gradiente**, $-\nabla f(x)$:
 - dá a **direção de decrescimento mais rápido de uma função** a partir de um ponto qualquer
 - e sua **magnitude** indica a **taxa de variação da função** nessa direção.
- Porém, ele **não nos informa a distância até o ponto de máximo**.

Escolha da taxa de aprendizagem

$$\mathbf{a} \leftarrow \mathbf{a} - \alpha \frac{\partial J_e(\mathbf{a})}{\partial \mathbf{a}}$$

- Portanto, para *andarmos na direção oposta à apontada pelo vetor gradiente*, usamos uma *porcentagem* do seu valor.
- Essa porcentagem é dada pela *taxa de aprendizagem*, α , que é sempre um valor maior do que zero.

Escolha da taxa de aprendizagem

$$\mathbf{a} \leftarrow \mathbf{a} - \alpha \frac{\partial J_e(\mathbf{a})}{\partial \mathbf{a}}$$

- A taxa de aprendizagem *controla o quão "grande" ou "pequena" é a atualização aplicada aos pesos* do modelo em cada iteração do processo de treinamento.
- Ou seja, ela determina o *tamanho do passo dado na direção oposta à indicada pelo vetor gradiente*.
- *Porém, qual deve ser o tamanho desse passo?*

Portanto, como veremos, a escolha da taxa de aprendizagem é muito importante para o **aprendizado** de um modelo de ML.


Escolha da taxa de aprendizagem

- O passo de aprendizagem é um *hiperparâmetro* que influencia diretamente o *desempenho e a convergência* do algoritmo do gradiente descendente.
 - **Hiperparâmetros:** são *parâmetros que não são aprendidos durante o treinamento* do modelo, mas que *influenciam* seu aprendizado.
- Valores *muito pequenos* podem resultar em *treinamento lento*, enquanto valores *muito grandes* podem causar *divergência*.

Escolha da taxa de aprendizagem

- Em geral, a escolha da taxa é feita **empiricamente** por meio de experimentação.
- Uma regra empírica para a **exploração** da taxa de aprendizagem é usar a seguinte sequência (**ajuste manual**):

..., 0.001, 0.003, 0.01, 0.03, 0.1, 0.3, 1.0, ...






The diagram shows a sequence of learning rates: ..., 0.001, 0.003, 0.01, 0.03, 0.1, 0.3, 1.0, Below the sequence, blue curved arrows point from each number to the next one. Under each arrow is a label: '3 x' for the first arrow (0.001 to 0.003), '≈ 3 x' for the second (0.003 to 0.01), '3 x' for the third (0.01 to 0.03), '≈ 3 x' for the fourth (0.03 to 0.1), '3 x' for the fifth (0.1 to 0.3), and '≈ 3 x' for the sixth (0.3 to 1.0).

- Vejamos um exemplo sobre como a taxa de aprendizagem afeta a convergência de um modelo.




Passo de aprendizado pequeno

- Caso a taxa de aprendizagem seja **muito pequeno**, a **convergência do algoritmo será muito lenta**.
- No exemplo abaixo, com $\alpha = 2 \times 10^{-6}$, o algoritmo atinge o ponto de mínimo, i.e., converge, após mais de 250 épocas.
 - **Passos muito curtos**, fazem com que o algoritmo **caminhe vagarosamente em direção ao mínimo global da função de erro**.




Passo de aprendizado grande

- Caso a taxa seja grande, o algoritmo pode nunca convergir.
- Se a taxa for grande, *mas não tão grande assim*, o algoritmo pode ficar “*pulando*” ou “*oscilando*” de um lado para o outro da superfície de erro até que, por sorte, ele converge.
 - No exemplo abaixo, com $\alpha = 1.8 \times 10^{-4}$, o algoritmo oscila inicialmente, mas acaba convergindo após 20 épocas.



Passo de aprendizado grande


feedback positivo → estouro da precisão numérica



- Em outros casos, quando a taxa é **muito grande** , a cada época, o algoritmo “pula” para um **valor de erro mais alto do que o anterior** e, assim, acaba divergindo.
- Ou seja, ao invés de se aproximar do ponto de mínimo a cada época, ele **se distancia dele** .

Passo de aprendizado grande




feedback positivo → estouro da precisão numérica




- Nesse caso ocorre um **ciclo de feedback positivo** onde **a cada época** os valores dos **gradientes** e, conseqüentemente, dos **pesos se tornam maiores e maiores** até que ocorra o **estouro (overflow) da representação numérica**.
 - **Overflow**: problema que ocorre quando uma variável não pode mais representar um valor, pois ele é maior do que o intervalo que ela pode armazenar.

Passo de aprendizado ideal

- Portanto, o valor da taxa de aprendizagem deve ser **explorado** para se encontrar um **valor ideal** que **acelere a convergência** de forma **estável**, ou seja, sem oscilações.
- O exemplo abaixo, com $\alpha = 10^{-4}$, o algoritmo converge de forma estável para o **mínimo global** em apenas 3 épocas.






Analizando o treinamento de um modelo






- *Nem sempre nós iremos conseguir plotar as superfícies de erro e de contorno* para analisarmos o treinamento de um modelo.
- Por exemplo, quando tivermos *três atributos*, a *superfície de erro terá quatro dimensões*, tornando sua análise mais difícil.
- Assim, em geral, usamos a *curva do erro (i.e., EQM) em função das iterações* de treinamento para analisar o aprendizado de um modelo.
- Vejamos alguns exemplos.

Analizando o treinamento de um modelo





- A figura ao lado mostra o **comportamento esperado** quando o **passo tem o tamanho ideal**.
- A **convergência** nesse caso é **rápida**.
 - O **erro diminui rapidamente nas primeiras iterações**.
 - Conforme o treinamento continua, o **erro se estabiliza e exibe uma redução suave** (i.e., mais lenta).
 - A **convergência é atingida quando o erro se torna praticamente constante** ao longo das iterações, indicando que os **pesos não são mais atualizados**, pois o mínimo da função foi atingido.
 - Por exemplo, o treinamento pode ser encerrado quando o erro entre duas iterações consecutivas for menor do que um valor pré-definido (e.g., $1e-5$).

Analizando o treinamento de um modelo






- A figura mostra o caso onde a ***taxa de aprendizagem é muito pequena***.
- Nesse caso, a ***convergência é muito lenta***.
- ***Após várias iterações*** de treinamento, o ***erro ainda não se estabilizou***.
- Levaria ***muito tempo*** para que o modelo atingisse o ***ponto de mínimo***.

Analizando o treinamento de um modelo




- A figura mostra o caso onde a **taxa de aprendizagem é muito grande**.
- Nesse caso, ocorre **divergência**.
- Ou seja, o **erro aumenta mais e mais ao longo do treinamento**, indicando que o algoritmo está se **distanciando do ponto de mínimo**.
- Se o treinamento continuar, os gradientes e pesos podem se tornar tão grandes que ocorre o **estouro da representação numérica**.

Analizando o treinamento de um modelo



- A figura mostra o caso onde a *taxa de aprendizagem é grande, mas não tão grande assim*.
- Nesse caso, o *erro oscila*, aumentando e diminuindo.
- Por ventura, a *convergência pode ocorrer após algumas iterações*.


Melhorando a convergência das versões estocásticas



Gradiente descendente estocástico (SGD)

- As versões estocásticas do GD, i.e., SGD e *mini-batch* (principalmente quando MB é pequeno), são **mais rápidas e menos complexas** computacionalmente que o GDB.
- Porém, elas têm um **caminho irregular para o ponto de mínimo**.
 - Devido à estimativa do vetor gradiente.
- Além disso, quando as **amostras** do conjunto de treinamento estão **contaminadas com ruído**, eles **podem não convergir** para o mínimo (i.e., ficam oscilando ao redor dele).

Melhorando a convergência das versões estocásticas



Gradiente descendente estocástico (SGD)

- Esses problemas *impactam* o *desempenho do modelo* e deixam o *treinamento lento* e, possivelmente, *instável*.
- Entretanto, existem *técnicas para minimizar* esses problemas, deixando essas versões do GD *mais comportadas*.
- As mais conhecidas envolvem o *ajuste do passo de aprendizagem* e/ou do *termo de atualização dos pesos*.
 - **Redução do passo:** força a convergência
 - **Ajuste adaptativo:** passos independentes
 - **Termo momentum:** redução da variação de direção

Redução gradual do passo de aprendizagem

- *Redução gradual* (ou decaimento) do passo de aprendizagem *diminui gradualmente o passo de aprendizagem* ao longo do treinamento.
- A redução da taxa de aprendizagem faz com que as *atualizações dos pesos se tornem cada vez menores* à medida que o treinamento progride, o que pode *melhorar (ou forçar) a convergência*.

$$\mathbf{a}(i + 1) = \mathbf{a}(i) - \boxed{\alpha(i)} \nabla \hat{J}_e (\mathbf{a}(i)),$$

onde i é número da iteração de atualização atual e $\nabla \hat{J}_e (\mathbf{a}(i))$ é a *estimativa do vetor gradiente*.

- Essa é a *técnica mais simples* das que veremos, *mas precisamos encontrar os hiperparâmetros* que dão a taxa ideal de redução do passo de aprendizagem de forma que haja a convergência.
- Veremos em breve um exemplo de como ela funciona.

Técnicas mais comuns para a redução do passo

- As três técnicas mais comuns para a **redução gradual** do passo de aprendizagem são:
 - **Decaimento por etapas ou degraus:** reduz o passo de aprendizagem inicial, α_0 , de um fator, τ , a cada número pré-definido de iterações, β . Um valor típico para reduzir a taxa de aprendizado é de $\tau = 0.5$ a cada β de iterações.
 - **Decaimento exponencial:** é dado pela equação $\alpha(i) = \alpha_0 e^{-ki}$, onde α_0 , k e i são passo de aprendizagem inicial, a taxa de decrescimento e o número da iteração de atualização atual, respectivamente.
 - **Decaimento temporal:** é dado pela equação $\alpha(i) = \alpha_0 / (1+ki)$ onde α_0 , k e i têm o mesmo significado que no decaimento exponencial.
- Entretanto, percebam que ainda temos que encontrar os valores ideais para os **hiperparâmetros** α_0 , τ , β e k .

Termo momentum

- O **termo momentum** adiciona a **média do histórico de estimativas do vetor gradientes**, $\mathbf{v}$, à equação de atualização dos pesos, **tornando as atualizações menos ruidosas**, e, conseqüentemente, **acelerando a convergência** do algoritmo.

$$\begin{aligned}\mathbf{v}(i) &= \mu \mathbf{v}(i-1) + (1-\mu) \nabla \hat{J}_e(\mathbf{a}(i)), \\ \mathbf{a}(i+1) &= \mathbf{a}(i) - \alpha \mathbf{v}(i),\end{aligned}$$

onde $\nabla \hat{J}_e(\mathbf{a}(i))$ é a **estimativa do vetor gradiente** para a i -ésima iteração e μ , chamado de **coeficiente de momentum**, determina a quantidade de estimativas anteriores que são consideradas no cálculo da média.


- Em geral, o passo de aprendizagem é constante, mas pode decair também.
- A **desvantagem** é que nós precisamos encontrar os valores ideais dos **hiperparâmetros** α e μ .

Variação adaptativa dos passos


- Estas técnicas ajustam *automaticamente* o *passo de aprendizado para cada peso* ao longo do treinamento, em vez de usar um único valor fixo.
 - Cada peso do modelo tem seu próprio passo de aprendizagem.
 - Cada passo é adaptado com base no histórico dos gradientes.
- As técnicas mais conhecidas são AdaGrad, RMSProp e Adam.
- **AdaGrad** reduz o passo usando o acúmulo de gradientes anteriores, mas sofre com a redução excessiva do passo ao longo do tempo.
- **RMSProp** usa uma média móvel dos gradientes anteriores para evitar que o passo caia demais.
- **Adam** combina RMSProp com o termo momento (média dos gradientes).
- Em geral, *não precisam de ajuste de nenhum hiperparâmetro*.

Exemplo de redução programada com GDE


Sem redução gradual




Redução gradual por degraus




Com redução gradual



- O caminho com **decaimento gradual** também não é regular para o ponto de mínimo.
- Ele apresenta **algumas mudanças de direção** ao longo do caminho.
- O **passo não influencia na direção, apenas no tamanho** do deslocamento.




```
# learning schedule: Gradual decay.  
def stepDecay(alpha_init, t, beta=6.0, drop=0.5):  
    """Gradual decay."""  
    alpha = alpha_init * math.pow(drop, math.floor((1+t)/beta))  
    return alpha
```




Exemplo de redução programada com GDE


Sem redução gradual




Redução gradual por degraus




Com redução gradual



- Porém, a **oscilação em torno do mínimo é bastante reduzida** devido à **diminuição gradual** do passo de aprendizagem, α .
- Conseguimos observar o efeito da redução de α nas figuras que mostram os elementos do vetor gradiente e de atualização.




```
# learning schedule: Gradual decay.  
def stepDecay(alpha_init, t, beta=6.0, drop=0.5):  
    """Gradual decay."""  
    alpha = alpha_init * math.pow(drop, math.floor((1+t)/beta))  
    return alpha
```




Exemplo de redução programada com GDE


Sem redução gradual




Redução gradual por degraus




Com redução gradual



- **Conclusão:** um passo de aprendizagem que tem seu valor reduzido ao longo das iterações de treinamento permite que *versões estocásticas do gradiente descendente se estabilizem* próximo ao ponto de mínimo global.




```
# learning schedule: Gradual decay.  
def stepDecay(alpha_init, t, beta=6.0, drop=0.5):  
    """Gradual decay."""  
    alpha = alpha_init * math.pow(drop, math.floor((1+t)/beta))  
    return alpha
```




Tarefas

- **Quiz:** “*T319 - Quiz - Regressão: Parte III*” que se encontra no MS Teams.
- **Exercício Prático:** [Laboratório #4](#).
 - Pode ser acessado através do link acima (Google Colab) ou no GitHub.
 - Vídeo explicando o laboratório: Arquivos -> Recordings -> Laboratório #4
 - Se atentem aos prazos de entrega.
 - [Instruções para resolução e entrega dos laboratórios](#).


Obrigado!



When someone asks why you never stops talking about machine learning




IF IF IF IF IF IF IF IF IF IF WE!






Albert Einstein: Insanity Is Doing the Same Thing Over and Over Again and Expecting Different Results


Machine learning:




FIGURAS





















gradiente negativo: $a_1 = a_1^{\text{inicial}} + \alpha \nabla J_e(a_1)$
 a_1 aumenta e se aproxima do mínimo





gradiente positivo: $a_1 = a_1^{\text{inicial}} - \alpha \nabla J_e(a_1)$
 a_1 diminuiu e se aproxima do mínimo









Gradiente Descendente Estocástico

